

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
PHÂN HIỆU TẠI TP. HỒ CHÍ MINH
BỘ MÔN CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN TỐT NGHIỆP

**ĐỀ TÀI: NGHIÊN CỨU VÀ ĐÁNH GIÁ PHƯƠNG PHÁP LAI GIỮA
TRÍCH RÚT VÀ DIỄN GIẢI CHO BÀI TOÁN TÓM TẮT VĂN BẢN
TIẾNG VIỆT**

Giảng viên hướng dẫn: THS. TRẦN PHONG NHÃ

Sinh viên thực hiện: NGUYỄN HỮU TOÀN

Lớp : CÔNG NGHỆ THÔNG TIN

Khoá : 63

Tp. Hồ Chí Minh, tháng 07 năm 2026

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
PHÂN HIỆU TẠI TP. HỒ CHÍ MINH
BỘ MÔN CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN TỐT NGHIỆP

**ĐỀ TÀI: NGHIÊN CỨU VÀ ĐÁNH GIÁ PHƯƠNG PHÁP LAI GIỮA
TRÍCH RÚT VÀ DIỄN GIẢI CHO BÀI TOÁN TÓM TẮT VĂN BẢN
TIẾNG VIỆT**

Giảng viên hướng dẫn: THS. TRẦN PHONG NHÃ

Sinh viên thực hiện: NGUYỄN HỮU TOÀN

Lớp : CÔNG NGHỆ THÔNG TIN

Khoá : 63

Tp. Hồ Chí Minh, tháng 07 năm 2026

NHIỆM VỤ THIẾT KẾ TỐT NGHIỆP

BỘ MÔN: CÔNG NGHỆ THÔNG TIN

Mã sinh viên: 6351071071

Họ tên SV: Nguyễn Hữu Toàn

Khóa: 63

Lớp: Công nghệ thông tin

1. Tên đề tài

Nghiên cứu và đánh giá phương pháp lai giữa trích rút và diễn giải cho bài toán tóm tắt văn bản tiếng Việt.

2. Mục đích thực hiện

Trong thời đại công nghệ số hiện nay, lượng thông tin ngày càng gia tăng nhanh chóng nhất là trong các lĩnh vực báo chí, các tài liệu nghiên cứu khoa học cũng như các tài liệu học tập. Nhu cầu khai thác thông tin cũng theo đó mà ngày càng tăng cao cho nên cần có những ứng dụng, phần mềm để tổng hợp thông tin, trích lọc những nội dung quan trọng trong những tài liệu có độ dài vừa phải nhưng phải đảm bảo yêu cầu về tốc độ tóm tắt thông tin cũng như phải trích rút được đầy đủ các nội dung quan trọng trong các tài liệu. Từ như cầu đó nên website tóm tắt văn bản, so sánh tốc độ, độ tương đồng ngữ nghĩa giữa bản gốc với các bản tóm tắt của nhiều loại hình tóm tắt đã ra đời không chỉ phục vụ mục đích tóm tắt văn bản của người dùng mà còn tạo ra một hệ thống so sánh giữa các loại hình tóm tắt với nhau, các loại hình tóm tắt nói ở đây là tóm tắt trích rút, tóm tắt diễn giải và tóm tắt lai hybrid.

Không chỉ xây dựng hệ thống so sánh các loại hình tóm tắt với nhau mà còn xây dựng một mô hình chatbot LLM để có thể đọc các tài liệu mà người dùng tải lên, trả lời một vài câu hỏi đơn giản, đa phần sẽ liên quan đến công việc trích rút các nội dung chính của tài liệu cũng như tóm tắt văn bản. Từ đây mục tiêu đề tài cũng đã được vạch sẵn để phục vụ các nghiệp vụ phân tích hệ thống và xây dựng ứng dụng sau này.

3. Nội dung và phạm vi đề tài

Nội dung của đề tài này là tập trung vào nghiên cứu và xây dựng ra một hệ thống website hoàn chỉnh cho phép người dùng có thể đưa đầu vào là văn bản, file .pdf, .docx hoặc .txt để hệ thống nhận diện, trích xuất văn bản và đưa văn bản vào các mô hình tóm tắt và cho ra kết quả tóm tắt cuối cùng. Không chỉ tóm tắt văn bản mà website còn cung cấp một hệ thống đánh giá kết quả của bản tóm tắt dựa trên các chỉ số như Rouge-1, Rouge-2, Rouge-L, Rouge-LSum, BERTScore Precision, BERTScore Recall, BERTScore F1 và Latency (s), các độ đo này sẽ được giới thiệu chi tiết ở các phần sau.

Những mô hình tóm tắt được sử dụng trong đề tài bao gồm: các mô hình tóm tắt trích rút như TextRank, LexRank, LSA; các mô hình tóm tắt diễn giải là ViT5, mT5, BARTPho và các mô hình tóm tắt lai giữa 2 loại này như TextRank_ViT5, LexRank_ViT5, LSA_ViT5, TextRank_mT5,...Chúng ta cũng sẽ tìm hiểu về kiến trúc Transformer - một kiến trúc mạng nơ-ron sâu dùng trong xử lý dữ liệu dạng chuỗi với một cơ chế đặc biệt là Self-Attention.

Phạm vi của đề tài chỉ tập trung vào tóm tắt và đánh giá các mô hình trên trong phạm vi ngôn ngữ tiếng Việt, cụ thể ở đây là các bài báo tiếng Việt. Đề tài không nghiên cứu hay tạo ra phương pháp tóm tắt mới mà chỉ vận dụng kết hợp các mô hình có sẵn, đề tài cũng không tạo ra các mô hình mới hay các khái niệm khoa học mới mà chỉ dựa trên các khái niệm khoa học sẵn có để vận dụng và tạo ra một hệ thống đánh giá tương đối cho các mô hình học máy đối với bài toán tóm tắt tiếng Việt.

4. Công nghệ, công cụ và ngôn ngữ lập trình

Hệ thống phía máy chủ được xây dựng bằng ngôn ngữ lập trình Python với FastAPI nhằm cung cấp khả năng suy luận cũng như các dịch vụ xử lý, Python là một trong những ngôn ngữ lập trình cực kỳ mạnh về AI có nhiều thư viện lớn hỗ trợ cho việc xử lý ngôn ngữ tự nhiên. Giao diện sẽ sử dụng kết hợp React và Tailwind CSS, đây là bộ đôi khá mạnh về giao diện và hiệu ứng cho website.

Hệ thống website cũng sử dụng thư viện Hugging Face Transformers để triển khai các mô hình học máy. Công cụ hỗ trợ phát triển phần mềm gồm VS Code, Git, Github.

5. Các kết quả chính dự kiến sẽ đạt được và ứng dụng

Kết quả dự kiến của đề tài là xây dựng nên một hệ thống tóm tắt với các độ đo hoàn chỉnh, hỗ trợ được nhiều loại hình tóm tắt khác nhau và hiển thị kết quả tóm tắt một cách trực quan lên trên giao diện để người dùng có thể dễ dàng quan sát và so sánh các kết quả chạy của các loại mô hình hay các mô hình tóm tắt khác nhau.

Xây dựng quy trình đánh giá chất lượng tóm tắt văn bản tiếng Việt có độ tin cậy, cung cấp kết quả thực nghiệm phục vụ quá trình nghiên cứu, báo cáo một cách chính xác. Về mặt ứng dụng, hệ thống có thể hỗ trợ cho giảng viên, sinh viên, nhà nghiên cứu hoặc người dùng phổ thông tải lên các tài liệu và nhận về bản tóm tắt nội dung chính. Hỗ trợ việc học tập cũng như nghiên cứu. Kết quả nghiên cứu cũng có thể được làm nền tảng để phát triển các hệ thống quản lý tài liệu thông minh, chatbot AI hỗ trợ học tập hoặc các ứng dụng khai thác tri thức từ văn bản,...

6. Giáo viên và cán bộ hướng dẫn

Họ tên: ThS. Trần Phong Nhã

Đơn vị công tác: Phân hiệu Trường Đại học Giao thông Vận tải

Điện thoại: 0906 761 014

Email: tpnha@utc2.edu.vn

Ngày tháng 03 năm 2026
Trưởng BM Công nghệ Thông tin

Đã giao nhiệm vụ TKTN
Giáo viên hướng dẫn

ThS. Trần Phong Nhã

ThS. Trần Phong Nhã

Đã nhận nhiệm vụ TKTN

Sinh viên: Nguyễn Hữu Toàn

Điện thoại: 0343768815

Ký tên:

Email: 6351071071@st.utc2.edu.vn

LỜI CẢM ƠN

Lời đầu tiên, em xin gửi lời cảm ơn sâu sắc đến quý thầy cô bộ môn Công nghệ thông tin của Phân hiệu trường đại học Giao thông vận tải tại thành phố Hồ Chí Minh đã tận tình dạy bảo, truyền đạt kiến thức cũng như kinh nghiệm học tập cho em trong suốt 4 năm thời gian em học tập tại trường, tạo điều kiện thuận lợi để em có nền tảng kiến thức vững chắc phục vụ cho việc nghiên cứu và hoàn thiện đề tài.

Đặc biệt, em xin bày tỏ lòng biết ơn sâu sắc đến thầy ThS. Trần Phong Nhã là người đã trực tiếp hướng dẫn cho em trong suốt quá trình làm đồ án. Thầy đã định hướng em nghiên cứu, tận tình góp ý, giúp đỡ em thực hiện đồ án tốt nghiệp với đề tài “Nghiên cứu và đánh giá phương pháp lai giữa trích rút và diễn giải cho bài toán tóm tắt văn bản tiếng Việt”. Những kiến thức chuyên môn và kinh nghiệm của thầy đã giúp em từng bước một hoàn thiện đề tài này.

Em cũng xin chân thành cảm ơn gia đình đã luôn là chỗ dựa vững chắc cho em, không ngừng động viên, cổ vũ, vực dậy tinh thần và tạo mọi điều kiện thuận lợi để em được học tập, nghiên cứu và hoàn thành đồ án tốt nghiệp này. Em cũng xin cảm ơn các anh chị, bạn bè trong ngành công nghệ thông tin đã luôn giúp đỡ, chia sẻ những kinh nghiệm quý báu trong quá trình làm đồ án.

Trong quá trình xây dựng đồ án, mặc dù em đã cố gắng hết sức nhưng do kinh nghiệm và kiến thức còn hạn chế nên không thể tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến góp ý từ quý thầy cô để em có thể nâng cao kiến thức cũng như năng lực cho những nghiên cứu trong thời gian tới.

Cuối cùng, em xin kính chúc quý thầy cô bộ môn Công nghệ thông tin, đặc biệt là thầy ThS. Trần Phong Nhã luôn dồi dào sức khỏe, hạnh phúc và gặt hái được nhiều thành công trong dự nghiệp giảng dạy cũng như trong cuộc sống.

Em xin chân thành cảm ơn!

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Tp. Hồ Chí Minh, ngày tháng 07 năm 2026
Giáo viên hướng dẫn

ThS. Trần Phong Nhã

MỤC LỤC

LỜI CẢM ƠN	i
NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN	ii
MỤC LỤC	iii
BẢNG BIỂU, SƠ ĐỒ, HÌNH VẼ	viii
TỔNG QUAN ĐỀ TÀI	ix
1. Giới thiệu đề tài	ix
2. Mục tiêu đề tài	x
3. Mục đích nghiên cứu	x
4. Đối tượng nghiên cứu	xi
5. Phạm vi nghiên cứu	xii
6. Phương pháp nghiên cứu	xiii
7. Cấu trúc cuốn báo cáo đề án	xiii
CHƯƠNG 1. CƠ SỞ LÝ THUYẾT	1
1.1. Bài toán tóm tắt văn bản	1
1.2. Tóm tắt trích rút	2
1.3. Tóm tắt diễn giải	3
1.4. Tóm tắt lại	4
1.5. Đặc điểm của tiếng Việt trong xử lý ngôn ngữ tự nhiên	5
1.6. Kiến trúc Transformer	6
1.7. Các mô hình Transformer sử dụng trong đề tài	7
1.8. Các phương pháp đánh giá chất lượng tóm tắt	9

CHƯƠNG 2. PHÂN TÍCH THIẾT KẾ HỆ THỐNG	10
2.1. Mô tả bài toán nghiên cứu	10
2.2. Phân tích yêu cầu hệ thống	12
2.3. Biểu đồ Use case	12
2.4. Biểu đồ hoạt động	16
2.5. Biểu đồ tuần tự	17
2.6. Biểu đồ BFD	18
2.7. Biểu đồ DFD	18
2.8. Phân tích và thiết kế mô hình nghiên cứu	20
2.8.1. Dữ liệu sử dụng trong nghiên cứu	20
2.8.2. Quy trình tiền xử lý dữ liệu	21
2.8.3. Quy trình huấn luyện mô hình	21
2.8.4. Quy trình suy luận và sinh tóm tắt	21
2.8.5. Đánh giá kết quả	22
2.9. Thiết kế kiến trúc hệ thống	23
2.9.1. Kiến trúc tổng thể hệ thống	23
2.9.2. Kiến trúc Frontend - Backend	23
2.9.3. Kiến trúc AI Engine	23
CHƯƠNG 3. GIAO DIỆN CHƯƠNG TRÌNH	24
3.1. Giao diện trang chủ	24
3.2. Giao diện tóm tắt văn bản	25
3.3. Giao diện so sánh bản tóm tắt của các mô hình	26

3.4. Giao diện đánh giá kết quả	28
CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ	29
4.1. Môi trường và công nghệ cài đặt	29
4.1.1. Cấu hình phần cứng hệ thống	29
4.1.2. Môi trường công nghệ phần mềm và thư viện hỗ trợ	29
4.2. Cơ chế hoạt động của Pipeline Tóm tắt Lai	29
4.3. Cài đặt mô hình và thiết kế thực nghiệm	30
4.3.1. Phân tích thống kê tập dữ liệu VietNews	30
4.3.2. Thiết kế kịch bản thực nghiệm và các độ đo đánh giá	31
4.4. Đánh giá hệ thống và phân tích kết quả đạt được	32
4.4.1. Số liệu benchmark tóm tắt văn bản	32
4.4.2. Nhận xét và phân tích chuyên sâu hiệu năng tóm tắt	33
KẾT QUẢ VÀ KIẾN NGHỊ	36
1. Kết quả đạt được	36
1.1. Về mặt lý thuyết	36
1.2. Về mặt thực nghiệm	36
2. Hạn chế	37
3. Hướng phát triển	37
TÀI LIỆU THAM KHẢO	39

DANH MỤC CHỮ VIẾT TẮT

STT	Mô tả	Ý nghĩa	Ghi chú
1	AI	Artificial Intelligence	Trí tuệ nhân tạo
2	API	Application Programming Interface	Giao diện lập trình ứng dụng
3	BPE	Byte-Pair Encoding	Thuật toán mã hóa từ vựng
4	CPU	Central Processing Unit	Bộ vi xử lý trung tâm
5	DB	Database	Cơ sở dữ liệu lưu trữ thông tin
6	DFD	Data Flow Diagram	Biểu đồ luồng dữ liệu
7	GPU	Graphics Processing Unit	Bộ xử lý đồ họa
8	HTML	HyperText Markup Language	Ngôn ngữ đánh dấu siêu văn bản
9	JSON	JavaScript Object Notation	Định dạng văn bản để lưu trữ và trao đổi dữ liệu
10	LLM	Large Language Model	Mô hình ngôn ngữ lớn
11	LSA	Latent Semantic Analysis	Phân tích ngữ nghĩa tiềm ẩn
12	LSTM	Long Short-Term Memory	Mạng mạng nơ-ron bộ nhớ ngắn hạn dài
13	mT5	Massively Multilingual T5	Mô hình Transformer hỗ trợ xử lý đa ngôn ngữ
14	NFC	Normalization Form C	Dạng chuẩn hóa ký tự Unicode
15	NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
16	RAG	Retrieval-Augmented Generation	Kiến trúc sinh văn bản tăng cường truy xuất
17	RAM	Random Access Memory	Bộ nhớ trong của hệ thống máy tính
18	RNN	Recurrent Neural Network	Mạng nơ-ron hồi quy

19	ROUGE	Recall-Oriented Understudy for Gisting Evaluation	Độ đo đánh giá chất lượng tự động cho hệ thống tóm tắt văn bản
20	SBERT	Sentence-BERT	Mô hình nhúng vector ở cấp độ câu
21	SOTA	State-of-the-Art	Chỉ các mô hình, phương pháp đạt kết quả tiên tiến và tốt nhất hiện tại
22	SVD	Singular Value Decomposition	Phép phân tích phân rã trị riêng
23	TF-IDF	Term Frequency-Inverse Document Frequency	Thuật toán thống kê tần suất xuất hiện của từ ngữ trong tài liệu
24	TPU	Tensor Processing Unit	Bộ xử lý trí tuệ nhân tạo chuyên dụng
25	ViT5	Vietnamese Text-to-Text Transfer Transformer	Mô hình Transformer được huấn luyện dành riêng cho tác vụ sinh tiếng Việt
26	VRAM	Video Random Access Memory	Bộ nhớ đồ họa của card màn hình

BẢNG BIỂU, SƠ ĐỒ, HÌNH VẼ

Hình 2.1. Sơ đồ hệ thống	12
Hình 2.2. Biểu đồ Use case tổng quát	13
Hình 2.3. Biểu đồ Use case Tóm tắt văn bản	14
Hình 2.4. Biểu đồ Use case Hỏi đáp tài liệu chatRAG	15
Hình 2.5. Biểu đồ hoạt động	16
Hình 2.6. Biểu đồ tuần tự	17
Hình 2.7. Biểu đồ BFD	18
Hình 2.8. Biểu đồ DFD mức ngữ cảnh	19
Hình 2.9. Biểu đồ DFD mức đỉnh	19
Hình 3.1. Giao diện trang chủ	24
Hình 3.2. Giao diện tóm tắt văn bản	26
Hình 3.3. Giao diện chọn các mẫu thử để xem văn bản tóm tắt	27
Hình 3.4. Giao diện đánh giá kết quả	28
Hình 4.1. Sơ đồ pipeline tóm tắt Lai hai giai đoạn	30
Bảng 4.1. Thống kê chi tiết tập dữ liệu VietNews	31
Hình 4.2. Kết quả thực nghiệm tóm tắt văn bản trên 5.000 mẫu VietNews	32

TỔNG QUAN ĐỀ TÀI

1. Giới thiệu đề tài

Trong hững năm gần đây công nghệ số ngày càng phát triển mạnh mẽ nên lượng dữ liệu văn bản được tạo ra được gia tăng đáng kể và được lưu dưới nhiều hình thức khác nhau như báo điện tử, tài liệu học tập, các trang web chia sẻ thông tin. Khối lượng thông tin ngày càng lớn mang lại nhiều cơ hội khai thác tri thức nhưng đồng thời cũng đặt ra nhiều thách thức cho người dùng trong việc tiếp cận, chọn lọc và nắm bắt nhanh những nội dung quan trọng.

Đối với các tài liệu có độ dài vừa và lớn người đọc thường phải dành nhiều thời gian để đọc toàn bộ nội dung trước khi xác định được các ý chính cần quan tâm. Nó sẽ vừa làm giảm hiệu quả tiếp nhận thông tin còn sẽ gây khó khăn trong quá trình học tập, nghiên cứu và làm việc. Từ đó nhu cầu xây dựng các hệ thống có khả năng tự động rút gọn nội dung văn bản nhưng vẫn bảo đảm giữ được các thông tin cốt lõi ngày càng trở nên cần thiết hơn.

Với sự phát triển của lĩnh vực xử lý ngôn ngữ tự nhiên, nhiều phương pháp tóm tắt văn bản đã được nghiên cứu và ứng dụng trong thực tế. Các phương pháp truyền thống như TextRank, LexRank hay LSA có ưu điểm về tính đơn giản và khả năng triển khai nhanh nhưng chất lượng tóm tắt vẫn còn hạn chế, thiếu tính liên kết khi phải xử lý các văn bản có cấu trúc phức tạp. Và sự xuất hiện của kiến trúc Transformer đã mở ra nhiều hướng tiếp cận mới cho bài toán tóm tắt văn bản. Các mô hình như ViT5, mT5 hay BARTPho có khả năng học ngữ nghĩa sâu của văn bản từ đó tạo ra các bản tóm tắt tự nhiên và mạch lạc hơn.

Xuất phát từ thực tế đó đề tài “Nghiên cứu và đánh giá phương pháp lai giữa trích rút và diễn giải cho bài toán tóm tắt văn bản tiếng Việt” được thực hiện nhằm nghiên cứu, xây dựng và đánh giá các phương pháp tóm tắt văn bản trên dữ liệu tiếng Việt. Hệ thống được xây dựng không chỉ hỗ trợ mục đích là tạo bản tóm tắt tự động mà còn cho phép so sánh kết quả giữa nhiều phương pháp khác nhau, góp phần hỗ trợ người dùng khai thác thông tin hiệu quả hơn từ các tài liệu văn bản có độ dài khác nhau.

2. Mục tiêu đề tài

Đề tài hướng đến việc nghiên cứu các phương pháp tóm tắt văn bản tự động và xây dựng một hệ thống hỗ trợ tóm tắt văn bản tiếng Việt dựa trên các kỹ thuật xử lý ngôn ngữ tự nhiên và mô hình Transformer.

Đề tài này sẽ tập trung vào tìm hiểu các kiến thức liên quan đến xử lý ngôn ngữ tự nhiên, tóm tắt văn bản, các mô hình tóm tắt trích rút, tóm tắt diễn giải, phương pháp tóm tắt lai, kiến trúc Transformer cùng các mô hình tiêu biểu như ViT5, mT5 và BARTPho. Đề tài này cũng sẽ nghiên cứu về các phương pháp đánh giá chất lượng tóm tắt từ các độ đo phổ biến như Rouge và BERTScore để phục vụ quá trình thực nghiệm và so sánh kết quả giữa nhiều loại mô hình khác nhau.

Đề tài xây dựng một hệ thống cho phép người dùng nhập văn bản, tải file tài liệu và thực hiện tóm tắt bằng nhiều phương pháp khác nhau. Hệ thống hỗ trợ các thuật toán TextRank, LexRank, LSA, ViT5, mT5, BARTPho đã được huấn luyện và các phương pháp lai giữa trích rút, diễn giải và lai ghép cho bài toán tóm tắt văn bản tiếng Việt. Kết quả tóm tắt được hiển thị trực quan lên giao diện website và cho phép đánh giá, so sánh chất lượng giữa các phương pháp trên cùng một tập dữ liệu có sẵn.

Đề tài hướng đến việc xây dựng một môi trường thử nghiệm thống nhất phục vụ nghiên cứu và đánh giá các phương pháp tóm tắt văn bản tiếng Việt. Từ quá trình triển khai và thực nghiệm, đề tài mong muốn xác định những ưu điểm, nhược điểm và khả năng ứng dụng thực tế của từng phương pháp, từ đó đề xuất hướng lựa chọn phù hợp đối với các bài toán tóm tắt văn bản trong môi trường tiếng Việt.

3. Mục đích nghiên cứu

Mục đích của đề tài là nghiên cứu và ứng dụng các kỹ thuật xử lý ngôn ngữ tự nhiên hiện đại vào bài toán tóm tắt văn bản tiếng Việt và xây dựng một hệ thống có khả năng hỗ trợ người dùng tiếp cận nhanh nội dung quan trọng của các tài liệu. Thông qua việc khảo sát và triển khai nhiều phương pháp khác nhau dự án hướng đến việc đánh giá khả năng áp dụng của các mô hình tóm tắt văn bản trong điều kiện dữ liệu tiếng Việt.

Tuy việc nghiên cứu các phương pháp tóm tắt truyền thống và phương pháp lai và chủ yếu nhưng dự án còn nhằm mục đích xây dựng một môi trường thực nghiệm cho phép so sánh kết quả giữa nhiều thuật toán trên cùng một tập dữ liệu. Điều này giúp làm rõ sự khác biệt về chất lượng tóm tắt, hiệu quả xử lý văn bản tiếng Việt của từng phương pháp.

Dự án còn hướng đến việc tạo ra một công cụ hỗ trợ khai thác thông tin từ văn bản. Hệ thống có thể hỗ trợ một phần nhỏ để sinh viên, giảng viên, nhà nghiên cứu và người dùng phổ thông trong việc tiếp cận nhanh các nội dung quan trọng của tài liệu, góp phần giảm thời gian đọc và nâng cao hiệu quả tiếp nhận thông tin.

Quá trình xây dựng nên hệ thống này, đánh giá các mô hình thuật toán được xây dựng trên nền Transformer cũng góp phần làm rõ những thuận lợi và bất lợi khi áp dụng các mô hình Transformer vào bài toán tóm tắt văn bản tiếng Việt, từ đó tạo cơ sở cho các nghiên cứu và hướng phát triển lớn hơn trong lĩnh vực xử lý ngôn ngữ tự nhiên.

4. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là bài toán tóm tắt văn bản tự động trong lĩnh vực xử lý ngôn ngữ tự nhiên trên tập dữ liệu văn bản bài báo tiếng Việt. Nội dung nghiên cứu hướng đến việc tìm hiểu các phương pháp và mô hình có khả năng rút gọn văn bản tiếng Việt nhưng vẫn giữ được những thông tin quan trọng và ý nghĩa chính của tài liệu gốc.

Phương pháp nghiên cứu: đề tài tập trung khảo sát ba hướng tiếp cận chính là tóm tắt trích rút, tóm tắt diễn giải và phương pháp kết hợp giữa cả hai. Nhóm phương pháp trích rút gồm các thuật toán như TextRank, LexRank và LSA, còn nhóm phương pháp tóm tắt diễn giải là các mô hình ViT5, mT5 và BARTPho dựa trên kiến trúc Transformer. Các mô hình tóm tắt lai sẽ tập trung kết hợp mô hình của hai phương pháp này.

Công nghệ sử dụng: đề tài nghiên cứu các kỹ thuật xử lý ngôn ngữ tự nhiên, kiến trúc Transformer, quy trình huấn luyện và suy luận mô hình học sâu, các phương pháp đánh giá chất lượng tóm tắt và các công nghệ phục vụ quá trình xây dựng hệ thống như FastAPI, React và các thư viện học máy liên quan đến việc tóm tắt.

Đối tượng nghiên cứu cũng bao gồm hệ thống phần mềm được xây dựng trong đề tài. Hệ thống có chức năng nhập văn bản đầu vào, thực hiện tóm tắt bằng nhiều phương pháp khác nhau, lưu trữ kết quả vào database và hỗ trợ đánh giá, so sánh chất lượng tóm tắt. Đây là cơ sở để tiến hành các thực nghiệm và đánh giá hiệu quả của các phương pháp được nghiên cứu trong đề tài.

5. Phạm vi nghiên cứu

Đề tài tập trung nghiên cứu và xây dựng hệ thống tóm tắt văn bản tự động dành cho dữ liệu tiếng Việt dựa trên các kỹ thuật xử lý ngôn ngữ tự nhiên. Phạm vi nghiên cứu của dự án này sẽ tập trung vào việc khảo sát, triển khai và đánh giá các phương pháp tóm tắt văn bản trên tập dữ liệu tiếng Việt, xây dựng một hệ thống hỗ trợ thực hiện và so sánh kết quả tóm tắt giữa nhiều phương pháp khác nhau.

Dữ liệu: đề tài này sẽ sử dụng bộ dữ liệu văn bản bài báo tiếng Việt phục vụ cho bài toán tóm tắt, các văn bản thuộc lĩnh vực tin tức và các nguồn dữ liệu khác miễn là phù hợp cho quá trình huấn luyện, kiểm thử và đánh giá mô hình. Dữ liệu dự án được thu thập trên các nguồn dataset trong các bài báo khoa học, đảm bảo được các mô hình tóm tắt được huấn luyện ổn định trên tập dữ liệu tiếng Việt. Các loại dữ liệu đa phương tiện như hình ảnh, âm thanh hoặc video không thuộc phạm vi nghiên cứu của đề tài.

Mô hình và thuật toán: đề tài nghiên cứu các phương pháp tóm tắt trích rút gồm TextRank, LexRank, LSA; triển khai các mô hình Transformer tiêu biểu như ViT5, mT5, BARTPho cho bài toán tóm tắt diễn giải và các phương pháp lai kết hợp giữa chúng ví dụ như TextRank_ViT5, TextRank_mT5, LSA_BARTPho,... Việc phát triển một kiến trúc Transformer hoàn toàn mới hoặc xây dựng mô hình ngôn ngữ từ đầu không nằm trong phạm vi thực hiện của đề tài này.

Hệ thống: đề tài chỉ tập trung xây dựng một ứng dụng hỗ trợ tóm tắt văn bản, đánh giá chất lượng tóm tắt và trực quan hóa kết quả thực nghiệm. Hệ thống còn tích hợp một mô hình LLM để người dùng có thể hỏi đáp đơn giản dựa vào các nguồn thông tin người dùng tải lên nhằm hiểu được nội dung chính tài liệu hay các vấn đề liên quan có trong tài liệu. Các nội dung liên quan đến triển khai hệ thống ở quy mô lớn, tối ưu hạ tầng phân tán hoặc cung cấp dịch vụ thương mại chưa được xem xét trong phạm vi nghiên cứu hiện tại.

6. Phương pháp nghiên cứu

Để đạt được các mục tiêu đã đề ra, đề tài kết hợp giữa phương pháp nghiên cứu lý thuyết và phương pháp thực nghiệm.

Ban đầu làm đề tài sẽ tiến hành thu thập, phân tích và tổng hợp các tài liệu, bài báo khoa học, công trình nghiên cứu liên quan đến lĩnh vực xử lý ngôn ngữ tự nhiên, bài toán tóm tắt văn bản, kiến trúc Transformer và các phương pháp đánh giá chất lượng tóm tắt.

Sau đó đề tài áp dụng phương pháp nghiên cứu thực nghiệm thông qua việc triển khai các thuật toán và mô hình tóm tắt văn bản trên dữ liệu tiếng Việt. Các phương pháp TextRank, LexRank, LSA, ViT5, mT5 và BARTPho được xây dựng, huấn luyện và tinh chỉnh phù hợp với yêu cầu của bài toán nhằm đánh giá khả năng xử lý và chất lượng tóm tắt của từng phương pháp.

Cùng lúc đó đề tài cũng sẽ sử dụng phương pháp so sánh và đánh giá để phân tích hiệu quả của các mô hình. Các chỉ số như Rouge và BERTScore được sử dụng để đo lường mức độ tương đồng giữa bản tóm tắt được sinh ra và bản tóm tắt tham chiếu. Kết quả thực nghiệm được tổng hợp, trực quan hóa và phân tích nhằm đưa ra nhận xét khách quan về ưu điểm, hạn chế cũng như khả năng ứng dụng của từng phương pháp.

Tổng kết lại đề tài sẽ áp dụng phương pháp thiết kế và phát triển phần mềm để xây dựng hệ thống tóm tắt văn bản hoàn chỉnh. Hệ thống được triển khai theo kiến trúc phù hợp, tích hợp các mô hình xử lý ngôn ngữ tự nhiên, giao diện người dùng và các chức năng hỗ trợ đánh giá kết quả, tạo môi trường thuận lợi cho việc nghiên cứu và thực nghiệm.

7. Cấu trúc cuốn báo cáo đề án

Nội dung cuốn báo cáo này chia thành năm chương chính, trình bày theo thứ tự từ cơ sở hình thành đề tài đến quá trình triển khai, đánh giá, kết luận, kết quả nghiên cứu.

Tổng quan đề tài: Chương này trình bày bối cảnh thực hiện đề tài, mục tiêu nghiên cứu, mục đích nghiên cứu, đối tượng nghiên cứu, phạm vi nghiên cứu, phương pháp nghiên cứu và cấu trúc tổng thể của báo cáo.

Chương 1: Cơ sở lý thuyết. Chương này giới thiệu các kiến thức nền tảng liên quan đến bài toán tóm tắt văn bản, các phương pháp tóm tắt trích rút và tóm tắt diễn giải, tóm tắt lai, các mô hình được sử dụng trong đề tài, các nghiên cứu liên quan cũng như những công nghệ và công cụ phục vụ quá trình xây dựng hệ thống.

Chương 2: Phân tích và thiết kế hệ thống. Chương này trình bày bài toán nghiên cứu, yêu cầu hệ thống, kiến trúc tổng thể, quy trình xử lý dữ liệu, thiết kế các thành phần chức năng, thiết kế cơ sở dữ liệu và các sơ đồ mô tả hoạt động của hệ thống.

Chương 3: Giao diện chương trình. Trình bày giao diện của hệ thống, giới thiệu các chức năng, bố cục giao diện, luồng hoạt động của chương trình để người dùng có thể nắm rõ nguyên lý cũng như cách vận hành website.

Chương 4: Xây dựng, thực nghiệm và đánh giá hệ thống. Chương này mô tả quá trình triển khai hệ thống, xây dựng các mô hình tóm tắt văn bản, thực hiện huấn luyện và đánh giá trên dữ liệu thực nghiệm. Chương cũng trình bày kết quả thu được, phân tích hiệu quả của từng phương pháp và so sánh chất lượng tóm tắt thông qua các chỉ số đánh giá.

Kết luận và kiến nghị: Phần này tổng kết những kết quả đạt được trong quá trình thực hiện đề tài, nêu ra các hạn chế còn tồn tại và đề xuất những hướng nghiên cứu, phát triển có thể thực hiện trong tương lai nhằm nâng cao hiệu quả của hệ thống.

Chương này đã trình bày tổng quan về đề tài nghiên cứu, bao gồm bối cảnh thực tiễn, lý do lựa chọn đề tài cũng như những vấn đề đặt ra đối với bài toán tóm tắt văn bản tự động tiếng Việt. Chương cũng xác định rõ mục tiêu, mục đích nghiên cứu, đối tượng nghiên cứu, phạm vi thực hiện và các phương pháp được sử dụng trong quá trình triển khai đề tài. Đồng thời cũng nêu ra ý nghĩa thực tiễn của hệ thống và cấu trúc tổng thể của báo cáo cũng đã được giới thiệu nhằm giúp người đọc có cái nhìn khái quát về nội dung nghiên cứu.

CHƯƠNG 1. CƠ SỞ LÝ THUYẾT

1.1. Bài toán tóm tắt văn bản

Bài toán tóm tắt văn bản tự động là một trong những vấn đề cốt lõi của lĩnh vực xử lý ngôn ngữ tự nhiên, đây là quá trình tự động rút gọn một hay nhiều văn bản gốc để tạo nên một phiên bản ngắn gọn hơn, súc tích hơn mà vẫn đảm bảo giữ lại được đầy đủ thông tin, nội dung chính và chủ đề quan trọng nhất của văn bản ban đầu [1, 2]. Hiện nay trong thời đại mà kỹ thuật số lên ngôi, dữ liệu thông tin trên internet cũng ngày càng bùng nổ và xuất hiện tràn lan nên bài toán tóm tắt văn bản tự động lại càng đóng vai trò cực kỳ quan trọng trong việc khai thác thông tin. Điều này cũng giúp cho con người tiết kiệm được khá khá thời gian đọc hiểu, bỏ đi nhiều thông tin không quan trọng và nhanh chóng nắm bắt được nội dung chính của vấn đề [3, 4]. Nó cũng giúp cho quá trình phân tích, tra cứu tài liệu và đưa ra quyết định được tối ưu hóa hơn rất nhiều.

Thực tế thì bài toán tóm tắt văn bản tự động đang được ứng dụng rộng rãi trong rất nhiều lĩnh vực và hệ thống khác nhau, ví dụ như trong lĩnh vực báo chí, các mô hình tóm tắt giúp tổng hợp tự động các bản tin hàng ngày hay gom cụm các sự kiện tin tức thời sự nổi bật [2]. Nó được sử dụng để tóm lược các tài liệu khoa học dài trong quá trình học tập hay nghiên cứu, giúp các nhà nghiên cứu nhanh chóng nắm bắt được thông tin chính, đánh giá được sự phù hợp của một bài báo [3]. Tóm tắt văn bản còn được ứng dụng mạnh mẽ trong việc trích xuất thông tin từ hồ sơ pháp lý, tóm tắt chuỗi email, tổng hợp ý kiến đánh giá của khách hàng trên mạng xã hội hay tóm gọn nội dung các cuộc họp [2].

Hiện nay, định hướng nghiên cứu các học giả trên thế giới đang dần chuyển dịch từ việc chỉ tập trung vào các phương pháp thống kê và trích xuất đơn thuần sang việc ứng dụng các mô hình học sâu để thực hiện tóm tắt diễn giải [1, 2]. Xu hướng hiện tại là đẩy mạnh hướng tiếp cận lai theo như nhiều nghiên cứu hiện nay, tập hợp sức mạnh của cả hai phương pháp là trích rút và diễn giải để giải quyết vấn đề các tài liệu siêu dài, khắc phục giới hạn về tài nguyên phần cứng và giới hạn độ dài của các mô hình ngôn ngữ lớn [3]. Bài toán tóm tắt văn bản được đề ra trong đề tài này không chỉ mang ý nghĩa lý thuyết về mặt tiếp cận đa mô hình trong NLP, mà nó còn mang giá trị thực tiễn sâu sắc trong việc

xây dựng một hệ thống xử lý tài liệu thông minh, giúp tự động hóa quy trình tóm tắt văn bản và khai thác tri thức cho văn bản dùng ngôn ngữ tiếng Việt.

1.2. Tóm tắt trích rút

Tóm tắt trích rút là quá trình xác định, đánh giá và lấy nguyên văn các câu hay các đoạn văn bản quan trọng nhất trong tài liệu để ghép nối lại thành một bản tóm tắt hoàn chỉnh. Đây là một phương pháp truyền thống nhưng lại cực kỳ hiệu quả trong bài toán tóm tắt văn bản [1]. Nguyên lý hoạt động của phương pháp này là quy bài toán về dạng phân loại nhị phân hay xếp hạng. Hệ thống này sẽ chia nhỏ văn bản thành các đơn vị cơ bản, ở đây thường là câu, sau đó nó sẽ tiến hành phân tích các đặc trưng thống kê, cú pháp, ngữ nghĩa của từng câu để tính toán ra điểm số về mức độ quan trọng của câu [3, 5].

Quy trình thường trải qua ba bước cốt lõi để lựa chọn ra các câu quan trọng: biểu diễn trung gian cho văn bản, tính toán điểm số câu, và cuối cùng là bước trích xuất. Các phương pháp phổ biến bao gồm việc sử dụng các độ đo thống kê như tần suất từ TF-IDF, vị trí của câu trong đoạn, hoặc độ dài của câu sẽ được dùng trong bước tính điểm[2]. Nâng cao hơn, các phương pháp dựa trên đồ thị như TextRank hay LexRank mô hình hóa văn bản thành một mạng lưới, trong đó mỗi câu là một đỉnh và độ tương đồng ngữ nghĩa giữa các câu là các cạnh nối. Thuật toán sẽ đánh giá tầm quan trọng của một câu dựa trên số lượng và trọng số của các kết nối trở đến nó, tương tự như nguyên lý xếp hạng website của thuật toán PageRank [2]. Văn bản tóm tắt cuối cùng sẽ là sự kết hợp của các câu có điểm số cao nhất và các câu đó cũng phải vượt qua một ngưỡng nhất định về điểm số.

Ưu điểm nổi bật nhất của phương pháp trích rút là đảm bảo được độ chính xác tuyệt đối về mặt thông tin sự kiện và sự chuẩn xác về mặt ngữ pháp, nguyên nhân là các câu được sao chép nguyên vẹn từ văn bản gốc của tác giả [1]. Phương pháp này đòi hỏi khá ít tài nguyên tính toán và thường không cần đến các bộ dữ liệu huấn luyện khổng lồ nếu sử dụng thuật toán không giám sát.

Tuy nhiên phương pháp tóm tắt trích rút này cũng mang những hạn chế chí mạng: do chỉ cắt ghép các câu rời rạc nên bản tóm tắt thường thiếu tính liên kết, luồng từ vựng không tự nhiên và đặc biệt là không có khả năng cô đọng, diễn giải hay khái quát hóa thông tin như cách bộ não con người thực hiện [2]. Hơn thế nữa phương pháp này dễ dẫn

đến hiện tượng lặp ý nếu tài liệu gốc chứa nhiều câu có nội dung tương đồng. Tuy khuyết điểm là vậy nhưng đối với tiếng Việt thì phương pháp trích rút vẫn có khả năng áp dụng rất tốt và đóng vai trò bản lề. Tóm tắt trích rút như một bộ lọc tiền xử lý, giúp nén các tài liệu dài thành những câu quan trọng nhất trước khi đưa qua mô hình sinh, giúp giải quyết được vấn đề giới hạn bộ nhớ của các mô hình Transformer trong đề tài [3, 5].

1.3. Tóm tắt diễn giải

Tóm tắt diễn giải thì trái ngược với tóm tắt trích rút, nó là quá trình xây dựng một biểu diễn ngữ nghĩa nội tại của văn bản gốc, từ đó tạo ra một văn bản tóm tắt hoàn toàn mới bằng các từ vựng, cấu trúc câu có thể chưa từng xuất hiện trong tài liệu ban đầu và nó được xem như là một phương pháp phức tạp và tiên tiến hơn [1]. Nguyên lý tạo ra văn bản tóm tắt của phương pháp này là dựa trên kiến trúc mã hóa - giải mã là Encoder - Decoder. Bộ mã hóa sẽ đọc và nén toàn bộ văn bản đầu vào thành một chuỗi các vector ngữ cảnh mang thông tin ngữ nghĩa mật độ cao. Sau đó, bộ giải mã sẽ sử dụng các vector này để dự đoán và sinh ra từng từ một cách tuần tự để hình thành bản tóm tắt mang ý nghĩa tương đồng với văn bản gốc ban đầu [1, 6] .

Sự khác biệt cốt lõi giữa phương pháp trích rút và diễn giải này là nằm ở khả năng hiểu và tái tạo ngôn ngữ tự nhiên. Phương pháp trích rút chỉ là cắt và dán lại các câu để tạo thành đoạn tóm tắt thì phương pháp diễn giải giống như cách con người đọc hiểu, tiếp nhận, phân tích và tiêu hóa thông tin, sau đó dùng lời văn của mình để diễn đạt lại một cách khái quát nội dung của văn bản gốc [1, 3]. Để làm được điều này, vai trò của các mô hình học sâu và đặc biệt là mạng nơ-ron hồi quy RNN, LSTM hay gần đây là kiến trúc Transformer đóng vai trò cực kỳ quan trọng và mang tính quyết định [1, 2]. Các mô hình này được tiền huấn luyện trên khối lượng dữ liệu khổng lồ, mang lại khả năng diễn đạt ngữ nghĩa cực kỳ phong phú, cho phép hệ thống viết lại, tổng quát hóa và thậm chí có thể lồng ghép các tri thức thực tế từ bên ngoài vào bản tóm tắt [1, 5].

Ưu điểm lớn nhất của tóm tắt diễn giải là tạo ra các văn bản tự nhiên, mạch lạc, súc tích và liền mạch, có cấu trúc rất gần với ngôn ngữ của con người [2, 6]. Bên cạnh kết quả lý tưởng đó, phương pháp tóm tắt lại cũng mang lại nhiều hạn chế nhất định. Hạn chế lớn nhất là xu hướng sinh ra thông tin sai lệch hoặc không có thật so với bản gốc - hiện tượng

hallucination, do mô hình đôi khi dự đoán từ vựng dựa trên xác suất thống kê thay vì bám sát ngữ cảnh thực tế [1]. Song song các mô hình sinh thường dễ bị lặp từ hoặc lặp đoạn văn khi giải mã các chuỗi dài, đồng thời gặp khó khăn với các từ vựng nằm ngoài từ điển Out-Of-Vocabulary [1, 6]. Khi áp dụng cho tiếng Việt, thách thức càng gia tăng do sự thiếu hụt các bộ dữ liệu cặp văn bản - tóm tắt chất lượng cao để tinh chỉnh mô hình. Thêm vào đó đặc thù của tiếng Việt đòi hỏi quá trình mã hóa từ vựng tinh vi hơn và khó khăn hơn rất nhiều, khiến việc huấn luyện mô hình tóm tắt sinh tiếng Việt trở nên cực kỳ tốn kém về mặt tài nguyên và thời gian [7]. Dù có nhiều khó khăn là vậy nhưng tóm tắt diễn giải mang ý nghĩa đặc biệt quan trọng đối với đề tài này, vì nó quyết định tính chuyên nghiệp, sự tự nhiên và chất lượng đầu ra cuối cùng của hệ thống tóm tắt thông tin văn bản.

1.4. Tóm tắt lai

Tóm tắt lai hay tên tiếng Anh thường gọi là Hybrid Summarization là một phương pháp tiếp cận tiên tiến trong lĩnh vực xử lý ngôn ngữ tự nhiên, nó được thiết kế để kết hợp và phát huy tối đa ưu điểm của cả hai kỹ thuật tóm tắt trích rút và tóm tắt diễn giải [4]. Thực tế trong quá trình tóm tắt tài liệu con người cũng phương pháp tóm tắt lai: đầu tiên chúng ta đọc và trích rút các phần thông tin quan trọng nhất, sau đó mới đưa ra quyết định loại bỏ các chi tiết thừa và cuối cùng là diễn đạt lại nội dung, biến đổi chúng thành một bản tóm tắt ngắn gọn, dễ hiểu [8].

Sự ra đời của các phương pháp tóm tắt lai chủ yếu để giải quyết các hạn chế của từng phương pháp đơn lẻ. Đối với phương pháp trích rút, dù đảm bảo được tính nguyên bản của thông tin nhưng các bản tóm tắt thường gặp phải vấn đề về như sự thiếu liên kết, thiếu tính mạch lạc và khó nắm bắt được toàn bộ tinh túy của tài liệu gốc do tính chất ghép nối các câu một cách thô, cứng nhắc [2]. Dù tạo ra văn bản tự nhiên nhưng phương pháp tóm tắt diễn giải lại dễ mắc lỗi lặp từ hay nghiêm trọng hơn là bịa thông tin, tạo ra các đoạn thông tin sai lệch không mang cùng ý nghĩa với nội dung của tài liệu nguồn. Các mô hình ngôn ngữ lớn dựa trên kiến trúc Transformer hiện nay thường gặp trở ngại về giới hạn độ dài token đầu vào, khiến chúng không thể trực tiếp xử lý các tài liệu dài một cách hiệu quả nếu chỉ dùng phương pháp diễn giải, vì thế nên sự ra đời của phương pháp tóm tắt lai là cần thiết [3].

Để khắc phục những rào cản này, kiến trúc của một hệ thống tóm tắt lại thường được chia thành hai giai đoạn phân biệt. Bước đầu tiên, hệ thống sẽ đóng vai trò là một bộ lọc, dùng các thuật toán hay mô hình trích rút để đánh giá, chọn lọc ra các câu mang thông tin chính từ văn bản gốc [3]. Bước thứ hai, tập hợp các câu đã được chọn lọc này sẽ được sử dụng làm ngữ cảnh đầu vào cho các mô hình diễn giải tự hồi quy để tiến hành viết lại và sinh ra bản tóm tắt cuối cùng [3].

Cách tiếp cận chia để trị này mang lại nhiều lợi ích to lớn, cách chỉ cung cấp cho mô hình diễn giải những câu văn quan trọng nhất, hệ thống giúp giảm bớt lượng thông tin nhiễu, từ đó đảm bảo mô hình giữ lại được các thông tin thực sự cần thiết cho bản tóm tắt. Và nó cũng sẽ giúp giảm thiểu đáng kể chi phí và yêu cầu về tài nguyên tính toán so với việc phải mã hóa toàn bộ tài liệu dài cùng một lúc [5]. Nhờ sự kết hợp này, mô hình tóm tắt lại có thể đồng thời đáp ứng được ba mục tiêu quan trọng của bài toán tóm tắt văn bản là: độ bao phủ thông tin quan trọng, tính liên quan và sự trôi chảy trong ngôn từ.

1.5. Đặc điểm của tiếng Việt trong xử lý ngôn ngữ tự nhiên

Xử lý ngôn ngữ tự nhiên cho tiếng Việt đối mặt với những khó khăn đặc thù xuất phát từ hệ thống cấu trúc ngôn ngữ. Đặc trưng ngôn ngữ nổi bật nhất của tiếng Việt là tính phân tiết rời rạc, trong đó khoảng trắng không chỉ được sử dụng để phân tách các từ như trong tiếng Anh, mà còn được dùng để phân tách các tiếng cấu tạo nên một từ [9]. Hiện tượng đa âm tiết vô cùng phổ biến trong hệ thống từ vựng tiếng Việt, với thống kê chỉ ra rằng có tới 85% các loại từ tiếng Việt được cấu tạo từ hai âm tiết trở lên [9]. Chẳng hạn, một chuỗi ký tự viết dưới dạng 6 âm tiết “Tôi là một nghiên cứu viên” thực chất chỉ tạo thành 4 từ hoàn chỉnh “Tôi / là / một / nghiên_cứu_viên” [9].

Chính đặc điểm này dẫn đến vấn đề tách từ trở thành một bước tiền xử lý mang tính sống còn đối với mọi bài toán NLP tiếng Việt, bao gồm cả tóm tắt văn bản. Nếu không có bước tách từ, các mô hình ngôn ngữ khi áp dụng thuật toán mã hóa BPE sẽ cắt trực tiếp vào cấp độ âm tiết [9]. Điều này dẫn đến vấn đề nhập nhằng ngữ nghĩa vô cùng nghiêm trọng. Khi một từ ghép bị bẻ gãy thành các âm tiết độc lập, mô hình học máy sẽ gặp khó khăn trong việc nắm bắt ý nghĩa toàn cục của từ đó, dẫn đến việc hiểu sai ngữ cảnh và giảm độ chính xác của các tác vụ phân tích ngôn ngữ [9].

Trong bài toán tóm tắt văn bản thì những đặc trưng này sẽ gây ảnh hưởng vô cùng lớn đến chất lượng sinh ra từ vựng cũng như khả năng trích xuất. Nếu hệ thống tóm tắt trích rút đánh giá tầm quan trọng của câu dựa trên tần suất từ mà không tách từ chính xác, nó sẽ dẫn đến việc đếm sai các thuật ngữ chuyên ngành đa âm tiết. Khó khăn đối với các mô hình học máy và đặc biệt là kiến trúc Transformer hiện đại nằm ở việc đa số các mô hình đa ngữ lớn thường chỉ xử lý ngôn ngữ ở cấp độ âm tiết để phục vụ chung cho nhiều ngôn ngữ [9]. Việc thiếu đi sự nhận thức về ranh giới từ tiếng Việt khiến các mô hình đa ngữ bị suy giảm hiệu suất và độ chính xác so với các mô hình đơn ngữ được huấn luyện riêng biệt trên dữ liệu đã qua tách từ ở cấp độ từ [9]. Nhận biết được đặc điểm này có ý nghĩa quan trọng cho đề tài trong việc định hướng thiết kế pipeline xử lý chuẩn xác, cũng như giải thích lý do ưu tiên lựa chọn các mô hình Transformer đã được tối ưu hóa đặc thù cho ngôn ngữ tiếng Việt.

1.6. Kiến trúc Transformer

Trong bối cảnh các mô hình mạng nơ-ron hồi quy và bộ nhớ ngắn hạn dài đang bộc lộ những giới hạn nghiêm trọng về hiệu suất do bắt buộc phải tính toán dữ liệu một cách tuần tự, kiến trúc Transformer đã ra đời như một cuộc cách mạng trong lĩnh vực NLP [10]. Giới hạn tuần tự của RNN khiến mô hình rất khó nắm bắt được sự phụ thuộc giữa các từ ở khoảng cách xa trong một câu dài, đồng thời không thể tận dụng sức mạnh xử lý song song của các hệ thống phần cứng hiện đại như GPU hay TPU [10]. Transformer được Google giới thiệu đã loại bỏ hoàn toàn cấu trúc hồi quy, thay vào đó dựa hoàn toàn vào cơ chế Self-Attention để lập mô hình các rêu rĩa toàn cục giữa đầu vào và đầu ra [10].

Về cấu trúc thì mô hình Transformer tuân theo mô hình mã hóa - giải mã. Cả bộ mã hóa và bộ giải mã đều được cấu tạo từ một chuỗi các khối xếp chồng lên nhau [10, 11]. Điểm cốt lõi tạo nên sức mạnh của Transformer là cơ chế tự chú ý Self-Attention. Trong khi giải mã hoặc mã hóa, cơ chế Self-Attention tính toán trọng số tương quan của một từ hiện tại so với tất cả các từ khác trong cùng một chuỗi đầu vào. Quá trình này tạo ra một biểu diễn mới cho từ đó bằng cách lấy trung bình có trọng số từ toàn bộ ngữ cảnh, giúp mô hình trực tiếp nhìn thấy sự gắn kết của các từ dù chúng cách xa nhau bao nhiêu đi nữa

[10, 11]. Kiến trúc này còn sử dụng Multi-Head Attention, cho phép mô hình thực hiện cơ chế chú ý song song trên nhiều không gian biểu diễn khác nhau, giúp thu thập được nhiều khía cạnh ngữ nghĩa đa dạng từ cùng một chuỗi văn bản [10, 11]. Hơn nữa, vì Transformer không xử lý từ theo thứ tự như RNN, nó cần một cơ chế Positional Encoding mã hóa vị trí để tiêm thông tin về thứ tự tuyến tính của các từ vào biểu diễn vector trước khi đưa qua mạng lưới nơ-ron [10, 11].

Quy trình xử lý dữ liệu của Transformer diễn ra đồng thời: toàn bộ chuỗi văn bản đầu vào được đưa qua bộ mã hóa trong một thao tác tính toán ma trận duy nhất. Ưu điểm tuyệt đối của Transformer so với RNN và LSTM là tốc độ xử lý nhanh hơn rất nhiều do khả năng tính toán song song, đồng thời tránh được hiện tượng suy giảm gradient khi mô hình hóa các chuỗi văn bản rất dài [10]. Vai trò của Transformer trong bài toán tóm tắt văn bản là nền tảng cốt lõi, nó là trái lõi kiến trúc của tất cả các mô hình ngôn ngữ sinh văn bản mạnh mẽ nhất hiện nay, cung cấp năng lực đọc hiểu ngữ cảnh sâu sắc và khả năng tự động giải mã ra các câu tóm tắt mạch lạc, linh hoạt mà các thể hệ mô hình học sâu trước đó không thể đạt tới [11]. Việc ứng dụng Transformer là điều kiện tiên quyết giúp đề tài tiếp cận với những tiêu chuẩn công nghệ tiên tiến nhất hiện nay.

1.7. Các mô hình Transformer sử dụng trong đề tài

ViT5: ViT5 có nguồn gốc từ kiến trúc mạng T5 của Google, nhưng được đào tạo lại từ đầu như một mô hình dành riêng cho tiếng Việt [6]. Kiến trúc của ViT5 hoàn toàn tuân theo cấu trúc Encoder-Decoder chuẩn, trong đó mọi bài toán NLP đều được coi là một tác vụ dịch văn bản sang văn bản [6]. Đặc điểm nổi bật của ViT5 là nó được tiền huấn luyện trên bộ dữ liệu khổng lồ CC100 đơn ngữ tiếng Việt với quy mô lên tới 138GB văn bản thô, và sử dụng bộ từ vựng đã được tối ưu hóa cẩn thận dành riêng cho sub-word tiếng Việt với kích thước 36K [6]. Khả năng xử lý tiếng Việt của ViT5 vô cùng vượt trội, mô hình đã đạt kết quả SOTA trên các bộ dữ liệu tóm tắt đa miền như Wikilingua và Vietnews [6]. Ưu điểm của mô hình là hiểu rất rõ ngữ pháp tiếng Việt, cho ra các đoạn tóm tắt Abstractive cực kỳ trôi chảy, có khả năng xử lý độ dài ngữ cảnh lớn lên tới 1024 token [6]. Hạn chế của nó là kích thước mô hình lớn và đòi hỏi tài nguyên tính toán cao

để tinh chỉnh. ViT5 được chọn làm một trong những mô hình lõi của đề tài nhờ năng lực sinh văn bản tiếng Việt xuất sắc và linh hoạt trên nhiều miền dữ liệu khác nhau.

mT5: mT5 là phiên bản đa ngôn ngữ của mô hình T5, do Google phát triển [12]. Kiến trúc của mT5 tương tự như ViT5 nhưng sở hữu một bộ từ vựng không lồ lên đến 250.000 wordpieces trong mục đích bao phủ hơn 100 ngôn ngữ khác nhau trên thế giới, bao gồm cả tiếng Việt [12].

Nét đặc sắc của mT5 là khả năng học hỏi chuyển giao ngôn ngữ cross-lingual transfer, có thể áp dụng kiến thức từ các ngôn ngữ tài nguyên phong phú như tiếng Anh sang ngôn ngữ có tài nguyên thấp [12]. Về khả năng xử lý tiếng Việt, mT5 có thể đọc và sinh tóm tắt tiếng Việt. Tuy nhiên, ưu điểm về sự đa năng của nó lại đi kèm với hạn chế lớn về hiệu suất nội tại: không gian tham số bị pha loãng cho 100 ngôn ngữ dẫn đến khả năng nắm bắt ngữ nghĩa sâu sắc đối với riêng tiếng Việt thường yếu hơn so với các mô hình đơn ngữ chuyên biệt [7]. Để chứng minh sự cần thiết của mô hình đơn ngữ, đề tài sử dụng mT5 làm mô hình cơ sở so sánh và chứng minh sự cần thiết của các mô hình đơn ngữ tối ưu hóa cho tiếng Việt.

BARTPho: BARTPho là mô hình Seq2Seq tiền huấn luyện độc quyền cho tiếng Việt [7, 9]. Đây là mô hình ngôn ngữ đơn ngữ cỡ lớn đầu tiên kiểu này. Mô hình có nguồn gốc từ kiến trúc Autoencoder khử nhiễu BART, áp dụng khung kiến trúc large kết hợp giữa một bộ mã hóa hai chiều tương tự BERT và một bộ giải mã tự hồi quy từ trái sang phải như GPT [7]. BARTPho sở hữu hai phiên bản riêng biệt: cấp độ âm tiết BARTpho-syllable và cấp độ từ BARTpho-word, được đào tạo trên 20GB dữ liệu tiếng Việt chất lượng cao [7].

Phiên bản BARTPho-word xử lý tiếng Việt vô cùng tốt nhờ nhận thức được cấu trúc từ ghép của tiếng Việt sau quá trình tách từ tự động [7]. BARTPho phù hợp tuyệt vời cho các tác vụ diễn giải tự nhiên, đạt kết quả SOTA vượt trội mô hình đa ngữ mBART [7]. Hạn chế của mô hình là nằm ở kích thước cửa sổ ngữ cảnh cố định, gây cản trở cho các văn bản quá dài. BARTPho được tuyển chọn vì đó là kiến trúc sinh văn bản Seq2Seq tiên tiến, cung cấp hiệu năng vượt trội và giải quyết triệt để vấn đề ranh giới từ trong tiếng Việt.

1.8. Các phương pháp đánh giá chất lượng tóm tắt

Mục đích của việc đánh giá là cung cấp các thước đo định lượng và định tính nhằm xác định mức độ chính xác, tính đầy đủ của thông tin, độ trôi chảy và khả năng khái quát hóa của bản tóm tắt do hệ thống máy tính sinh ra so với bản tóm tắt mẫu do con người viết [13, 14].

Để giải quyết điều này, chỉ số Rouge thường được sử dụng như một tiêu chuẩn đánh giá truyền thống và phổ biến nhất [14]. Rouge đo lường tỷ lệ các đơn vị văn bản chồng chéo giữa bản tóm tắt sinh ra và bản mẫu. Các biến thể chính của Rouge bao gồm: Rouge-1 đo lường độ bao phủ dựa trên tần suất trùng khớp của các từ đơn - unigrams, Rouge-2 đo lường sự trùng khớp của các cụm 2 từ liên tiếp - bigrams nhằm kiểm tra thứ tự từ, và Rouge-L đo lường dựa trên chuỗi con chung dài nhất - Longest Common Subsequence - phản ánh cấu trúc câu và sự liên mạch của luồng thông tin [14].

Rouge dễ triển khai và đánh giá tốt mức độ đầy đủ của nội dung dựa trên sự bảo toàn từ vựng gốc [5]. Bất lợi lớn là nó phạt rất nặng các mô hình tóm tắt diễn giải khi mô hình thực hiện viết lại câu bằng các từ đồng nghĩa dù ngữ nghĩa không hề thay đổi, do Rouge chỉ xét khớp từ vựng chính xác [13, 5].

BERTScore ra đời để giải quyết vấn đề này. BERTScore đánh giá độ tương đồng giữa hai chuỗi văn bản bằng cách tính toán khoảng cách Cosine giữa các vector nhúng embeddings ngữ cảnh của các token, được sinh ra từ các mô hình ngôn ngữ lớn như BERT hoặc DistilBERT [5]. Ý nghĩa của BERTScore là nó tập trung vào cấp độ ngữ nghĩa thay vì cú pháp bề mặt. Bằng cách này, BERTScore chấm điểm công bằng hơn cho các bản tóm tắt Abstractive chứa các từ ngữ đồng nghĩa hoặc được diễn giải theo cấu trúc ngữ pháp khác biệt [5].

Việc áp dụng cả hai độ đo là Rouge và BERTScore đó cung cấp một khung đánh giá toàn diện, sâu sắc và đa chiều: Rouge xác nhận sự đảm bảo thông tin nguyên bản quan trọng đối với phần trích rút, trong khi BERTScore chứng minh sự tinh vi của các mô hình sinh như ViT5 và BARTPho thông qua chất lượng ngữ nghĩa tự nhiên của bản tóm tắt đầu ra [5, 2].

CHƯƠNG 2. PHÂN TÍCH THIẾT KẾ HỆ THỐNG

2.1. Mô tả bài toán nghiên cứu

Hiện nay khối lượng thông tin và tài liệu văn bản tiếng Việt đang gia tăng với tốc độ rất nhanh. Đặc biệt là các văn bản bài báo trực tuyến. Người đọc báo thường xuyên phải đối mặt với vấn đề có quá nhiều thông tin trong một ngày và có những bài báo rất dài khiến cho việc đọc hiểu và tổng hợp thông tin mất rất nhiều thời gian. Việc này làm giảm hiệu quả tổng hợp thông tin, chưa kể đến các bài báo dài thì người đọc sẽ dễ sinh cảm giác chán nản, hoặc đọc lướt qua có thể khiến họ bỏ qua nhiều đoạn thông tin quan trọng. Vậy nên hệ thống tóm tắt văn bản và đánh giá các thuật toán tóm tắt trên bộ dữ liệu bài báo tiếng Việt này ra đời.

Hệ thống sử dụng ba loại phương pháp tóm tắt khác nhau. Mỗi phương pháp đều tồn tại những ưu, nhược điểm nhất định:

- + Các mô hình tóm tắt trích rút cổ điển: TextRank, LexRank, LSA, hoạt động bằng cách chọn trực tiếp những câu quan trọng nhất trong tài liệu gốc để tạo thành bản tóm tắt. Phương pháp này có ưu điểm là tốc độ xử lý rất nhanh và độ trung thực thông tin cao, nhược điểm lớn là văn bản tóm tắt sẽ thô, rời rạc, thiếu tính liên kết và mạch lạc, không thể tự diễn giải lại nội dung văn bản gốc theo văn phong tự nhiên của con người.

- + Các mô hình diễn giải hiện đại: sử dụng các mạng nơ-ron sequence-to-sequence Transformer đọc và hiểu ngữ cảnh của văn bản gốc, sau đó viết lại bản tóm tắt diễn giải. Dù bản tóm tắt sinh ra có tính liên kết và có văn phong giống con người nhưng các mô hình này lại bị giới hạn nghiêm ngặt về độ dài ngữ cảnh đầu vào thường chỉ từ 512 đến 1024 tokens. Khi gặp các tài liệu có độ dài lớn, hệ thống buộc phải cắt bỏ bớt thông tin, điều này có thể dẫn đến mất mát thông tin quan trọng trong quá trình tóm tắt. Hơn nữa quá trình sinh văn bản tóm tắt cũng tiêu tốn rất nhiều tài nguyên phần cứng như GPU VRAM và có tốc độ phản hồi rất lâu, dễ gặp các lỗi như lặp từ, sinh ra các thông tin bịa đặt không có trong văn bản gốc ban đầu.


+ Từ những hạn chế của từng phương pháp trên, đề tài hướng tới mục tiêu cụ thể là xây dựng hệ thống tóm tắt lai và so sánh hiệu năng, cũng như độ chính xác của văn bản tóm tắt trên 15 mô hình thuật toán khác nhau bao gồm 3 trích rút, 3 diễn giải, 9 mô hình tóm tắt lai hybrid trên cùng một tập dữ liệu chuẩn để tìm ra phương pháp tối ưu. Phương pháp lai trích xuất văn bản trên CPU trước và sinh diễn giải bằng GPU nhằm giảm thời gian xử lý đối với các văn bản dài.

Thiết kế chatbot AI hỏi đáp ngữ cảnh nâng cao tích hợp RAG với cơ chế phân mảnh ngữ nghĩa Sematic chunking, tìm kiếm lai Hybrid Search, tái xếp hạng Cross-Encoder Reranking, cây tóm tắt Raptor và tích hợp cả LLM Ollama để hiểu và trả lời các câu hỏi từ tổng quát đến chi tiết.

Xây dựng hệ thống tự động đánh giá đa tiêu chí kết hợp giữa các độ đo Rouge-1, Rouge-2, Rouge-L, Rouge-LSum, BERTScore Precision, BERTScore Recall, BERTScore F1 và Latency (s) để cung cấp cái nhìn tổng quan về độ tương đồng đơn, từ ghép, ngữ nghĩa, thời gian chạy giữa các thuật toán. Hệ thống được thiết kế với các luồng dữ liệu đầu vào đầu ra rõ ràng. Hệ thống tóm tắt và đánh giá các thuật toán nhận văn bản đầu vào từ ô nhập văn bản hoặc người dùng cũng có thể tải lên các file tài liệu để hệ thống nhận diện và lấy văn bản. Đầu ra là văn bản tóm tắt và bảng metrics bao gồm các độ đo để đánh giá từng thuật toán. Đối với hệ thống chatRAG, đầu vào là các file tài liệu và các câu hỏi truy vấn, đầu ra là câu trả lời tương ứng với câu hỏi truy vấn mà người dùng đưa vào.

Bảng metrics các độ đo của 15 mô hình tóm tắt sẽ hiển thị lên giao diện một cách trực quan, người dùng có thể xếp hạng các thuật toán tăng dần hay giảm dần theo từng độ đo khác nhau. Từ bảng kết quả đó người dùng, nhà nghiên cứu có thể nhận biết được rõ ưu, nhược điểm của từng nhóm mô hình hay từng mô hình khác nhau. Về câu trả lời của chatbot AI tích hợp LLM sẽ hiển thị được nguồn của câu trả lời trong tài liệu, người dùng có thể dựa vào nguồn đó để biết chatbot có bịa thông tin hay không. ChatRAG cũng tính toán và đưa ra cho người dùng biết độ tin cậy của câu trả lời đó là bao nhiêu dựa trên các độ đo như độ khớp - đo lường mức độ liên quan của các đoạn văn truy xuất được và độ trung thực - đánh giá xem mô hình có bị ảo giác hay không.

2.2. Phân tích yêu cầu hệ thống



Hình 2.1. Sơ đồ hệ thống

Quy trình hoạt động của hệ thống bắt đầu khi người dùng chọn một trong hai chức năng trên giao diện hệ thống React là tóm tắt tài liệu hoặc hỏi đáp ChatRAG. Dựa vào lựa chọn của người dùng, hệ thống phân loại tác vụ và điều hướng luồng dữ liệu sang một trong hai nhánh trên, nó còn đảm bảo tối ưu hóa đường truyền và thời gian phản hồi.

Ở nhánh tóm tắt tài liệu, hệ thống tiến hành quá trình lọc ra các câu văn quan trọng từ văn bản nguồn bằng cách sử dụng các thuật toán tóm tắt trích rút là TextRank, LexRank, LSA để tóm tắt và dùng các độ đo để đánh giá các câu và thu gọn văn bản cần tóm tắt. Các câu cốt lõi sau khi lọc tiếp tục được đưa qua các mô hình học sâu đã được tinh chỉnh gồm ViT5, mT5, BARTpho để diễn giải và sinh ra bản tóm tắt tự nhiên trôi

chảy sau đó hiển thị kết quả lên giao diện cho người dùng xem kết quả tất cả các bản tóm tắt đối chiếu, đánh giá.

Ở nhánh hỏi đáp ChatRAG, sau khi được người dùng tải lên tài liệu sẽ được chia nhỏ thành các đoạn có cùng ngữ nghĩa để phục vụ cho cơ chế tìm kiếm lai. Cơ chế này sẽ chạy song song để tìm kiếm ngữ nghĩa Dense trên không gian vector của Qdrant hoặc ChromaDB và tìm kiếm từ khóa trên các chỉ mục BM25 của SQLite. Các phân đoạn tìm được sẽ thông qua mô hình bge-reranker để tái xếp hạng, chọn lọc ngữ cảnh tối ưu nhất, sau đó đưa vào mô hình sinh tạo câu trả lời và hiển thị lên trên giao diện người dùng cùng với trích dẫn nguồn.


2.3. Biểu đồ Use case



Hình 2.2. Biểu đồ Use case tổng quát

Biểu đồ use case tổng quát của dự án mô tả các mối quan hệ giữa hai tác nhân chính là người dùng và quản trị viên hệ thống với các chức năng cốt lõi của chương trình. Người dùng đại diện cho người sử dụng cuối hay các nhà nghiên cứu, người mà có thể sử dụng trực tiếp các chức năng chính của chương trình như tóm tắt văn bản sử dụng nhiều loại mô hình tóm tắt khác nhau, hỏi đáp với chatbot tích hợp RAG thông qua các tài liệu mà người dùng tải lên để khai thác nội dung tri thức từ đó. Họ còn có thể so sánh, đối chiếu các thông số, độ đo của bản tóm tắt sau khi mô hình thực thi để rút ra kết luận hay xem biểu đồ hiệu năng trên giao diện.


Người quản trị viên hệ thống chịu trách nhiệm vận hành, kiểm tra, cấu hình hệ thống, quản lý các tài liệu người dùng đưa vào và cấu hình các tham số của mô hình. Cả hai tác nhân người dùng và người quản trị đều có thể xem và theo dõi dữ liệu thực nghiệm, các phân tích thống kê chất lượng mô hình trên toàn hệ thống.



Hình 2.3. Biểu đồ Use case Tóm tắt văn bản

Biểu đồ này mô tả chi tiết các bước thao tác của người dùng hệ thống khi thực hiện tác vụ tóm tắt tài liệu trên hệ thống. Người dùng tương tác trực tiếp với use case chính là tóm tắt tài liệu. Tóm tắt tài liệu cung cấp hai cách nhập dữ liệu: paste trực tiếp hoặc tải file từ máy tính người dùng. File tài liệu có thể là các loại như: pdf, word, text document.

Sau khi đã có dữ liệu văn bản nguồn thì hệ thống tiếp tục thực hiện các bước tóm tắt. Tại bước chọn phương pháp tóm tắt, người dùng có thể chọn một hoặc nhiều mô hình tóm tắt như tóm tắt trích rút, tóm tắt diễn giải hay tóm tắt lai ghép hai giai đoạn. Tóm tắt trích rút đảm bảo tốc độ tóm tắt nhanh nhưng văn bản tóm tắt cho ra bị thiếu liên kết, đọc khá thô. Tóm tắt diễn giải cho ra bản tóm tắt mạch lạc giống với văn phong mà con người viết nhưng thời gian xử lý rất lâu. Còn tóm tắt lai ghép hai giai đoạn đảm bảo được thời gian chạy không quá dài và bản tóm tắt cho ra cũng không quá thô như tóm tắt trích rút. Cuối cùng giao diện hiển thị bảng metrics kết quả độ tương đồng từ, cặp từ, câu, ngữ nghĩa và thời gian chạy các thuật toán để người dùng đối chiếu.




Hình 2.4. Biểu đồ Use case Hỏi đáp tài liệu chatRAG

Biểu đồ use case hỏi đáp tài liệu với ChatRAG thể hiện quy trình tương tác của người dùng với các tác nhân khi tiến hành khai phá tri thức trên các tài liệu dài mà người dùng vừa tải lên hoặc đã tải lên trước đó. Người dùng bắt đầu một phiên làm việc mới bằng cách tải lên tài liệu và chọn các tài liệu để chatbot dựa vào để trả lời.

Sau khi chọn xong tài liệu, người dùng nhập câu hỏi hoặc câu lệnh truy vấn để chatbot trả lời. Hệ thống ChatRAG nhận dữ liệu đầu vào là các file và câu truy vấn mà người dùng vừa nhập để thực hiện phân mảnh ngữ nghĩa, lập chỉ mục đệ quy để phân tách và cấu trúc hóa dữ liệu văn bản, cuối cùng dùng mô hình LLM sinh câu trả lời tự động.

Người dùng có thể xem nguồn trích dẫn của câu trả lời mà chatbot trả về trong tài liệu thông qua các tab nguồn hiển thị trực tiếp trên giao diện. Người dùng cũng có thể quan sát được độ trung thực cũng như độ khớp của câu trả lời phía trên câu trả lời mà chatbot trả về từ đó có thể đánh giá được độ bao phủ cũng như độ chính xác của mô hình.


2.4. Biểu đồ hoạt động



Hình 2.5. Biểu đồ hoạt động

Biểu đồ hoạt động mô tả chi tiết luồng nghiệp vụ xử lý các tác vụ của hệ thống từ điểm khởi đầu cho đến kết thúc. Sau khi người dùng chọn các chức năng trên giao diện website, hệ thống dựa vào lựa chọn của người dùng mà thực hiện chức năng tương ứng. Các chức năng có trong hệ thống là tóm tắt tài liệu, chat trực tiếp với ChatRAG và chạy benchmark để đánh giá hiệu năng các thuật toán tóm tắt.

2.5. Biểu đồ tuần tự




Hình 2.6. Biểu đồ tuần tự

Biểu đồ này mô tả quy trình làm việc của hệ thống thông qua hai tình huống chính. Khi người dùng tải tài liệu lên, dữ liệu được gửi từ giao diện tới máy chủ backend xử lý. Backend gửi tài liệu qua bộ xử lý AI để tiến hành các bước tiếp theo. Bộ xử lý AI tiếp tục chia nhỏ tài liệu và tính toán các vector, những vector này được lưu trong Qdrant còn thông tin tài liệu được ghi lại trong cơ sở dữ liệu SQLite. Sau khi hoàn tất, giao diện nhận được thông báo cho biết việc tải đã thành công.

Khi người dùng nhập một câu hỏi, nó được gửi tới backend để xử lý. Backend gọi bộ xử lý AI để tìm kiếm thông tin cần thiết. Bộ xử lý thực hiện tìm kiếm theo hai hướng, trước tiên tìm các đoạn tương tự trong Qdrant, đồng thời cũng tìm từ khóa trong SQLite và kết hợp hai kết quả này lại. Sau đó, một mô hình xếp lại các kết quả theo độ liên quan và những kết quả tốt nhất được đưa vào để tạo nên câu trả lời. Lịch sử hội thoại được lưu vào cơ sở dữ liệu, cuối cùng câu trả lời được gửi về giao diện cùng với các liên kết tham chiếu.


2.6. Biểu đồ BFD




Hình 2.7. Biểu đồ BFD

Ứng dụng này có 4 tính năng. Tính năng đầu tiên cho phép bạn paste một đoạn văn bản, chọn cách tóm tắt rồi xem kết quả về. Tính năng thứ hai là một chatbot mà bạn có thể upload file PDF hoặc Word lên và hỏi những câu hỏi liên quan tới nội dung file đó. Tính năng thứ ba dùng để so sánh xem và so sánh các mô hình tóm tắt văn bản. Tính năng cuối cùng là quản lý các cài đặt của ứng dụng.

2.7. Biểu đồ DFD



Hình 2.8. Biểu đồ DFD mức ngữ cảnh



Hình 2.9. Biểu đồ DFD mức định

Biểu đồ luồng dữ liệu mức ngữ cảnh của hệ thống mô tả mối quan hệ giữa trung tâm hệ thống tóm tắt AI với hai tác nhân là người dùng/nhà nghiên cứu và bộ máy suy luận AI core engine. Người dùng tải lên các tệp tin tài liệu, văn bản cần tóm tắt, câu hỏi để ChatRAG trả lời và chọn các mô hình tóm tắt có trên giao diện, hệ thống sẽ trả về bản kết quả tóm tắt, điểm đánh giá, câu trả lời từ chatbot tích hợp RAG và các biểu đồ trực quan. Tiến trình trung tâm hệ thống chuyển văn bản đã chuẩn hóa cùng với yêu cầu suy luận cho bộ máy suy luận AI và nhận về văn bản tóm tắt thô, câu trả lời từ mô hình LLM và các vector nhúng ngữ nghĩa và hoàn thiện kết quả trả về cho người dùng.

Biểu đồ luồng dữ liệu mức đỉnh chia tiến trình xử lý trung tâm thành bốn phân hệ chính tương tác trực tiếp với hai tác nhân bên ngoài và ba kho lưu trữ dữ liệu cục bộ bao gồm kho lịch sử SQLite, kho cơ sở dữ liệu vector và kho dữ liệu kiểm thử benchmark. Phân hệ tóm tắt sẽ tiếp nhận văn bản cần tóm tắt từ người dùng để thực hiện thu gọn nội dung, trả về bản tóm tắt đồng thời cũng lưu lịch sử phiên làm việc vào kho SQLite. Phân hệ hỏi đáp ChatRAG có nhiệm vụ tiếp nhận câu hỏi để thực hiện truy vấn và tính toán nhúng vector trên kho dữ liệu vector, sau đó đọc ghi lịch sử trò chuyện trên kho SQLite trước khi trả lời người dùng lên giao diện. Phân hệ đánh giá benchmark thực hiện đọc dữ liệu từ kho dữ liệu kiểm thử rồi tính toán các điểm số chất lượng và độ trễ, lưu kết quả vào kho SQLite rồi trả báo cáo cho người dùng cũng thông qua giao diện.

2.8. Phân tích và thiết kế mô hình nghiên cứu

2.8.1. Dữ liệu sử dụng trong nghiên cứu

Dự án nghiên cứu này sử dụng bộ dữ liệu báo chí tiếng Việt VietNews (nam194/vietnews) <https://github.com/ThanhChinhBK/vietnews> [15]. Nó được tải trực tiếp từ Hugging Face Hub. Đây là bộ dữ liệu tóm tắt văn bản tiếng Việt quy mô lớn gồm hơn 143.000 mẫu bài báo, thu thập từ các trang tin tức lớn như VnExpress, Tuổi Trẻ, Người Đưa Tin. Cấu trúc mỗi mẫu dữ liệu gồm các cột sau:

- + *article*: Văn bản bài viết thô (độ dài trung bình khoảng 400 từ).
- + *abstract*: Bản tóm tắt mẫu chuẩn do biên tập viên viết (độ dài trung bình khoảng 32 từ).
- + *title*: Tiêu đề bài viết.

Nghiên cứu thực hiện chia bộ dữ liệu theo tỷ lệ chuẩn theo tỉ lệ: 99.134 mẫu cho tập huấn luyện, 22.184 mẫu cho tập kiểm chuẩn và 22.498 mẫu cho tập kiểm thử. Để thực hiện benchmark hiệu năng khoa học trong đề tài, hệ thống trích ra một tập mẫu test ngẫu nhiên gồm 5000 bài báo, các bài này được chọn lọc cố định bằng cách thiết lập Random Seed = 42 để đảm bảo tính chân thực kết quả đánh giá, sau đó chạy trực tiếp 5000 mẫu thử với 15 mô hình tóm tắt gồm 3 mô hình trích rút, 3 mô hình diễn giải và 9 mô hình tóm tắt lai hai giai đoạn trực tiếp trên GPU của máy và cho ra kết quả.

2.8.2. Quy trình tiền xử lý dữ liệu

Làm sạch nhiễu: quá trình này bỏ đi các ký tự lỗi và xóa các khoảng trắng thừa.

Chuẩn hóa Unicode: chuyển đổi toàn bộ văn bản về dạng chuẩn Unicode NFC để giải quyết lỗi gõ dấu tiếng Việt.

Tách câu: sử dụng các biểu thức chính quy tối ưu cho tiếng Việt để tách văn bản thành danh sách các câu độc lập dựa trên các dấu chấm câu và ngữ cảnh viết tắt.

Tách từ ghép tiếng Việt: sử dụng công cụ tách từ của thư viện pyvi để liên kết các âm tiết cấu thành từ ghép bằng dấu gạch dưới, ví dụ: “trí tuệ nhân tạo” thành “trí_tuệ nhân_tạo”, giúp mô hình nhúng và mô hình sinh học sâu nhận diện đúng ranh giới ngữ nghĩa của từ ghép tiếng Việt đơn lập.

2.8.3. Quy trình huấn luyện mô hình

Các mô hình học sâu Transformers gồm ViT5, mT5 và BARTPho được huấn luyện trực tiếp trên colab. Máy chủ colab cung cấp GPU-T4 16GB RAM giúp các mô hình tóm tắt diễn giải với hàng trăm triệu tham số này được huấn luyện nhanh và ổn định hơn nhiều so với phần cứng của máy là RTX 3050Ti 4GB VRAM.

Dữ liệu ban đầu được làm sạch và chuyển thành các chuỗi token ids bằng bộ tokenizer riêng của từng mô hình tóm tắt. Hai mô hình là ViT5 và mT5 sẽ được chèn thêm một tiền tố tác vụ dạng summarize để đảm bảo mô hình nhận diện đúng nhiệm vụ tóm tắt.

Kích thước lô hiệu dụng của các siêu tham số được cấu hình cố định ở mức 16. VRAM trên GPU colab được thiết lập batch size vật lý bằng 2 hoặc 4 kết hợp với tích lũy gradient accumulation steps bằng 4 hoặc 8 để giải quyết vấn đề giới hạn VRAM. Tốc độ học của mô hình được đặt ở mức $5e-5$ đi với thuật toán tối ưu adamW và linear warmup schedule.

Khi chạy xong một epoch, mô hình được đánh giá một cách trực tiếp dựa trên tập validation. Dùng cơ chế early stopping để liên tục giám sát điểm validation loss. Tiến trình sẽ tự ngắt nếu điểm loss không giảm liên tiếp 3 epoch để tránh hiện tượng overfitting và sau đó xuất checkpoint tốt nhất ra làm mô hình cuối cùng.

2.8.4. Quy trình suy luận và sinh tóm tắt

Tiến trình suy luận của hệ thống được kiểm soát chặt chẽ thông qua cơ chế khóa semaphore toàn cục nhằm tránh hiện tượng tranh chấp tài nguyên hệ thống gây lỗi tràn bộ nhớ VRAM trên GPU. Khi gửi một yêu cầu suy luận mới đến, hệ thống sẽ kiểm tra trạng thái GPU, yêu cầu mới sẽ được sắp xếp vào hàng đợi nếu GPU còn đang bận xử lý các tác vụ khác, đảm bảo cho số lượng yêu cầu đồng thời tại một thời điểm không vượt quá giới hạn tối đa đã được cấu hình.

Giải thuật beam search được tích hợp sẵn trong mô hình tóm tắt diễn giải để tạo ra chuỗi token ids. Cấu hình giải mã được thiết lập như sau: num_beams bằng 4, hình phạt lặp từ repetition bằng 1.2 nhằm hạn chế tình trạng lặp từ vô nghĩa. Thuật toán greedy search với num_beams bằng 1 sẽ được áp dụng trong một vài trường hợp khi cần ưu tiên tốc độ xử lý tối đa để chạy benchmark.

Văn bản đầu ra sau khi giải mã token ids sẽ được kiểm tra chất lượng thông qua một bộ lọc, bộ lọc này có khả năng quét và phát hiện lỗi lặp từ vô nghĩa dạng 1-gram, 2-gram, 3-gram, các ký tự lỗi, không đúng font tiếng Việt. Nếu bản tóm tắt lỗi, hệ thống sẽ kích hoạt cơ chế giải mã dự phòng để sinh lại một bản tóm tắt hợp lệ khác.

2.8.5. Đánh giá kết quả

Hệ thống đánh giá mức độ tương đồng về mặt ngữ nghĩa giữa bản tóm tắt và văn bản nguồn thông qua bộ chỉ số gồm Rouge-1, Rouge-2, Rouge-L, Rouge-Lsum. Các độ đo này sẽ đánh giá độ trùng khớp từ trên các đơn vị như từ đơn, từ đôi, chuỗi con chung dài nhất, từ đó phản ánh được khả năng lưu giữ nội dung gốc của văn bản tóm tắt.

Hệ thống đo lường độ tương đồng về mặt ngữ nghĩa giữa hai văn bản dựa trên chỉ số BERTScore, chỉ số này sẽ tính toán các giá trị như Precision, Recall, F1 dựa trên vector embedding của các token thu được từ LLM, giúp biết được chính xác mô hình dùng từ đồng nghĩa để tóm tắt hoặc dùng các cấu trúc diễn đạt khác.

Thời gian thực thi của các thuật toán cũng được lưu lại thông qua Latency tính bằng giây. Đây là chỉ số dùng để so sánh tốc độ sinh văn bản tóm tắt của các mô hình, từ đó hỗ trợ việc so sánh hiệu năng của các mô hình.

2.9. Thiết kế kiến trúc hệ thống

2.9.1. Kiến trúc tổng thể hệ thống

Mô hình hoạt động tổng thể của hệ thống dựa trên luồng giao tiếp bất đồng bộ qua mạng nội bộ hoặc Internet. Client gửi các yêu cầu xử lý dữ liệu và nhận phản hồi dưới dạng JSON. Hệ thống mã nguồn được tổ chức theo kiến trúc phân lớp gồm: lớp định tuyến API, lớp dịch vụ nghiệp vụ và lớp điều phối suy luận học máy.

2.9.2. Kiến trúc Frontend - Backend

Frontend: được xây dựng bằng các ngôn ngữ lập trình React, Vite và TypeScript. Trạng thái ứng dụng được quản lý tập trung bằng Zustand store. Frontend chịu trách nhiệm gửi các file tài liệu hoặc tham số cấu hình tóm tắt thông qua các HTTP Post requests dạng multipart/form-data đến Backend, nhận lại JSON kết quả và render các biểu đồ so sánh chất lượng bằng công cụ đồ họa Recharts.

Backend: Chạy trên nền ngôn ngữ lập trình Python, đóng vai trò như một API gateway điều phối. Backend tiếp nhận các yêu cầu, phân tích các tệp tin tải lên, thực hiện lưu trữ metadata vào SQLite DB và chuyển văn bản thô đến lớp AI Engine để tính toán và thực hiện các tác vụ. FastAPI được cấu hình chạy đa luồng bất đồng bộ để nâng cao khả năng xử lý.

2.9.3. Kiến trúc AI Engine


Model Registry: là file cấu hình khai báo danh sách tất cả các checkpoint mô hình trích xuất, mô hình sinh Seq2Seq và mô hình nhúng kèm đường dẫn thư mục cục bộ của chúng.

Model Loader: đây là module quản lý vòng đời nạp mô hình vào GPU VRAM. Khi mô hình được yêu cầu, ModelLoader sẽ nạp nó vào bộ nhớ đệm để tái sử dụng cho các request sau. Khi bộ nhớ GPU đầy thì nó sẽ tự động hủy nạp các mô hình ít sử dụng.

Vector Store Integrator: thành phần giao tiếp với Vector DB để thực hiện lưu trữ vector phân đoạn tài liệu và truy vấn tìm kiếm ngữ nghĩa thời gian thực phục vụ cho quá trình hoạt động của ChatRAG.

CHƯƠNG 3. GIAO DIỆN CHƯƠNG TRÌNH

3.1. Giao diện trang chủ



Hình 3.1. Giao diện trang chủ

Trang chủ là màn hình chào đón, nó là nơi đầu tiên người dùng nhìn thấy khi truy cập vào hệ thống, màn hình này cung cấp cái nhìn toàn cảnh về mục tiêu nghiên cứu và trạng thái vận hành hiện tại của đề tài. Màn hình tích hợp các thẻ thống kê số liệu thời gian thực hiển thị tổng số lượng tài liệu nghiên cứu đã được nạp, số lượt yêu cầu tóm tắt

đã thực hiện, cùng trạng thái kết nối của cơ sở dữ liệu quan hệ SQLite và các hoạt động gần đây trên hệ thống.

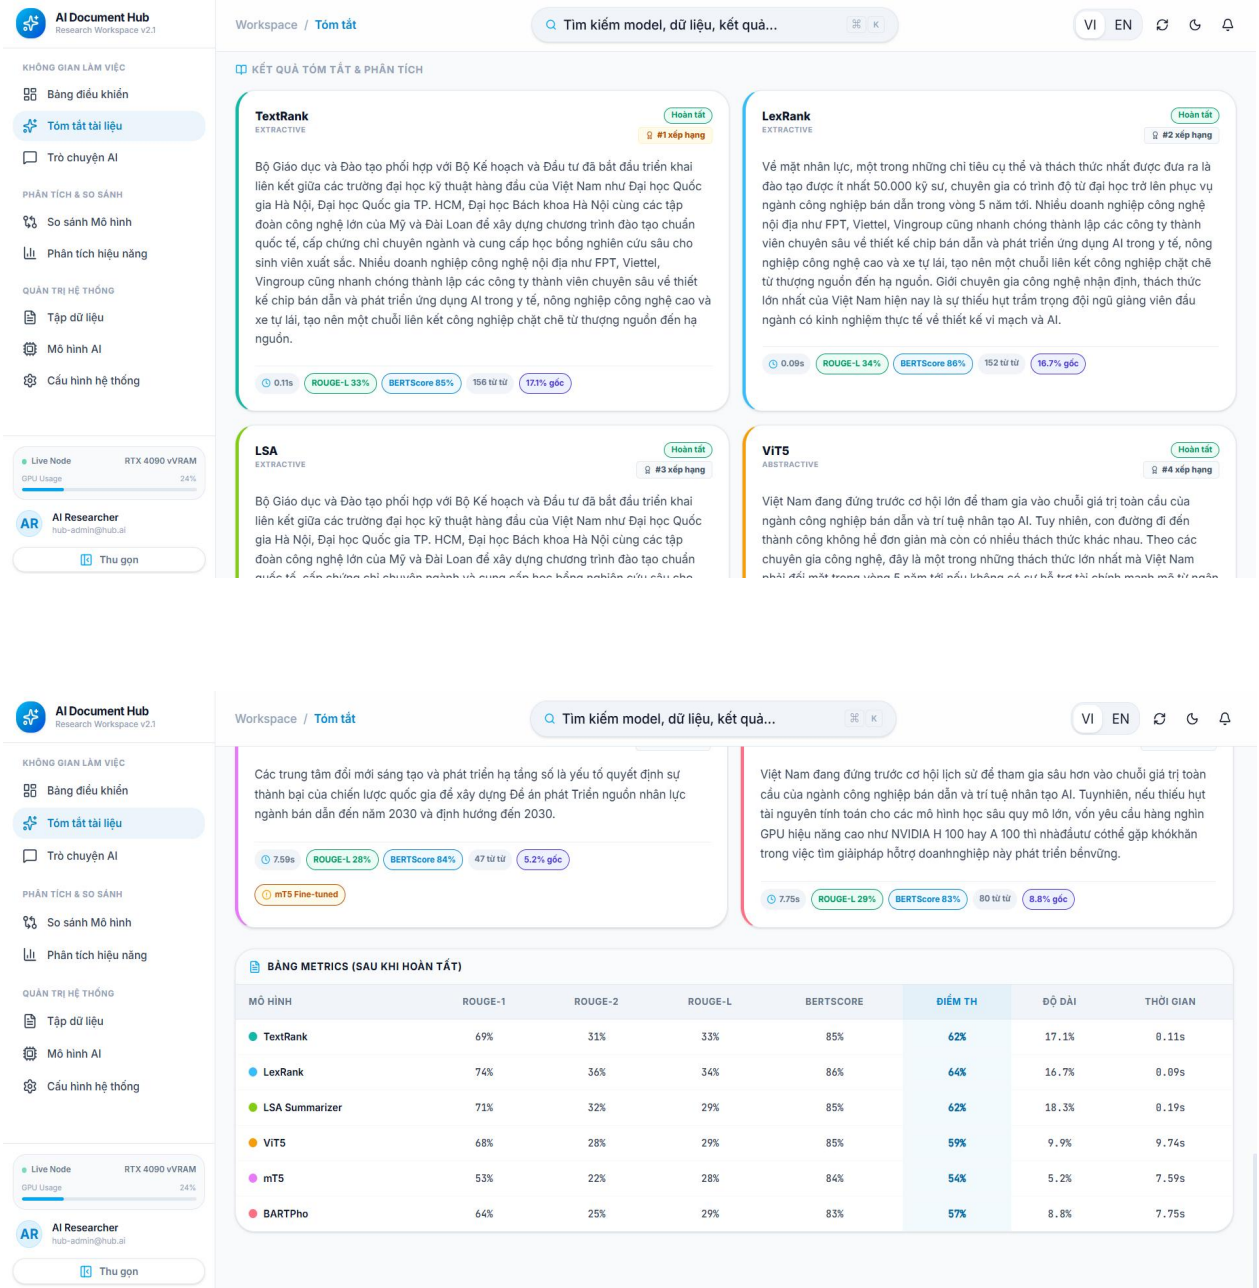
Trang chủ cung cấp hệ thống các lối tắt điều hướng trực quan giúp người dùng nhanh chóng truy cập vào ba chức năng cốt lõi của đề tài bao gồm tóm tắt văn bản với nhiều thuật toán, hỏi đáp tài liệu ChatRAG và theo dõi bảng xếp hạng benchmark. Giao diện này cũng tích hợp các hướng dẫn sử dụng nhanh giúp người dùng dễ dàng nắm bắt luồng vận hành của hệ thống ngay từ lần đầu tiên truy cập.

3.2. Giao diện tóm tắt văn bản

Trang tóm tắt văn bản cung cấp không gian làm việc trực quan cho người dùng, cho phép người dùng nhập trực tiếp đoạn văn bản từ bàn phím hoặc tải lên các tệp tin tài liệu cần được tóm tắt từ máy tính cá nhân. Trang web tích hợp bảng điều khiển cho phép người dùng chọn linh hoạt giữa 3 phương pháp tóm tắt chính là trích rút câu quan trọng, diễn giải tự nhiên hoặc lai ghép hai giai đoạn. Sau khi hệ thống hoàn tất xử lý, bản tóm tắt kết quả sẽ được hiển thị lên giao diện giúp người dùng dễ dàng đối chiếu và kiểm tra tính toàn vẹn của thông tin. Giao diện này cũng hiển thị các chỉ số đo lường hiệu năng thời gian thực bao gồm thời gian suy diễn của mô hình tính bằng giây, số lượng từ đã rút gọn và tỷ lệ nén thực tế đạt được sau khi thực thi.

The screenshot displays the 'AI Document Hub' interface, specifically the 'Tóm tắt' (Summarization) workspace. The interface is divided into several sections:

- Left Sidebar:** Contains navigation links such as 'KHÔNG GIAN LÀM VIỆC' (Workspace), 'Bảng điều khiển' (Dashboard), 'Tóm tắt tài liệu' (Document Summarization), 'Trò chuyện AI' (AI Chat), 'PHÂN TÍCH & SO SÁNH' (Analysis & Comparison), 'So sánh Mô hình' (Model Comparison), 'Phân tích hiệu năng' (Performance Analysis), 'QUẢN TRỊ HỆ THỐNG' (System Management), 'Tập dữ liệu' (Dataset), 'Mô hình AI' (AI Model), and 'Cấu hình hệ thống' (System Configuration).
- Top Bar:** Includes a search bar for models, datasets, and results, and language selection options (VI, EN).
- Main Content Area:**
 - CẤU HÌNH THỬ NGHIỆM (Experiment Configuration):** Features a 'TÀI LIỆU ĐẦU VÀO' (Input Document) section with a 'Tải lên tài liệu của bạn' (Upload your document) button. Below it, a 'LỰA CHỌN THUẬT TOÁN' (Algorithm Selection) section offers 'EXTRACTIVE' (TextRank, LexRank, LSA) and 'ABSTRACTIVE' (VITS, mTS, BARTPho) options. A 'TOM TẮT CẤU HÌNH' (Summarization Configuration) box shows 'Đã chọn: 6 thuật toán' (Selected: 6 algorithms) and 'Nguồn: 907 từ' (Source: 907 words).
 - Sẵn sàng chạy so sánh (Ready to compare):** A button to initiate the summarization process.
 - VĂN BẢN GỐC (Original Text):** Displays a paragraph about Vietnam's AI strategy, mentioning the 2030 and 2050 goals.
 - TÓM TẮT THAM CHIẾU (TUY CHỌN) (Referenced Summary (Optional)):** Shows a summarized version of the text, highlighting key points about AI development and national strategy.



Hình 3.2. Giao diện tóm tắt văn bản

3.3. Giao diện so sánh bản tóm tắt của các mô hình

Khi người dùng đổi trang, Frontend gửi một yêu cầu truy vấn đến API Backend kèm theo thông tin trang hoặc ID mẫu thử. Từ đó backend có thể lấy dữ liệu để hiển thị lên giao diện cho người dùng có thể quan sát, so sánh, đối chiếu kết quả của các mô hình tóm tắt khác nhau trên cùng một trang giao diện, để cho người dùng dễ xem xét và so sánh các mô hình tóm tắt với nhau.

3.4. Giao diện đánh giá kết quả

PHƯƠNG PHÁP	ROUGE-1 (R1)	ROUGE-2 (R2)	ROUGE-L (RL)	ROUGE-LSUM	BERT P	BERT R	BERT F1	LATENCY (S)
Extractive LSA Summarizer	0.4600	0.2085	0.2929	0.2929	0.6882	0.7344	0.7101	0.0088
Extractive LexRank	0.4254	0.2098	0.2833	0.2833	0.6936	0.7516	0.7210	0.0093
Extractive TextRank	0.4194	0.2072	0.2818	0.2818	0.6917	0.7508	0.7196	0.0198
Hybrid LSA → VIT5	0.5612	0.2292	0.3456	0.3456	0.7240	0.6644	0.6925	1.7865
Hybrid LexRank → VIT5	0.5819	0.2595	0.3660	0.3660	0.7322	0.6732	0.7011	1.8453
Hybrid TextRank → VIT5	0.5816	0.2605	0.3673	0.3673	0.7323	0.6735	0.7013	1.9019
Hybrid LSA → BARTPho	0.5644	0.2330	0.3464	0.3464	0.7147	0.6695	0.6910	2.1272
Hybrid LexRank → BARTPho	0.5836	0.2599	0.3653	0.3653	0.7229	0.6773	0.6989	2.3137
Hybrid TextRank → BARTPho	0.5844	0.2617	0.3662	0.3662	0.7234	0.6773	0.6992	2.4403
Abstractive (FT) VIT5 (Fine-tuned)	0.5950	0.2773	0.3800	0.3800	0.7365	0.6799	0.7067	2.6564
Hybrid TextRank → mT5	0.5471	0.2197	0.3343	0.3343	0.7208	0.6595	0.6884	2.6709
Hybrid LexRank → mT5	0.5459	0.2184	0.3330	0.3330	0.7206	0.6590	0.6880	2.7206
Hybrid LSA → mT5	0.5217	0.1921	0.3182	0.3182	0.7149	0.6491	0.6800	3.0224
Abstractive (Base) mT5 (Baseline)	0.5506	0.2154	0.3328	0.3328	0.7177	0.6595	0.6870	3.2492
Abstractive (FT) BARTPho (Fine-tuned)	0.5978	0.2792	0.3775	0.3775	0.7252	0.6847	0.7040	5.1996

Hình 3.4. Giao diện đánh giá kết quả

Đánh giá kết quả là trung tâm hỗ trợ người dùng theo dõi, so sánh đối chiếu hiệu năng và chất lượng của 15 cấu hình mô hình tóm tắt khác nhau. Màn hình tích hợp bộ chọn quy mô dữ liệu kiểm thử cùng các biểu đồ trực quan sinh động như biểu đồ mạng nhện đánh giá đa chiều về chất lượng ngôn ngữ và biểu đồ thanh ngang so sánh độ trễ xử lý. Giao diện này giúp người dùng dễ dàng nhận diện điểm mạnh cũng như điểm yếu của từng giải thuật để đưa ra lựa chọn tối ưu cho từng bài toán cụ thể.

Phía dưới là bảng so sánh chi tiết hiển thị các chỉ số Rouge, BERTScore và thời gian phản hồi thực tế được làm tròn 4 chữ số thập phân, kết hợp hệ thống badge màu phân loại rõ ràng 4 nhóm phương pháp tóm tắt. Toàn bộ số liệu trên giao diện được cập nhật tự động thời gian thực thông qua các yêu cầu API gửi từ React Frontend đến FastAPI Backend để đọc các tệp kết quả lưu trữ dạng JSON trên máy chủ, bỏ qua các tầng bộ nhớ đệm để luôn đảm bảo tính cập nhật.

CHƯƠNG 4. THỰC NGHIỆM VÀ ĐÁNH GIÁ

4.1. Môi trường và công nghệ cài đặt

4.1.1. Cấu hình phần cứng hệ thống

Để đảm bảo tính nhất quán và khả năng trung thực của các kết quả thực nghiệm, toàn bộ quá trình chạy suy luận và đánh giá chất lượng được thực thi trên một cấu hình phần cứng cục bộ chuẩn xác như sau:

- + Bộ vi xử lý (CPU): Intel(R) Core (TM) i5-12450H 12th Gen (2.00 GHz).
- + Bộ nhớ trong (RAM): 16 GB RAM vật lý.
- + Card đồ họa (GPU): NVIDIA GeForce RTX 3050 Ti Laptop GPU.
- + Bộ nhớ đồ họa (VRAM): 4.0 GB GDDR6.

4.1.2. Môi trường công nghệ phần mềm và thư viện hỗ trợ

Hệ thống sử dụng các nền tảng công nghệ mã nguồn mở hiện đại, đảm bảo tính mở rộng và hiệu năng xử lý cao:

- + Ngôn ngữ lập trình chính: Python version 3.13.2.
- + Thư viện học sâu và xử lý ngôn ngữ tự nhiên: PyTorch CUDA 12.4.
- + Hệ quản trị cơ sở dữ liệu và tìm kiếm: Qdrant Vector DB, SQLite.
- + Phát triển API và Giao diện: FastAPI, React.

4.2. Cơ chế hoạt động của Pipeline Tóm tắt Lại

Trong môi trường tài nguyên phần cứng hạn chế VRAM GPU 4GB, việc đưa trực tiếp một văn bản dài ví dụ bài báo 2.000 từ vào mô hình sinh Transformer Seq2Seq như ViT5 hay BARTPho sẽ ngay lập tức gây ra lỗi tràn bộ nhớ hoặc văn bản bị cắt cụt do vượt quá giới hạn ngưỡng cảnh 512 tokens. Để giải quyết triệt để vấn đề này, hệ thống phát triển cơ chế tóm tắt lại hai giai đoạn là two-stage hybrid summarization.



Hình 4.1. Sơ đồ pipeline tóm tắt Lại hai giai đoạn

4.3. Cài đặt mô hình và thiết kế thực nghiệm

4.3.1. Phân tích thống kê tập dữ liệu VietNews

Bộ dữ liệu được sử dụng để tinh chỉnh và đánh giá các mô hình là “nam194/vietnews”. Đây là bộ dữ liệu tóm tắt văn bản tiếng Việt quy mô lớn, chứa các bài báo thu thập từ 3 trang tin điện tử phổ biến tại Việt Nam: Tuổi trẻ, VnExpress và Người đưa tin. Phân bố chi tiết của bộ dữ liệu thực tế được sử dụng trong thực nghiệm được mô tả trong bảng thống kê ASCII dưới đây:

Bảng 4.1. Thống kê chi tiết tập dữ liệu VietNews

Chỉ số phân tích	Tập Train	Tập Validation	Tập Test
Số lượng mẫu (bài báo)	99.134	22.184	22.498
Độ dài bài viết trung bình (từ)	406,5	435,7	429,5
Độ dài bản tóm tắt tham chiếu TB (từ)	32,4	31,8	31,8
Tỷ lệ nén trung bình (%)	9,31%	8,76%	8,92%
Độ dài bài viết tại phân vị 95% (từ)	785	804	812

Quy trình tiền xử lý dữ liệu thực tế: Loại bỏ các bài báo có phần nội dung bài viết hoặc phần tóm tắt bị trống hoặc ngắn dưới 10 từ. Chuẩn hóa văn bản tiếng Việt bằng cách đưa toàn bộ ký tự Unicode về dạng chuẩn NFC nhằm loại bỏ sự không đồng nhất trong gõ dấu tiếng Việt.

4.3.2. Thiết kế kịch bản thực nghiệm và các độ đo đánh giá

Quá trình huấn luyện các mô hình diễn giải được thực thi bằng cách sử dụng thư viện “Seq2SeqTrainer” của Hugging Face. Nhóm nghiên cứu thực hiện tinh chỉnh 3 mô hình nền tảng khác nhau để làm cơ sở so sánh thực nghiệm. Các thông số cài đặt huấn luyện thực tế được ghi nhận chi tiết như sau:

Mô hình ViT5-base là mô hình Seq2Seq được phát triển chuyên biệt cho tiếng Việt bởi VietAI. Mô hình được tiền huấn luyện trên khoảng 50GB dữ liệu văn bản tiếng Việt và sở hữu khoảng 220 triệu tham số. Trong nghiên cứu này, ViT5-base lựa chọn làm mô hình sinh tóm tắt chính và tinh chỉnh trên bộ dữ liệu VietNews trong 3 epochs.

Mô hình BARTPho-syllable là mô hình Transformer do VinAI phát triển, được thiết kế chuyên biệt cho tiếng Việt ở cấp độ âm tiết. Cách tiếp cận này giúp giảm ảnh hưởng của các từ ngoài từ điển và cải thiện khả năng xử lý ngôn ngữ tự nhiên tiếng Việt. Với khoảng 340 triệu tham số. Mô hình được tinh chỉnh trong 3 epochs kết hợp với bộ lập

lich học cosine decay nhằm nâng cao chất lượng sinh văn bản và duy trì tính ổn định trong quá trình huấn luyện.

Mô hình mT5-small là mô hình Seq2Seq đa ngôn ngữ được phát triển bởi Google với khoảng 300 triệu tham số. Trong nghiên cứu, mT5-small sử dụng như mô hình đối chuẩn để so sánh với các mô hình huấn luyện chuyên biệt cho tiếng Việt. Mô hình tinh chỉnh trên bộ dữ liệu VietNews trong 3 epochs nhằm bảo đảm tính thống nhất về điều kiện thực nghiệm.

Thực nghiệm benchmark chạy trên 5.000 mẫu ngẫu nhiên được trích xuất cố định seed = 42 từ tập kiểm thử độc lập của bộ dữ liệu VietNews. 15 kịch bản thực nghiệm được thiết kế bao gồm: Lọc câu bằng các giải thuật TextRank, LexRank, và LSA. Sinh câu tóm tắt trực tiếp từ mô hình gốc tinh chỉnh ViT5, BARTPho, mT5. Kết hợp chéo 2 giai đoạn: giai đoạn 1 lọc bớt câu rác bằng Extractive rồi mới chuyển sang giai đoạn 2 cho các mô hình Transformer sinh bản tóm tắt cuối cùng.

4.4. Đánh giá hệ thống và phân tích kết quả đạt được

4.4.1. Số liệu benchmark tóm tắt văn bản

PHƯƠNG PHÁP	ROUGE-1 (R1)	ROUGE-2 (R2)	ROUGE-L (RL)	ROUGE-LSUM	BERT P	BERT R	BERT F1	LATENCY (S)
Extractive LSA Summarizer	0.4600	0.2005	0.2929	0.2929	0.6882	0.7344	0.7101	0.0088
Extractive LexRank	0.4254	0.2098	0.2833	0.2833	0.6936	0.7516	0.7210	0.0093
Extractive TextRank	0.4194	0.2072	0.2818	0.2818	0.6917	0.7508	0.7196	0.0198
Hybrid LSA → ViT5	0.5612	0.2292	0.3456	0.3456	0.7240	0.6644	0.6925	1.7865
Hybrid LexRank → ViT5	0.5819	0.2595	0.3660	0.3660	0.7322	0.6732	0.7011	1.8453
Hybrid TextRank → ViT5	0.5816	0.2605	0.3673	0.3673	0.7323	0.6735	0.7013	1.9019
Hybrid LSA → BARTPho	0.5644	0.2330	0.3464	0.3464	0.7147	0.6695	0.6910	2.1272
Hybrid LexRank → BARTPho	0.5836	0.2599	0.3653	0.3653	0.7229	0.6773	0.6989	2.3137
Hybrid TextRank → BARTPho	0.5844	0.2617	0.3662	0.3662	0.7234	0.6773	0.6992	2.4403
Abstractive (FT) ViT5 (Fine-tuned)	0.5950	0.2773	0.3800	0.3800	0.7365	0.6799	0.7067	2.6564
Hybrid TextRank → mT5	0.5471	0.2197	0.3343	0.3343	0.7208	0.6595	0.6884	2.6709
Hybrid LexRank → mT5	0.5459	0.2184	0.3330	0.3330	0.7206	0.6590	0.6880	2.7206
Hybrid LSA → mT5	0.5217	0.1921	0.3182	0.3182	0.7149	0.6491	0.6800	3.0224
Abstractive (Base) mT5 (Baseline)	0.5506	0.2154	0.3328	0.3328	0.7177	0.6595	0.6870	3.2492
Abstractive (FT) BARTPho (Fine-tuned)	0.5978	0.2792	0.3775	0.3775	0.7252	0.6847	0.7040	5.1996

Hình 4.2. Kết quả thực nghiệm tóm tắt văn bản trên 5.000 mẫu VietNews

4.4.2. Nhận xét và phân tích chuyên sâu hiệu năng tóm tắt

4.4.2.1. Phân tích chất lượng của các mô hình diễn giải trừu tượng

Các mô hình tóm tắt diễn giải sinh trừu tượng cho thấy khả năng diễn đạt tự nhiên và cô đọng tốt. Trong đó thì ViT5 đạt điểm Rouge-L cao nhất hệ thống với giá trị là 0,3800. Kết quả này cao hơn mô hình BARTPho đạt 0,3775 khoảng 0,66 phần trăm. Nó vượt trội hơn mô hình baseline mT5 đạt 0,3328 khoảng 14,18 phần trăm. Việc ViT5 thể hiện ưu thế về chất lượng trùng lặp từ vựng bề mặt có thể lý giải bởi cấu trúc tokenizer sentencePiece được tối ưu hóa chuyên biệt cho ngôn ngữ tiếng Việt.

Tokenizer của ViT5 có xu hướng chia tách các từ ghép tiếng Việt chính xác theo ranh giới âm tiết và ngữ cảnh ngữ nghĩa, hạn chế tối đa việc phân mảnh từ thành các subtoken vô nghĩa. Còn BARTPho dù là mô hình rất mạnh cho tiếng Việt đạt Rouge-L là 0,3775, thấp hơn một chút so với ViT5.

Phân tích sâu hơn cho ta thấy điểm tương đồng ngữ nghĩa cấp độ câu qua thước đo BERT R tức là điểm recall của BARTPho đạt 0,6847. Nó cao hơn điểm số 0,6799 của ViT5. Điều đó chứng minh rằng BARTPho có xu hướng viết lại câu linh hoạt bằng cách sử dụng các cấu trúc ngữ pháp đồng nghĩa, làm cho mô hình dễ bị thấp điểm ở thước đo so khớp bề mặt như Rouge-L nhưng lại bảo toàn tốt ngữ nghĩa sâu của tài liệu gốc.

Với mô hình đa ngôn ngữ mT5 phiên bản cơ sở baseline, nó chỉ đạt điểm Rouge-L ở mức 0,3328, thấp hơn nhiều so với hai mô hình đã tinh chỉnh. Quá trình đánh giá thực tế cho thấy mô hình này hay xuất hiện lỗi ngữ pháp, lặp từ, hoặc sinh câu không hoàn chỉnh trong một số trường hợp văn bản nguồn phức tạp.

Nguyên nhân ở cơ chế chia sẻ không gian từ vựng của tokenizer đa ngôn ngữ. Bộ từ vựng của mT5 phải biểu diễn hơn 100 ngôn ngữ khác nhau, khiến dung lượng tài nguyên dành riêng cho việc biểu diễn các đặc trưng tiếng Việt bị thu hẹp đi nhiều. Đó chính là nguyên nhân chính làm mô hình gặp khó khăn trong việc duy trì tính mạch lạc dài và độ tự nhiên ngôn ngữ của tiếng Việt so với các mô hình được tiền huấn luyện chuyên biệt như ViT5 và BARTPho.

4.5.2.2. Đánh giá hiệu quả của phương pháp lai ghép

Kiến trúc lai ghép kết hợp giai đoạn trích xuất để lọc nhiều văn bản nguồn trước khi đưa vào giai đoạn sinh diễn giải thể hiện ưu thế vượt trội về khả năng tối ưu hóa tài nguyên phần cứng trong khi vẫn bảo toàn chất lượng thông tin.

Đối với khả năng giảm độ trễ suy diễn, thực nghiệm cho ta thấy đây là cải tiến quan trọng nhất của phương pháp lai. BARTPho, khi hoạt động ở chế độ độc lập diễn giải thuần túy, thời gian suy diễn trung bình cho mỗi văn bản lên tới 5,1996 giây do cơ chế tự hồi quy phải xử lý toàn bộ chiều dài của tài liệu nguồn gốc.

Khi kết hợp với LexRank tạo thành mô hình lai LexRank kết hợp BARTPho, thời gian xử lý giảm xuống còn 2,3137 giây cho mỗi mẫu, tương đương với việc tiết kiệm được 55,50 phần trăm thời gian xử lý và tốc độ tăng khoảng 2,25 lần. Kết quả tương tự cũng ghi nhận ở cấu hình lai LSA kết hợp BARTPho với độ trễ giảm xuống còn 2,1272 giây, tiết kiệm 59,09 phần trăm thời gian suy diễn. Thuật toán ViT5, thời gian xử lý từ 2,6564 giây đối với mô hình thuần giảm xuống chỉ còn 1,8453 giây khi kết hợp với LexRank tạo thành cấu hình lai LexRank kết hợp ViT5, giảm 30,53 phần trăm độ trễ, và giảm xuống còn 1,7865 giây khi kết hợp với LSA tạo thành cấu hình lai LSA kết hợp ViT5, giảm 32,75 phần trăm độ trễ.

Sự cải thiện mạnh mẽ này có được là nhờ giai đoạn trích xuất đã rút gọn văn bản xuống còn khoảng 30 phần trăm đến 35 phần trăm độ dài ban đầu, loại bỏ các phần thông tin không liên quan, giúp bộ giải mã của các mô hình sinh giảm thiểu đáng kể số bước tự hồi quy.

Độ bảo toàn chất lượng tóm tắt, dù kích thước đầu vào của mô hình sinh bị cắt giảm từ 65 phần trăm đến 70 phần trăm, chất lượng của văn bản tóm tắt đầu ra chỉ ghi nhận mức suy giảm rất nhỏ. Ta có thể thấy cấu hình TextRank kết hợp ViT5 đạt điểm Rouge-L là 0,3673, chỉ thấp hơn khoảng 3,34 phần trăm so với điểm số 0,3800 của ViT5 thuần.

Cấu hình LexRank kết hợp ViT5 đạt ROUGE-L là 0,3660 giảm 3,68 phần trăm. Đối với BARTPho, cấu hình LexRank kết hợp BARTPho đạt Rouge-L ở mức 0,3653, chỉ

giảm 3,23 phần trăm so với mô hình gốc. Điều này chứng minh rằng cơ sở lý thuyết của phương pháp lai khi các thuật toán trích xuất đã loại bỏ thành công phần lớn thông tin dư thừa, lặp ý hoặc các chi tiết gây nhiễu nhưng vẫn bảo toàn nguyên vẹn các mệnh đề thông tin cốt lõi làm đầu vào chất lượng cho mô hình sinh.

Về tính ổn định phần cứng, trong môi trường GPU hạn chế với VRAM 4,0 GB của card đồ họa RTX 3050 Ti Laptop, khi thử nghiệm với các tài liệu dài trên 1.500 từ, các mô hình sinh thuần túy thường xuyên gặp lỗi tràn bộ nhớ VRAM do cơ chế tự chú ý có độ phức tạp tính toán bình phương theo chiều dài chuỗi. Ngược lại thì các cấu hình lai duy trì sự ổn định tuyệt đối với mức tiêu thụ VRAM giảm đáng kể, đảm bảo mức thời gian phản hồi trung bình luôn dưới 2,5 giây cho mọi kích thước tài liệu kiểm thử.

4.5.2.3. Điểm mạnh và hạn chế của nhóm thuật toán trích rút

Các thuật toán trích xuất thuần túy bao gồm LexRank, TextRank và LSA xếp ở vị trí cao về mặt hiệu năng tổng thể trên các thước đo tốc độ và độ trung thực thông tin.

Về tốc độ xử lý thì LSA và LexRank đạt độ trễ rất thấp lần lượt là 8,8 mili giây và 9,3 mili giây cho mỗi tài liệu, còn TextRank mất 19,8 mili giây. Tốc độ này nhanh gấp từ 250 đến 500 lần so với các mô hình diễn giải tự hồi quy. Về độ trung thực thông tin, nhóm thuật toán trích rút đạt điểm số lên tới 100 phần trăm và tỷ lệ ảo giác thông tin bằng 0 phần trăm. Do nguyên lý cốt lõi của phương pháp trích xuất là lựa chọn nguyên bản các câu quan trọng có sẵn trong văn bản nguồn để đưa vào bản tóm tắt, mô hình hoàn toàn không tự sinh ra từ mới nên loại bỏ được hoàn toàn nguy cơ ảo giác thông tin. Đây đóng vai trò yếu tố cực kỳ quan trọng đối với các hệ thống yêu cầu tính chính xác sự thật cao.

Nhóm trích rút có nhược điểm rất lớn là tính liên kết ngữ nghĩa và độ tự nhiên của ngôn ngữ. Bản tóm tắt trích rút thực chất là sự chắp vá của các câu văn rời rạc. Điều này làm giảm tính trôi chảy của văn bản tóm tắt làm cho văn bản thiếu đi tính liên kết, đôi khi gặp hiện tượng mất đại từ thay thế hoặc thiếu các liên từ logic chuyển ý, làm ảnh hưởng đến trải nghiệm đọc của người dùng so với khả năng diễn đạt mượt mà, cô đọng của các mô hình sinh trừu tượng.

KẾT QUẢ VÀ KIẾN NGHỊ

1. Kết quả đạt được

1.1. Về mặt lý thuyết

Trong quá trình nghiên cứu và thực hiện đề tài “Nghiên cứu và đánh giá phương pháp lai giữa trích rút và diễn giải cho bài toán tóm tắt văn bản tiếng Việt”, em đã tiếp cận, học hỏi và làm chủ các kiến thức nền tảng cũng như nâng cao.

Đã biết được kiến trúc Seq2Seq Transformer với cơ chế là Multi-Head Self-Attention. Nó đóng vai trò cốt lõi trong việc hiểu ngữ cảnh văn bản tiếng Việt. Và nghiên cứu sâu các mô hình Transformer được huấn luyện riêng cho tiếng Việt. Ví dụ như ViT5 và BARTPho, giúp em biết được sự khác biệt về kiến trúc và phương pháp mã hóa từ vựng.

Đề tài tìm hiểu và hiện thực hóa thành công các phương pháp tóm tắt trích xuất truyền thống gồm TextRank, LexRank và LSA. Các thuật toán này giúp đánh giá khả năng lựa chọn câu quan trọng trong văn bản và làm cơ sở để xây dựng các mô hình lai.

Nghiên cứu tiếp cận kiến trúc RAG cho bài toán hỏi đáp tài liệu dài. Các kỹ thuật được nghiên cứu bao gồm: phân mảnh ngữ nghĩa động, tìm kiếm lai kết hợp BM25, Dense Vector, tái xếp hạng bằng Cross-Encoder, cơ chế chỉ mục phân cấp RAPTOR để hỗ trợ truy xuất tri thức hiệu quả trên các tài liệu có kích thước lớn.

1.2. Về mặt thực nghiệm

Các mô hình học sâu ViT5 và BARTPho được huấn luyện và tinh chỉnh thành công trên 30 nghìn mẫu thử trên khoảng 143 nghìn mẫu của bộ dữ liệu VietNews. Quá trình huấn luyện áp dụng kỹ thuật LoRA, giúp giảm yêu cầu phần cứng nhưng vẫn duy trì khả năng hội tụ tốt của mô hình ở mức ổn.

Đề tài giải quyết cơ bản bài toán giới hạn bộ nhớ đồ họa và độ dài ngữ cảnh đầu vào của Transformer nhờ việc xây dựng Pipeline tóm tắt lai hai giai đoạn. Giai đoạn đầu sử dụng phương pháp trích chọn để loại bỏ phần lớn nội dung dư thừa, trong khi giai đoạn sau sử dụng mô hình sinh để diễn giải lại nội dung theo ngôn ngữ tự nhiên.

Kết quả thực nghiệm cho thấy phương pháp lai trong dự án này giúp giảm từ 30 phần trăm đến 59 phần trăm thời gian suy luận của các mô hình sinh mà vẫn duy trì chất lượng tóm tắt ở mức cao. Ví dụ như thời gian xử lý của BARTPho giảm từ 5,20 giây xuống còn khoảng 2,1 đến 2.5 giây trong khi điểm Rouge-L suy giảm không đáng kể.

Đề tài đã hoàn thiện một hệ thống phần mềm full-stack với Backend FastAPI và Frontend React. Cung cấp giao diện trực quan cho việc thử nghiệm, so sánh mô hình, đánh giá chất lượng và theo dõi hiệu năng hệ thống.

2. Hạn chế

Giới hạn về phần cứng là rào cản đáng kể. Với GPU dung lượng 4GB VRAM, vận hành đồng thời nhiều mô hình như Embedding Model, Reranker và Generator tạo áp lực lớn lên bộ nhớ đồ họa. Cơ chế offload động đã giúp khắc phục vấn đề nhưng mà thời gian khởi tạo mô hình ở lần chạy đầu vẫn còn tương đối cao.

Chất lượng của Pipeline Hybrid phụ thuộc trực tiếp vào hiệu quả của giai đoạn trích xuất. Nếu các câu chứa thông tin quan trọng bị loại bỏ ở bước đầu tiên thì mô hình sinh ở giai đoạn sau không thể khôi phục lại các thông tin đó trong bản tóm tắt cuối cùng.

Hiện tượng ảo giác thông tin vẫn xuất hiện ở mức độ nhỏ đối với các mô hình sinh. Trong một số trường hợp, mô hình có thể bổ sung hoặc diễn giải chưa chính xác các thực thể và số liệu xuất hiện trong văn bản nguồn.

Hệ thống hiện chưa xử lý tối ưu các tài liệu PDF có cấu trúc phức tạp như bảng biểu lồng nhau, sơ đồ hình ảnh, làm việc trích xuất văn bản đôi khi bị mất định dạng hoặc thiếu thông tin.

3. Hướng phát triển

Áp dụng kỹ thuật QLoRA 4-bit có thể giúp giảm thêm mức tiêu thụ bộ nhớ GPU, tạo điều kiện thử nghiệm các mô hình lớn hơn như ViT5-large hoặc BARTPho-word trên phần cứng phổ thông.

Tích hợp các mô hình ngôn ngữ lớn chuyên biệt cho tiếng Việt để nâng cao chất lượng hội thoại và khả năng lập luận của hệ thống ChatRAG.

Mở rộng sang bài toán tóm tắt đa văn bản, cho phép tổng hợp thông tin từ nhiều nguồn tài liệu khác nhau về cùng một chủ đề hoặc sự kiện.

Xây dựng quy trình đánh giá có sự tham gia của con người nhằm bổ sung cho các thước đo tự động như Rouge, Bleu và BERTScore.

Tích hợp các mô hình xử lý bố cục tài liệu hoặc OCR hiện đại, giúp trích xuất chính xác nội dung từ các bảng biểu, biểu đồ và hình ảnh phức tạp phục vụ cho hệ thống RAG.

TÀI LIỆU THAM KHẢO

- [1] A. See, P. J. Liu, and C. D. Manning, “Get To The Point: Summarization with Pointer-Generator Networks,” in *Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, R. Barzilay and M.-Y. Kan, Eds., Vancouver, Canada: Association for Computational Linguistics, Jul. 2017, pp. 1073–1083. doi: [10.18653/v1/P17-1099](https://doi.org/10.18653/v1/P17-1099).
- [2] N. Giarelis, C. Mastrokostas, and N. Karacapilidis, “Abstractive vs. Extractive Summarization: An Experimental Review,” *Applied Sciences*, vol. 13, no. 13, p. 7620, Jun. 2023, doi: [10.3390/app13137620](https://doi.org/10.3390/app13137620).
- [3] V. Tretyak and D. Stepanov, “Combination of abstractive and extractive approaches for summarization of long scientific texts,” Jun. 12, 2020, *arXiv*: arXiv:2006.05354. doi: [10.48550/arXiv.2006.05354](https://doi.org/10.48550/arXiv.2006.05354).
- [4] Z. Alami Merrouni, B. Frikh, and B. Ouhbi, “EXABSUM: a new text summarization approach for generating extractive and abstractive summaries,” *J Big Data*, vol. 10, no. 1, p. 163, Oct. 2023, doi: [10.1186/s40537-023-00836-y](https://doi.org/10.1186/s40537-023-00836-y).
- [5] D. F. Coimbra, “Hybrid Extractive/Abstractive Summarization Using Pre-Trained Sequence-to-Sequence Models,” *M.S. thesis*, Instituto Superior Técnico, Universidade de Lisboa, Lisbon, Portugal, 2020.
- [6] L. Phan, H. Tran, H. Nguyen, and T. H. Trinh, “ViT5: Pretrained Text-to-Text Transformer for Vietnamese Language Generation,” in *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies: Student Research Workshop*, D. Ippolito, L. H. Li, M. L. Pacheco, D. Chen, and N. Xue, Eds., Hybrid: Seattle, Washington + Online: Association for Computational Linguistics, Jul. 2022, pp. 136–142. doi: [10.18653/v1/2022.naacl-srw.18](https://doi.org/10.18653/v1/2022.naacl-srw.18).

- [7] N. L. Tran, D. Le, and D. Q. Nguyen, “BARTpho: Pre-trained Sequence-to-Sequence Models for Vietnamese,” in *Proc. Interspeech 2022*, 2022, pp. 1751–1755. doi: [10.21437/Interspeech.2022-10177](https://doi.org/10.21437/Interspeech.2022-10177).
- [8] D. S., S. N., J. Andrew, and M. Mazzara, “Unified extractive-abstractive summarization: a hybrid approach utilizing BERT and transformer models for enhanced document summarization,” *PeerJ Computer Science*, vol. 10, p. e2424, Nov. 2024, doi: [10.7717/peerj-cs.2424](https://doi.org/10.7717/peerj-cs.2424).
- [9] D. Q. Nguyen and A. Tuan Nguyen, “PhoBERT: Pre-trained language models for Vietnamese,” in *Findings of the Association for Computational Linguistics: EMNLP 2020*, T. Cohn, Y. He, and Y. Liu, Eds., Online: Association for Computational Linguistics, Nov. 2020, pp. 1037–1042. doi: [10.18653/v1/2020.findings-emnlp.92](https://doi.org/10.18653/v1/2020.findings-emnlp.92).
- [10] A. Vaswani *et al.*, “Attention is All you Need,” in *Advances in Neural Information Processing Systems*, vol. 30, Curran Associates, Inc., 2017. Accessed: Jul. 08, 2026. [Online]. Available: <https://proceedings.neurips.cc/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>
- [11] C. Raffel *et al.*, “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer,” *Journal of Machine Learning Research*, vol. 21, no. 140, pp. 1–67, 2020. [Online]. Available: <https://jmlr.org/papers/v21/20-074.html>.
- [12] L. Xue *et al.*, “mT5: A Massively Multilingual Pre-trained Text-to-Text Transformer,” in *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, K. Toutanova, A. Rumshisky, L. Zettlemoyer, D. Hakkani-Tur, I. Beltagy, S. Bethard, R. Cotterell, T. Chakraborty, and Y. Zhou, Eds., Online: Association for Computational Linguistics, Jun. 2021, pp. 483–498. doi: [10.18653/v1/2021.naacl-main.41](https://doi.org/10.18653/v1/2021.naacl-main.41).

- [13] J. Zhang, Y. Zhao, M. Saleh, and P. J. Liu, “PEGASUS: Pre-training with Extracted Gap-sentences for Abstractive Summarization,” in *Proceedings of the 37th International Conference on Machine Learning (ICML 2020)*, PMLR, Jul. 2020, vol. 119, pp. 11328–11339. [Online]. Available: <https://proceedings.mlr.press/v119/zhang20ae.html>.
- [14] C.-Y. Lin, “ROUGE: A Package for Automatic Evaluation of Summaries,” in *Text Summarization Branches Out*, Barcelona, Spain: Association for Computational Linguistics, Jul. 2004, pp. 74–81. Accessed: Jul. 08, 2026. [Online]. Available: <https://aclanthology.org/W04-1013/>
- [15] V.-H. Nguyen, T.-C. Nguyen, M.-T. Nguyen, and N. X. Hoai, “VNDS: A Vietnamese Dataset for Summarization,” in *2019 6th NAFOSTED Conference on Information and Computer Science (NICS)*, Hanoi, Vietnam: IEEE, Dec. 2019, pp. 375–380. doi: [10.1109/NICS48868.2019.9023886](https://doi.org/10.1109/NICS48868.2019.9023886).