

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
PHÂN HIỆU TẠI TP. HỒ CHÍ MINH
BỘ MÔN CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN TỐT NGHIỆP

**ĐỀ TÀI: NGHIÊN CỨU VÀ XÂY DỰNG HỆ THỐNG TÓM TẮT VĂN BẢN
TỰ ĐỘNG TIẾNG VIỆT SỬ DỤNG CÁC MÔ HÌNH TRANSFORMER VÀ
KỸ THUẬT XỬ LÝ NGÔN NGỮ TỰ NHIÊN**

Giảng viên hướng dẫn: THS. TRẦN PHONG NHÃ

Sinh viên thực hiện: NGUYỄN HỮU TOÀN

Lớp : CÔNG NGHỆ THÔNG TIN

Khoá : 63

Tp. Hồ Chí Minh, năm 2026

TRƯỜNG ĐẠI HỌC GIAO THÔNG VẬN TẢI
PHÂN HIỆU TẠI TP. HỒ CHÍ MINH
BỘ MÔN CÔNG NGHỆ THÔNG TIN



BÁO CÁO ĐỒ ÁN TỐT NGHIỆP

**ĐỀ TÀI: NGHIÊN CỨU VÀ XÂY DỰNG HỆ THỐNG TÓM TẮT VĂN BẢN
TỰ ĐỘNG TIẾNG VIỆT SỬ DỤNG CÁC MÔ HÌNH TRANSFORMER VÀ
KỸ THUẬT XỬ LÝ NGÔN NGỮ TỰ NHIÊN**

Giảng viên hướng dẫn: THS. TRẦN PHONG NHÃ

Sinh viên thực hiện: NGUYỄN HỮU TOÀN

Lớp : CÔNG NGHỆ THÔNG TIN

Khoá : 63

Tp. Hồ Chí Minh, năm 2026

NHIỆM VỤ THIẾT KẾ TỐT NGHIỆP
BỘ MÔN: CÔNG NGHỆ THÔNG TIN

Mã sinh viên: 6351071071

Họ tên SV: Nguyễn Hữu Toàn

Khóa: 63

Lớp: Công nghệ thông tin

1. Tên đề tài

Nghiên cứu và xây dựng hệ thống tóm tắt văn bản tự động Tiếng Việt sử dụng các mô hình Transformer và kỹ thuật xử lý ngôn ngữ tự nhiên.

2. Mục đích thực hiện

Sự gia tăng nhanh chóng của lượng thông tin số trong các lĩnh vực báo chí, giáo dục, nghiên cứu khoa học và quản lý dữ liệu đặt ra nhu cầu khai thác nội dung văn bản một cách hiệu quả. Việc đọc và xử lý thủ công các tài liệu có độ dài lớn thường tiêu tốn nhiều thời gian, gây khó khăn cho quá trình tiếp cận và tổng hợp thông tin. Trong bối cảnh đó, tóm tắt văn bản tự động được xem là một hướng nghiên cứu quan trọng nhằm hỗ trợ người dùng nhanh chóng nắm bắt các nội dung chính của tài liệu.

Đề tài được thực hiện với mục tiêu nghiên cứu các phương pháp tóm tắt văn bản hiện đại, đặc biệt là các mô hình Transformer, đồng thời xây dựng một hệ thống cho phép tạo bản tóm tắt tự động đối với văn bản tiếng Việt. Hệ thống hỗ trợ so sánh kết quả giữa nhiều phương pháp khác nhau, từ các kỹ thuật trích xuất truyền thống đến các mô hình sinh ngôn ngữ dựa trên học sâu.

Bên cạnh việc xây dựng hệ thống, đề tài còn tập trung đánh giá chất lượng tóm tắt thông qua các bộ chỉ số phổ biến trong lĩnh vực xử lý ngôn ngữ tự nhiên nhằm xác định ưu điểm, hạn chế và khả năng ứng dụng của từng phương pháp đối với dữ liệu tiếng Việt.

3. Nội dung và phạm vi đề tài

Đề tài tập trung nghiên cứu và triển khai một hệ thống tóm tắt văn bản tự động dành cho tiếng Việt. Người dùng có thể nhập nội dung văn bản hoặc lựa chọn tài liệu cần xử lý, sau đó hệ thống thực hiện các bước tiền xử lý, áp dụng thuật toán hoặc mô hình phù hợp để sinh ra bản tóm tắt.

Hệ thống hỗ trợ nhiều phương pháp khác nhau bao gồm các kỹ thuật tóm tắt trích xuất như TextRank, LexRank, LSA và các mô hình tóm tắt sinh văn bản như ViT5, mT5 và BARTPho. Kết quả sinh ra được lưu trữ và hiển thị trực quan nhằm hỗ trợ người dùng so sánh chất lượng giữa các phương pháp.

Trong phạm vi nghiên cứu, đề tài sử dụng bộ dữ liệu tiếng Việt phục vụ cho bài toán tóm tắt văn bản, thực hiện huấn luyện và đánh giá các mô hình Transformer trên dữ liệu có sẵn. Các chỉ số đánh giá như ROUGE và BERTScore được sử dụng để đo lường mức độ tương đồng giữa bản tóm tắt sinh ra và bản tóm tắt tham chiếu.

Đề tài tập trung vào việc nghiên cứu, triển khai và đánh giá các phương pháp tóm tắt văn bản hiện có. Việc phát triển kiến trúc Transformer mới hoặc xây dựng mô hình ngôn ngữ từ đầu không nằm trong phạm vi nghiên cứu của đề tài.

4. Công nghệ, công cụ và ngôn ngữ lập trình

Hệ thống được phát triển chủ yếu bằng ngôn ngữ Python. Phần backend được xây dựng bằng FastAPI nhằm cung cấp các dịch vụ xử lý và suy luận mô hình. Giao diện người dùng được phát triển bằng React kết hợp với Tailwind CSS để hỗ trợ thao tác và trực quan hóa kết quả.

Đề tài sử dụng thư viện Hugging Face Transformers để triển khai các mô hình Transformer, cùng với các thư viện xử lý dữ liệu và đánh giá mô hình như PyTorch, Pandas, NumPy, ROUGE và BERTScore.

Các công cụ hỗ trợ phát triển gồm: Visual Studio Code, Git, GitHub.

5. Các kết quả chính dự kiến sẽ đạt được và ứng dụng

Kết quả dự kiến của đề tài là xây dựng được một hệ thống tóm tắt văn bản tự động tiếng Việt có khả năng hỗ trợ nhiều phương pháp tóm tắt khác nhau trong cùng một môi trường làm việc thống nhất. Hệ thống cho phép thực hiện tóm tắt văn bản, so sánh kết quả giữa các mô hình và trực quan hóa các chỉ số đánh giá phục vụ nghiên cứu.

Đề tài đồng thời xây dựng quy trình đánh giá chất lượng tóm tắt dựa trên các độ đo phổ biến trong lĩnh vực xử lý ngôn ngữ tự nhiên, từ đó cung cấp cơ sở thực nghiệm cho việc phân tích và lựa chọn mô hình phù hợp đối với dữ liệu tiếng Việt.

Về mặt ứng dụng, hệ thống có thể hỗ trợ sinh viên, giảng viên, nhà nghiên cứu và người dùng phổ thông trong việc khai thác nhanh nội dung của các tài liệu có độ dài lớn. Kết quả nghiên cứu cũng có thể được sử dụng làm nền tảng cho các hướng phát triển tiếp theo như hệ thống quản lý tài liệu thông minh, trợ lý học tập hoặc các ứng dụng khai thác tri thức từ văn bản.

6. Giáo viên và cán bộ hướng dẫn

Họ tên: ThS. Trần Phong Nhã

Đơn vị công tác: Phân hiệu Trường Đại học Giao thông Vận tải

Điện thoại: 0906 761 014

Email: tpnha@utc2.edu.vn

Ngày tháng 07 năm 2026
Trưởng BM Công nghệ Thông tin

Đã giao nhiệm vụ TKTN
Giáo viên hướng dẫn

ThS. Trần Phong Nhã

ThS. Trần Phong Nhã

Đã nhận nhiệm vụ TKTN

Sinh viên: Nguyễn Hữu Toàn

Điện thoại: 0343768815

Ký tên:

Email: 6351071071@st.utc2.edu.vn

LỜI CẢM ƠN

Em xin chân thành cảm ơn thầy ThS. Trần Phong Nhã, giảng viên Bộ môn Công nghệ Thông tin, Phân hiệu Trường Đại học Giao thông Vận tải tại Thành phố Hồ Chí Minh, đã tận tình hướng dẫn và hỗ trợ em trong suốt quá trình thực hiện đồ án tốt nghiệp.

Trong quá trình nghiên cứu đề tài “Nghiên cứu và xây dựng hệ thống tóm tắt văn bản tự động tiếng Việt sử dụng các mô hình Transformer và kỹ thuật xử lý ngôn ngữ tự nhiên”, em đã nhận được nhiều ý kiến góp ý, định hướng chuyên môn và sự động viên từ thầy. Những hướng dẫn đó đã giúp em hoàn thiện đề tài cũng như củng cố kiến thức và kỹ năng nghiên cứu của bản thân.

Do kiến thức và kinh nghiệm thực tế còn hạn chế, báo cáo khó tránh khỏi những thiếu sót. Em rất mong nhận được những ý kiến đóng góp từ quý thầy cô để tiếp tục hoàn thiện bản thân trong thời gian tới.

Kính chúc thầy ThS. Trần Phong Nhã cùng quý thầy cô luôn mạnh khỏe, hạnh phúc và thành công trong công tác giảng dạy và nghiên cứu.

Em xin chân thành cảm ơn!

NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Tp. Hồ Chí Minh, ngày tháng 06 năm 2026
Giáo viên hướng dẫn

Trần Phong Nhã

MỤC LỤC

LỜI CẢM ƠN	i
NHẬN XÉT CỦA GIÁO VIÊN HƯỚNG DẪN	ii
MỤC LỤC	iii
DANH MỤC CHỮ VIẾT TẮT	vi
BẢNG BIỂU, SƠ ĐỒ, HÌNH VẼ	viii
CHƯƠNG 1. MỞ ĐẦU	1
1.1. Giới thiệu đề tài	1
1.2. Mục tiêu đề tài	2
1.3. Mục đích nghiên cứu	2
1.4. Đối tượng nghiên cứu	3
1.5. Phạm vi nghiên cứu	4
1.6. Phương pháp nghiên cứu	4
1.7. Ý nghĩa thực tiễn của đề tài	5
1.8. Cấu trúc cuốn báo cáo đồ án	6
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT	8
2.1. Bài toán tóm tắt văn bản	8
2.2. Tóm tắt trích rút	9
2.3. Tóm tắt diễn giải	10
2.4. Đặc điểm của tiếng Việt trong xử lý ngôn ngữ tự nhiên	11
2.5. Kiến trúc Transformer	12
2.6. Các mô hình Transformer sử dụng trong đề tài	13
2.7. Các phương pháp đánh giá chất lượng tóm tắt	15

CHƯƠNG 3: PHÂN TÍCH THIẾT KẾ HỆ THỐNG	17
3.1. Mô tả bài toán nghiên cứu	17
3.2. Phân tích yêu cầu hệ thống	19
3.2.1. Yêu cầu chức năng	19
3.2.2. Yêu cầu phi chức năng	20
3.3. Thiết kế giao diện hệ thống	20
3.3.1. Giao diện trang chủ	20
3.3.2. Giao diện tóm tắt văn bản	22
3.3.3. Giao diện so sánh bản tóm tắt của các mô hình	23
3.3.4. Giao diện đánh giá kết quả	24
3.4. Phân tích và thiết kế mô hình nghiên cứu	25
3.4.1. Dữ liệu sử dụng trong nghiên cứu	25
3.4.2. Quy trình tiền xử lý dữ liệu	26
3.4.3. Quy trình huấn luyện mô hình	26
3.4.4. Quy trình suy luận và sinh tóm tắt	27
3.4.5. Đánh giá kết quả	27
3.5. Thiết kế kiến trúc hệ thống	28
3.5.1. Kiến trúc tổng thể hệ thống	28
3.5.2. Kiến trúc Frontend - Backend	28
3.5.3. Kiến trúc AI Engine	28
3.6. Các sơ đồ thiết kế hệ thống	29
3.6.1. Sơ đồ kiến trúc nghiên cứu	29
3.6.2. Sơ đồ Pipeline xử lý dữ liệu	30
3.6.3. Workflow suy luận mô hình	30

3.6.4. Biểu đồ Use Case	31
CHƯƠNG 4: CÀI ĐẶT THỰC NGHIỆM VÀ ĐÁNH GIÁ	34
4.1. Môi trường và công nghệ cài đặt	34
4.1.1. Cấu hình phần cứng hệ thống	34
4.1.2. Môi trường công nghệ phần mềm và thư viện hỗ trợ	34
4.2. Cơ chế hoạt động của Pipeline Tóm tắt Lại	35
4.3. Cài đặt mô hình và thiết kế thực nghiệm	36
4.3.1. Phân tích thống kê tập dữ liệu VietNews	36
4.3.2. Thiết kế kịch bản thực nghiệm và Các độ đo đánh giá	36
4.4. Đánh giá hệ thống và phân tích kết quả đạt được	38
4.4.1. Số liệu benchmark tóm tắt văn bản	38
4.4.2. Nhận xét và phân tích chuyên sâu hiệu năng tóm tắt	39
4.5. Khó khăn và hạn chế trong quá trình triển khai thực nghiệm	40
KẾT QUẢ VÀ KIẾN NGHỊ	42
1. Kết quả đạt được	42
1.1. Về mặt lý thuyết	42
1.2. Về mặt thực nghiệm	42
2. Hạn chế còn tồn đọng	43
3. Hướng phát triển trong tương lai	43
TÀI LIỆU THAM KHẢO	45

DANH MỤC CHỮ VIẾT TẮT

STT	Từ viết tắt	Ý nghĩa
1	AI	Artificial Intelligence
2	API	Application Programming Interface
3	BLEU	Bilingual Evaluation Understudy
4	BPE	Byte-Pair Encoding
5	CPU	Central Processing Unit
6	DB	Database
7	EVN	Tập đoàn Điện lực Việt Nam
8	GPU	Graphics Processing Unit
9	HTML	HyperText Markup Language
10	JSON	JavaScript Object Notation
11	LLM	Large Language Model
12	LSA	Latent Semantic Analysis
13	LSTM	Long Short-Term Memory
14	mT5	Massively Multilingual T5
15	NDCG	Normalized Discounted Cumulative Gain
16	NFC	Normalization Form C
17	NLP	Natural Language Processing

18	RAG	Retrieval-Augmented Generation
19	RAM	Random Access Memory
20	RNN	Recurrent Neural Network
21	ROUGE	Recall-Oriented Understudy for Gisting Evaluation
22	SOTA	State-of-the-Art
23	SPA	Single Page Application
24	SVD	Singular Value Decomposition
25	TF-IDF	Term Frequency-Inverse Document Frequency
26	TPU	Tensor Processing Unit
27	ViT5	Vietnamese Text-to-Text Transfer Transformer
28	VRAM	Video Random Access Memory

BẢNG BIỂU, SƠ ĐỒ, HÌNH VẼ

Hình 3.1. Giao diện trang chủ	21
Hình 3.2. Giao diện tóm tắt văn bản	23
Hình 3.3. Giao diện chọn các mẫu thử để xem văn bản tóm tắt	23
Hình 3.4. Giao diện hiển thị kết quả tóm tắt	24
Hình 3.5. Giao diện đánh giá kết quả	25
Hình 3.6. Sơ đồ kiến trúc nghiên cứu	29
Hình 3.7. Sơ đồ pipeline xử lý dữ liệu	30
Hình 3.8. Sơ đồ tuần tự suy luận của mô hình	31
Hình 3.9. Sơ đồ Use case tổng quát	31
Hình 3.10. Sơ đồ Use case tóm tắt văn bản	32
Hình 3.11. Sơ đồ Use case chatbot RAG	32
Hình 3.12. Sơ đồ Use case thống kê giám sát	33
Hình 4.1. Sơ đồ pipeline tóm tắt Lai hai giai đoạn	35
Bảng 4.1: Thống kê chi tiết tập dữ liệu VietNews	36
Hình 4.2. Kết quả thực nghiệm tóm tắt văn bản trên 1.000 mẫu VietNews	38

CHƯƠNG 1. MỞ ĐẦU

1.1. Giới thiệu đề tài

Trong những năm gần đây, sự phát triển mạnh mẽ của công nghệ số đã làm gia tăng đáng kể lượng dữ liệu văn bản được tạo ra và lưu trữ dưới nhiều hình thức khác nhau như báo điện tử, tài liệu học tập, báo cáo chuyên môn, tài liệu nghiên cứu khoa học và văn bản hành chính. Khối lượng thông tin ngày càng lớn mang lại nhiều cơ hội khai thác tri thức, nhưng đồng thời cũng đặt ra thách thức cho người dùng trong việc tiếp cận, chọn lọc và nắm bắt nhanh những nội dung quan trọng.

Đối với các tài liệu có độ dài lớn, người đọc thường phải dành nhiều thời gian để đọc toàn bộ nội dung trước khi xác định được các ý chính cần quan tâm. Điều này không chỉ làm giảm hiệu quả tiếp nhận thông tin mà còn gây khó khăn trong quá trình học tập, nghiên cứu và làm việc. Vì vậy, nhu cầu xây dựng các hệ thống có khả năng tự động rút gọn nội dung văn bản, đồng thời vẫn bảo đảm giữ được các thông tin cốt lõi ngày càng trở nên cần thiết.

Cùng với sự phát triển của lĩnh vực xử lý ngôn ngữ tự nhiên, nhiều phương pháp tóm tắt văn bản đã được nghiên cứu và ứng dụng trong thực tế. Các phương pháp truyền thống như TextRank, LexRank hay LSA có ưu điểm về tính đơn giản và khả năng triển khai nhanh, tuy nhiên chất lượng tóm tắt vẫn còn hạn chế khi phải xử lý các văn bản có cấu trúc phức tạp. Trong khi đó, sự xuất hiện của kiến trúc Transformer đã mở ra nhiều hướng tiếp cận mới cho bài toán tóm tắt văn bản. Các mô hình như ViT5, mT5 hay BARTPho có khả năng học ngữ nghĩa sâu của văn bản, từ đó tạo ra các bản tóm tắt tự nhiên và giàu thông tin hơn.

Xuất phát từ thực tế đó đề tài “Nghiên cứu và xây dựng hệ thống tóm tắt văn bản tự động tiếng Việt sử dụng các mô hình Transformer và kỹ thuật xử lý ngôn ngữ tự nhiên” được thực hiện nhằm nghiên cứu, triển khai và đánh giá các phương pháp tóm tắt văn bản trên dữ liệu tiếng Việt. Hệ thống được xây dựng không chỉ hỗ trợ sinh bản tóm tắt tự động mà còn cho phép so sánh kết quả giữa nhiều phương pháp khác nhau, góp phần hỗ trợ người dùng khai thác thông tin hiệu quả hơn từ các tài liệu văn bản có độ dài lớn.

1.2. Mục tiêu đề tài

Đề tài hướng đến việc nghiên cứu các phương pháp tóm tắt văn bản tự động và xây dựng một hệ thống hỗ trợ tóm tắt văn bản tiếng Việt dựa trên các kỹ thuật xử lý ngôn ngữ tự nhiên và mô hình Transformer.

Về mặt lý thuyết: đề tài sẽ tập trung tìm hiểu các kiến thức liên quan đến xử lý ngôn ngữ tự nhiên, tóm tắt văn bản, các phương pháp tóm tắt trích rút và tóm tắt diễn giải, kiến trúc Transformer cùng các mô hình tiêu biểu như ViT5, mT5 và BARTPho. Song song, đề tài cũng nghiên cứu về các phương pháp đánh giá chất lượng tóm tắt thông qua các độ đo phổ biến như ROUGE và BERTScore nhằm mục đích phục vụ quá trình thực nghiệm và so sánh kết quả.

Đề tài xây dựng một hệ thống cho phép người dùng nhập văn bản và thực hiện tóm tắt bằng nhiều phương pháp khác nhau. Hệ thống hỗ trợ các thuật toán TextRank, LexRank, LSA và các mô hình Transformer được huấn luyện cho bài toán tóm tắt tiếng Việt. Kết quả tóm tắt được hiển thị trực quan lên giao diện website và cho phép đánh giá, so sánh chất lượng giữa các phương pháp trên cùng một tập dữ liệu.

Đề tài hướng đến việc xây dựng một môi trường thử nghiệm thống nhất phục vụ nghiên cứu và đánh giá các phương pháp tóm tắt văn bản tiếng Việt. Từ quá trình triển khai và thực nghiệm, đề tài mong muốn xác định những ưu điểm, nhược điểm và khả năng ứng dụng thực tế của từng phương pháp, từ đó đề xuất hướng lựa chọn phù hợp đối với các bài toán tóm tắt văn bản trong môi trường tiếng Việt.

1.3. Mục đích nghiên cứu

Mục đích của đề tài là nghiên cứu và ứng dụng các kỹ thuật xử lý ngôn ngữ tự nhiên hiện đại vào bài toán tóm tắt văn bản tiếng Việt, từ đó xây dựng một hệ thống có khả năng hỗ trợ người dùng tiếp cận nhanh nội dung quan trọng của các tài liệu có độ dài lớn. Thông qua việc khảo sát và triển khai nhiều phương pháp khác nhau dự án hướng đến việc đánh giá khả năng áp dụng của các mô hình tóm tắt văn bản trong điều kiện dữ liệu tiếng Việt.

Bên cạnh việc nghiên cứu các phương pháp tóm tắt truyền thống và các mô hình Transformer, dự án còn nhằm mục đích xây dựng một môi trường thực nghiệm cho phép so sánh kết quả giữa nhiều thuật toán trên cùng một tập dữ liệu. Điều này giúp làm rõ sự khác biệt về chất lượng tóm tắt, hiệu quả xử lý văn bản tiếng Việt của từng phương pháp.

Dự án còn hướng đến việc tạo ra một công cụ hỗ trợ khai thác thông tin từ văn bản. Hệ thống có thể hỗ trợ một phần nhỏ để sinh viên, giảng viên, nhà nghiên cứu và người dùng phổ thông trong việc tiếp cận nhanh các nội dung quan trọng của tài liệu, góp phần giảm thời gian đọc và nâng cao hiệu quả tiếp nhận thông tin.

Từ quá trình nghiên cứu, xây dựng và đánh giá hệ thống này đề tài cũng góp phần làm rõ những thuận lợi và bất lợi khi áp dụng các mô hình Transformer vào bài toán tóm tắt văn bản tiếng Việt, từ đó tạo cơ sở cho các nghiên cứu và hướng phát triển lớn hơn trong lĩnh vực xử lý ngôn ngữ tự nhiên.

1.4. Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài là bài toán tóm tắt văn bản tự động trong lĩnh vực xử lý ngôn ngữ tự nhiên, tập trung vào dữ liệu văn bản tiếng Việt. Nội dung nghiên cứu hướng đến việc tìm hiểu các phương pháp và mô hình có khả năng rút gọn văn bản tiếng Việt nhưng vẫn giữ được những thông tin quan trọng và ý nghĩa chính của tài liệu gốc.

Phương pháp nghiên cứu: đề tài tập trung khảo sát hai hướng tiếp cận chính là tóm tắt trích rút và tóm tắt diễn giải. Các thuật toán TextRank, LexRank và LSA được lựa chọn đại diện cho nhóm phương pháp trích rút, còn các mô hình ViT5, mT5 và BARTPho đại diện cho nhóm phương pháp tóm tắt diễn giải dựa trên kiến trúc Transformer.

Công nghệ sử dụng: đề tài nghiên cứu các kỹ thuật xử lý ngôn ngữ tự nhiên, kiến trúc Transformer, quy trình huấn luyện và suy luận mô hình học sâu, các phương pháp đánh giá chất lượng tóm tắt và các công nghệ phục vụ quá trình xây dựng hệ thống như FastAPI, React và các thư viện học máy liên quan đến việc tóm tắt.

Đối tượng nghiên cứu cũng bao gồm hệ thống phần mềm được xây dựng trong đề tài. Hệ thống có chức năng nhập văn bản đầu vào, thực hiện tóm tắt bằng nhiều phương pháp khác nhau, lưu trữ kết quả vào database và hỗ trợ đánh giá, so sánh chất lượng tóm

tất. Đây là cơ sở để tiến hành các thực nghiệm và đánh giá hiệu quả của các phương pháp được nghiên cứu trong đề tài.

1.5. Phạm vi nghiên cứu

Đề tài tập trung nghiên cứu và xây dựng hệ thống tóm tắt văn bản tự động dành cho dữ liệu tiếng Việt dựa trên các kỹ thuật xử lý ngôn ngữ tự nhiên và mô hình Transformer. Phạm vi nghiên cứu xoay quanh việc khảo sát, triển khai và đánh giá các phương pháp tóm tắt văn bản trên tập dữ liệu tiếng Việt, từ đó xây dựng một hệ thống hỗ trợ thực hiện và so sánh kết quả tóm tắt giữa nhiều phương pháp khác nhau.

Dữ liệu: đề tài sử dụng các bộ dữ liệu văn bản tiếng Việt phục vụ cho bài toán tóm tắt, tập trung vào các văn bản thuộc lĩnh vực tin tức và các nguồn dữ liệu phù hợp cho quá trình huấn luyện, kiểm thử và đánh giá mô hình. Các loại dữ liệu đa phương tiện như hình ảnh, âm thanh hoặc video không thuộc phạm vi nghiên cứu của đề tài.

Mô hình và thuật toán: đề tài nghiên cứu các phương pháp tóm tắt trích rút gồm TextRank, LexRank và LSA, song song cũng triển khai các mô hình Transformer tiêu biểu như ViT5, mT5 và BARTPho cho bài toán tóm tắt diễn giải. Việc phát triển một kiến trúc Transformer hoàn toàn mới hoặc xây dựng mô hình ngôn ngữ từ đầu không nằm trong phạm vi thực hiện của đề tài này.

Hệ thống: đề tài chỉ tập trung xây dựng một ứng dụng hỗ trợ tóm tắt văn bản, đánh giá chất lượng tóm tắt và trực quan hóa kết quả thực nghiệm. Các nội dung liên quan đến triển khai hệ thống ở quy mô lớn, tối ưu hạ tầng phân tán hoặc cung cấp dịch vụ thương mại chưa được xem xét trong phạm vi nghiên cứu hiện tại.

1.6. Phương pháp nghiên cứu

Để đạt được các mục tiêu đã đề ra, đề tài kết hợp giữa phương pháp nghiên cứu lý thuyết và phương pháp thực nghiệm.

Ban đầu làm đề tài sẽ tiến hành thu thập, phân tích và tổng hợp các tài liệu, bài báo khoa học, công trình nghiên cứu liên quan đến lĩnh vực xử lý ngôn ngữ tự nhiên, bài toán tóm tắt văn bản, kiến trúc Transformer và các phương pháp đánh giá chất lượng tóm tắt.

Sau đó đề tài áp dụng phương pháp nghiên cứu thực nghiệm thông qua việc triển khai các thuật toán và mô hình tóm tắt văn bản trên dữ liệu tiếng Việt. Các phương pháp TextRank, LexRank, LSA, ViT5, mT5 và BARTPho được xây dựng, huấn luyện và tinh chỉnh phù hợp với yêu cầu của bài toán nhằm đánh giá khả năng xử lý và chất lượng tóm tắt của từng phương pháp.

Cùng lúc đó đề tài cũng sẽ sử dụng phương pháp so sánh và đánh giá để phân tích hiệu quả của các mô hình. Các chỉ số như ROUGE và BERTScore được sử dụng để đo lường mức độ tương đồng giữa bản tóm tắt được sinh ra và bản tóm tắt tham chiếu. Kết quả thực nghiệm được tổng hợp, trực quan hóa và phân tích nhằm đưa ra nhận xét khách quan về ưu điểm, hạn chế cũng như khả năng ứng dụng của từng phương pháp.

Tổng kết lại đề tài sẽ áp dụng phương pháp thiết kế và phát triển phần mềm để xây dựng hệ thống tóm tắt văn bản hoàn chỉnh. Hệ thống được triển khai theo kiến trúc phù hợp, tích hợp các mô hình xử lý ngôn ngữ tự nhiên, giao diện người dùng và các chức năng hỗ trợ đánh giá kết quả, tạo môi trường thuận lợi cho việc nghiên cứu và thực nghiệm.

1.7. Ý nghĩa thực tiễn của đề tài

Trong bối cảnh lượng thông tin số gia tăng việc tiếp cận và khai thác hiệu quả nội dung từ các tài liệu văn bản trở thành nhu cầu thiết thực đối với nhiều đối tượng người dùng. Đề tài góp phần ứng dụng các thành tựu của lĩnh vực xử lý ngôn ngữ tự nhiên vào giải quyết bài toán tóm tắt văn bản tiếng Việt, hỗ trợ người dùng nhanh chóng nắm bắt những nội dung quan trọng mà không cần đọc toàn bộ tài liệu.

Hệ thống được xây dựng có thể hỗ trợ một phần nhỏ cho sinh viên, giảng viên, nhà nghiên cứu và nhân viên văn phòng trong quá trình học tập, nghiên cứu và làm việc. Thông qua khả năng tự động tạo bản tóm tắt, hệ thống giúp giảm thời gian đọc, hỗ trợ tra cứu thông tin nhanh hơn và tăng hiệu quả tiếp nhận tri thức từ các nguồn dữ liệu có độ dài vừa phải.

Không chỉ cung cấp một ít giá trị ứng dụng thực tế đề tài còn cung cấp môi trường thực nghiệm phục vụ việc nghiên cứu và đánh giá các phương pháp tóm tắt văn bản khác

nhau trên dữ liệu tiếng Việt. Kết quả nghiên cứu có thể được sử dụng làm tài liệu tham khảo cho các nghiên cứu tiếp theo trong lĩnh vực xử lý ngôn ngữ tự nhiên, đồng thời tạo nền tảng cho việc phát triển các hệ thống quản lý tài liệu thông minh, trợ lý học tập hoặc các ứng dụng khai thác tri thức từ văn bản trong tương lai.

Từ việc xây dựng và đánh giá nhiều phương pháp tóm tắt trong cùng một hệ thống cũng sẽ giúp làm rõ khả năng ứng dụng của các mô hình Transformer đối với tiếng Việt, góp phần thúc đẩy việc nghiên cứu và triển khai các giải pháp trí tuệ nhân tạo trong thực tiễn.

1.8. Cấu trúc cuốn báo cáo đồ án

Nội dung báo cáo được tổ chức thành bốn chương chính, trình bày theo trình tự từ cơ sở hình thành đề tài đến quá trình triển khai, đánh giá và kết luận kết quả nghiên cứu.

Chương 1: Mở đầu. Chương này trình bày bối cảnh thực hiện đề tài, mục tiêu nghiên cứu, mục đích nghiên cứu, đối tượng nghiên cứu, phạm vi nghiên cứu, phương pháp nghiên cứu, ý nghĩa thực tiễn của đề tài và cấu trúc tổng thể của báo cáo.

Chương 2: Cơ sở lý thuyết. Chương này giới thiệu các kiến thức nền tảng liên quan đến bài toán tóm tắt văn bản, các phương pháp tóm tắt trích rút và tóm tắt diễn giải, kiến trúc Transformer, các mô hình được sử dụng trong đề tài, các nghiên cứu liên quan cũng như những công nghệ và công cụ phục vụ quá trình xây dựng hệ thống.

Chương 3: Phân tích và thiết kế hệ thống. Chương này trình bày bài toán nghiên cứu, yêu cầu hệ thống, kiến trúc tổng thể, quy trình xử lý dữ liệu, thiết kế các thành phần chức năng, thiết kế cơ sở dữ liệu và các sơ đồ mô tả hoạt động của hệ thống.

Chương 4: Xây dựng, thực nghiệm và đánh giá hệ thống. Chương này mô tả quá trình triển khai hệ thống, xây dựng các mô hình tóm tắt văn bản, thực hiện huấn luyện và đánh giá trên dữ liệu thực nghiệm. Đồng thời, chương cũng trình

bày kết quả thu được, phân tích hiệu quả của từng phương pháp và so sánh chất lượng tóm tắt thông qua các chỉ số đánh giá.

Phần cuối sẽ là kết luận và hướng phát triển. Phần này tổng kết những kết quả đạt được trong quá trình thực hiện đề tài, nêu ra các hạn chế còn tồn tại và đề xuất những hướng nghiên cứu, phát triển có thể thực hiện trong tương lai nhằm nâng cao hiệu quả của hệ thống.

Chương 1 này đã trình bày tổng quan về đề tài nghiên cứu, bao gồm bối cảnh thực tiễn, lý do lựa chọn đề tài cũng như những vấn đề đặt ra đối với bài toán tóm tắt văn bản tự động tiếng Việt. Chương cũng xác định rõ mục tiêu, mục đích nghiên cứu, đối tượng nghiên cứu, phạm vi thực hiện và các phương pháp được sử dụng trong quá trình triển khai đề tài. Đồng thời cũng nêu ra ý nghĩa thực tiễn của hệ thống và cấu trúc tổng thể của báo cáo cũng đã được giới thiệu nhằm giúp người đọc có cái nhìn khái quát về nội dung nghiên cứu.

Những nội dung được trình bày trong chương này là cơ sở định hướng cho toàn bộ quá trình thực hiện đề tài. Trên nền tảng đó, Chương 2 sẽ tập trung trình bày các cơ sở lý thuyết, các nghiên cứu liên quan, cùng những công nghệ, mô hình và phương pháp được sử dụng để xây dựng hệ thống tóm tắt văn bản tự động tiếng Việt.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT

Chương này sẽ cung cấp nền tảng lý thuyết và phân tích các nghiên cứu liên quan làm cơ sở cho việc phát triển hệ thống tóm tắt văn bản tự động. Nội dung chương tập trung vào phân tích các phương pháp tóm tắt văn bản như: Extractive, Abstractive, Hybrid, đặc trưng của ngôn ngữ tiếng Việt trong xử lý ngôn ngữ tự nhiên. Qua đó, trình bày chi tiết về các công nghệ cốt lõi được lựa chọn cho đề tài như mô hình Transformer ViT5, BARTpho và kỹ thuật Retrieval-Augmented Generation.

2.1. Bài toán tóm tắt văn bản

Tóm tắt văn bản tự động là một bài toán cốt lõi trong lĩnh vực xử lý ngôn ngữ tự nhiên, được định nghĩa là quá trình tự động rút gọn một hoặc nhiều văn bản gốc để tạo ra một phiên bản ngắn gọn, súc tích nhưng vẫn phải đảm bảo giữ lại đầy đủ các thông tin, ý chính và chủ đề quan trọng nhất của văn bản ban đầu [10, 1]. Trong thời đại kỹ thuật số hiện nay, khi khối lượng dữ liệu văn bản và thông tin trên internet bùng nổ mạnh mẽ, bài toán tóm tắt văn bản đóng vai trò vô cùng thiết yếu trong việc khai thác thông tin. Nó giúp con người tiết kiệm đáng kể thời gian đọc hiểu, loại bỏ các thông tin dư thừa và nhanh chóng nắm bắt được cốt lõi của vấn đề [7, 8]. Nhờ đó, quá trình phân tích dữ liệu, tra cứu tài liệu và đưa ra quyết định được tối ưu hóa một cách triệt để.

Trên thực tế, tóm tắt văn bản tự động đã và đang được ứng dụng rộng rãi trong rất nhiều lĩnh vực và hệ thống khác nhau. Điển hình như trong lĩnh vực báo chí, các mô hình tóm tắt giúp tổng hợp tự động các bản tin hàng ngày hoặc gom cụm các sự kiện tin tức thời sự nổi bật [1]. Trong lĩnh vực học thuật và nghiên cứu, nó được sử dụng để tóm lược các tài liệu khoa học dài, giúp các nhà nghiên cứu nhanh chóng đánh giá được sự phù hợp của một bài báo [7]. Tóm tắt văn bản còn được ứng dụng mạnh mẽ trong việc trích xuất thông tin từ hồ sơ pháp lý, tóm tắt chuỗi email, tổng hợp ý kiến đánh giá của khách hàng trên mạng xã hội, hoặc thu gọn nội dung các cuộc họp [1].

Về định hướng nghiên cứu hiện nay, các học giả trên thế giới đang dần chuyển dịch từ việc chỉ tập trung vào các phương pháp thống kê và trích xuất đơn thuần sang việc ứng dụng các mô hình học sâu để thực hiện tóm tắt diễn giải [10,1]. Hơn thế nữa, các nghiên cứu gần đây đang đẩy mạnh hướng tiếp cận lai, kết hợp sức mạnh của cả hai kỹ

thuật trích rút và diễn giải để giải quyết bài toán với các tài liệu siêu dài, nhằm khắc phục giới hạn về tài nguyên phần cứng và cửa sổ độ dài của các mô hình ngôn ngữ lớn [7]. Đối với đề tài này, bài toán tóm tắt văn bản không chỉ mang ý nghĩa lý thuyết về mặt tiếp cận đa mô hình trong NLP, mà còn mang giá trị thực tiễn sâu sắc trong việc xây dựng một hệ thống xử lý tài liệu thông minh, giúp số hóa và tự động hóa quy trình khai thác tri thức đặc thù cho ngôn ngữ tiếng Việt.

2.2. Tóm tắt trích rút

Tóm tắt trích rút là một hướng tiếp cận truyền thống nhưng cực kỳ hiệu quả trong bài toán tóm tắt văn bản, được định nghĩa là quá trình xác định, đánh giá và trích xuất nguyên văn các đoạn văn hoặc các câu quan trọng nhất từ tài liệu gốc để ghép nối lại thành một bản tóm tắt hoàn chỉnh [10]. Về nguyên lý hoạt động cơ bản, phương pháp này thường quy bài toán về dạng phân loại nhị phân hoặc xếp hạng. Hệ thống sẽ chia nhỏ văn bản thành các đơn vị cơ bản thường là câu, sau đó tiến hành phân tích các đặc trưng thống kê, cú pháp, ngữ nghĩa của từng câu để tính toán điểm số về mức độ quan trọng [7, 11].

Quy trình lựa chọn câu quan trọng thường trải qua ba bước cốt lõi: biểu diễn trung gian cho văn bản, tính toán điểm số câu, và cuối cùng là trích xuất. Ở bước tính điểm, các phương pháp phổ biến bao gồm việc sử dụng các độ đo thống kê như tần suất từ TF-IDF, vị trí của câu trong đoạn, hoặc độ dài của câu [18]. Nâng cao hơn, các phương pháp dựa trên đồ thị như TextRank hay LexRank mô hình hóa văn bản thành một mạng lưới, trong đó mỗi câu là một đỉnh và độ tương đồng ngữ nghĩa giữa các câu là các cạnh nối. Thuật toán sẽ đánh giá tầm quan trọng của một câu dựa trên số lượng và trọng số của các kết nối trở đến nó, tương tự như nguyên lý xếp hạng trang web của thuật toán PageRank [18]. Những câu có điểm số cao nhất, vượt qua một ngưỡng nhất định, sẽ được hệ thống lựa chọn đưa vào bản tóm tắt cuối cùng.

Ưu điểm nổi bật nhất của phương pháp trích xuất là đảm bảo được độ chính xác tuyệt đối về mặt thông tin sự kiện và sự chuẩn xác về mặt ngữ pháp, do các câu được sao chép nguyên vẹn từ văn bản gốc của tác giả [10]. Phương pháp này cũng đòi hỏi ít tài nguyên tính toán hơn và thường không cần đến các bộ dữ liệu huấn luyện khổng lồ nếu sử dụng thuật toán không giám sát.

Tuy nhiên, tóm tắt trích rút mang những hạn chế chí mạng: do chỉ cắt ghép các câu rời rạc, bản tóm tắt thường thiếu tính liên kết, luồng từ vựng không tự nhiên, và đặc biệt là không có khả năng cô đọng, diễn giải hay khái quát hóa thông tin như cách bộ não con người thực hiện [1]. Hơn nữa, phương pháp này dễ dẫn đến hiện tượng lặp ý nếu tài liệu gốc chứa nhiều câu có nội dung tương đồng. Mặc dù vậy, đối với tiếng Việt, phương pháp trích rút vẫn có khả năng áp dụng rất tốt và đóng vai trò bản lề. Trong đề tài này, tóm tắt trích rút mang ý nghĩa như một bộ lọc tiền xử lý, giúp nén các tài liệu dài thành những câu cốt lõi nhất trước khi đưa qua mô hình sinh, từ đó giải quyết bài toán giới hạn bộ nhớ của các mô hình Transformer [7,11].

2.3. Tóm tắt diễn giải

Trái ngược hoàn toàn với trích xuất, tóm tắt diễn giải là một phương pháp phức tạp và tiên tiến hơn, được định nghĩa là quá trình xây dựng một biểu diễn ngữ nghĩa nội tại của văn bản gốc, từ đó tạo ra một văn bản tóm tắt hoàn toàn mới bằng các từ vựng và cấu trúc câu có thể chưa từng xuất hiện trong tài liệu ban đầu [10]. Về nguyên lý sinh văn bản, phương pháp này thường dựa trên kiến trúc mã hóa - giải mã là Encoder - Decoder. Bộ mã hóa sẽ đọc và nén toàn bộ văn bản đầu vào thành một chuỗi các vector ngữ cảnh mang thông tin ngữ nghĩa mật độ cao. Sau đó, bộ giải mã sẽ sử dụng các vector này để dự đoán và sinh ra từng từ một cách tuần tự để hình thành bản tóm tắt [10, 18] .

Sự khác biệt cốt lõi giữa phương pháp diễn giải và trích rút nằm ở khả năng hiểu và tái tạo ngôn ngữ tự nhiên. Trong khi trích rút chỉ là cắt và dán, phương pháp diễn giải giống như cách con người đọc hiểu, tiêu hóa thông tin, sau đó dùng lời văn của mình để diễn đạt lại một cách khái quát [10, 7]. Để làm được điều này, vai trò của các mô hình học sâu và đặc biệt là mạng nơ-ron hồi quy RNN, LSTM hay gần đây là kiến trúc Transformer đóng vai trò mang tính quyết định [10, 1]. Các mô hình này được tiền huấn luyện trên khối lượng dữ liệu khổng lồ, mang lại khả năng diễn đạt ngữ nghĩa cực kỳ phong phú, cho phép hệ thống viết lại, tổng quát hóa và thậm chí lồng ghép các tri thức thực tế từ bên ngoài vào bản tóm tắt [10, 11].

Ưu điểm lớn nhất của tóm tắt diễn giải là tạo ra các văn bản tự nhiên, mạch lạc, súc tích và liền mạch, có cấu trúc rất gần với ngôn ngữ của con người [1, 18]. Dù mang lại kết

quả lý tưởng, phương pháp sinh tồn tại nhiều hạn chế đáng kể. Hạn chế lớn nhất là xu hướng sinh ra thông tin sai lệch hoặc không có thật so với bản gốc - hiện tượng hallucination, do mô hình đôi khi dự đoán từ vựng dựa trên xác suất thống kê thay vì bám sát ngữ cảnh thực tế [10]. Song song các mô hình sinh thường dễ bị lặp từ hoặc lặp đoạn văn khi giải mã các chuỗi dài, đồng thời gặp khó khăn với các từ vựng nằm ngoài từ điển Out-Of-Vocabulary [10, 18]. Khi áp dụng cho tiếng Việt, thách thức càng gia tăng do sự thiếu hụt các bộ dữ liệu cặp văn bản - tóm tắt chất lượng cao để tinh chỉnh mô hình. Thêm vào đó đặc thù của tiếng Việt đòi hỏi quá trình mã hóa từ vựng tinh vi hơn, khiến việc huấn luyện mô hình tóm tắt sinh tiếng Việt trở nên cực kỳ tốn kém về mặt tài nguyên và thời gian [4]. Dù khó khăn, tóm tắt diễn giải mang ý nghĩa đặc biệt quan trọng đối với đề tài, vì nó quyết định tính chuyên nghiệp, sự tự nhiên và chất lượng đầu ra cuối cùng của hệ thống tổng hợp thông tin văn bản.

2.4. Đặc điểm của tiếng Việt trong xử lý ngôn ngữ tự nhiên

Xử lý ngôn ngữ tự nhiên cho tiếng Việt đối mặt với những rào cản đặc thù xuất phát từ hệ thống cấu trúc ngôn ngữ. Đặc trưng ngôn ngữ nổi bật nhất của tiếng Việt là tính phân tiết rời rạc, trong đó khoảng trắng không chỉ được sử dụng để phân tách các từ như trong tiếng Anh, mà còn được dùng để phân tách các âm tiết cấu tạo nên một từ [15]. Hiện tượng đa âm tiết vô cùng phổ biến trong hệ thống từ vựng tiếng Việt, với thống kê chỉ ra rằng có tới 85% các loại từ tiếng Việt được cấu tạo từ hai âm tiết trở lên [15]. Chẳng hạn, một chuỗi ký tự viết dưới dạng 6 âm tiết “Tôi là một nghiên cứu viên” thực chất chỉ tạo thành 4 từ hoàn chỉnh “Tôi / là / một / nghiên_cứu_viên” [15].

Chính đặc điểm này dẫn đến vấn đề tách từ trở thành một bước tiền xử lý mang tính sống còn đối với mọi bài toán NLP tiếng Việt, bao gồm cả tóm tắt văn bản. Nếu không có bước tách từ, các mô hình ngôn ngữ khi áp dụng thuật toán mã hóa BPE sẽ cắt trực tiếp vào cấp độ âm tiết [15]. Điều này dẫn đến vấn đề nhập nhằng ngữ nghĩa vô cùng nghiêm trọng. Khi một từ ghép bị bẻ gãy thành các âm tiết độc lập, mô hình học máy sẽ gặp khó khăn trong việc nắm bắt ý nghĩa toàn cục của từ đó, dẫn đến việc hiểu sai ngữ cảnh và giảm độ chính xác của các tác vụ phân tích ngôn ngữ [15].

Đối với bài toán tóm tắt văn bản, những đặc trưng này gây ảnh hưởng trực tiếp đến chất lượng sinh từ và trích xuất. Nếu hệ thống tóm tắt trích rút đánh giá tầm quan trọng của câu dựa trên tần suất từ mà không tách từ chính xác, nó sẽ đếm sai các thuật ngữ chuyên ngành đa âm tiết. Khó khăn đối với các mô hình học máy và đặc biệt là kiến trúc Transformer hiện đại nằm ở việc đa số các mô hình đa ngữ lớn thường chỉ xử lý ngôn ngữ ở cấp độ âm tiết để phục vụ chung cho nhiều ngôn ngữ [15]. Việc thiếu đi sự nhận thức về ranh giới từ tiếng Việt khiến các mô hình đa ngữ bị suy giảm hiệu suất so với các mô hình đơn ngữ được huấn luyện riêng biệt trên dữ liệu đã qua tách từ ở cấp độ từ [15]. Nhận thức rõ ràng đặc điểm này có ý nghĩa quan trọng cho đề tài trong việc định hướng thiết kế pipeline xử lý chuẩn xác, cũng như giải thích lý do ưu tiên lựa chọn các mô hình Transformer đã được tối ưu hóa đặc thù cho ngôn ngữ tiếng Việt.

2.5. Kiến trúc Transformer

Trong bối cảnh các mô hình mạng nơ-ron hồi quy và bộ nhớ ngắn hạn dài đang bộc lộ những giới hạn nghiêm trọng về hiệu suất do bắt buộc phải tính toán dữ liệu một cách tuần tự, kiến trúc Transformer đã ra đời như một cuộc cách mạng trong lĩnh vực NLP [2]. Giới hạn tuần tự của RNN khiến mô hình rất khó nắm bắt được sự phụ thuộc giữa các từ ở khoảng cách xa trong một câu dài, đồng thời không thể tận dụng sức mạnh xử lý song song của các hệ thống phần cứng hiện đại như GPU hay TPU [2]. Transformer được Google giới thiệu đã loại bỏ hoàn toàn cấu trúc hồi quy, thay vào đó dựa hoàn toàn vào cơ chế chú ý để lập mô hình các râu ria toàn cục giữa đầu vào và đầu ra [2].

Về cấu trúc, Transformer tuân theo mô hình mã hóa - giải mã. Cả bộ mã hóa và bộ giải mã đều được cấu tạo từ một chuỗi các khối xếp chồng lên nhau [2, 9]. Điểm cốt lõi tạo nên sức mạnh của Transformer là cơ chế tự chú ý Self-Attention. Trong khi giải mã hoặc mã hóa, cơ chế Self-Attention tính toán trọng số tương quan của một từ hiện tại so với tất cả các từ khác trong cùng một chuỗi đầu vào. Quá trình này tạo ra một biểu diễn mới cho từ đó bằng cách lấy trung bình có trọng số từ toàn bộ ngữ cảnh, giúp mô hình trực tiếp nhìn thấy sự gắn kết của các từ dù chúng cách xa nhau bao nhiêu đi nữa [2, 9].

Kiến trúc này còn sử dụng Multi-Head Attention, cho phép mô hình thực hiện cơ chế chú ý song song trên nhiều không gian biểu diễn khác nhau, giúp thu thập được nhiều

khía cạnh ngữ nghĩa đa dạng từ cùng một chuỗi văn bản [2, 9]. Hơn nữa, vì Transformer không xử lý từ theo thứ tự như RNN, nó cần một cơ chế Positional Encoding mã hóa vị trí để tiêm thông tin về thứ tự tuyến tính của các từ vào biểu diễn vector trước khi đưa qua mạng lưới nơ-ron [2, 9].

Quy trình xử lý dữ liệu của Transformer diễn ra đồng thời: toàn bộ chuỗi văn bản đầu vào được đưa qua bộ mã hóa trong một thao tác tính toán ma trận duy nhất. Ưu điểm tuyệt đối của Transformer so với RNN và LSTM là tốc độ xử lý nhanh hơn rất nhiều do khả năng tính toán song song, đồng thời tránh được hiện tượng suy giảm gradient khi mô hình hóa các chuỗi văn bản rất dài [2]. Vai trò của Transformer trong bài toán tóm tắt văn bản là nền tảng cốt lõi. Nó là trái lõi kiến trúc của tất cả các mô hình ngôn ngữ sinh văn bản mạnh mẽ nhất hiện nay, cung cấp năng lực đọc hiểu ngữ cảnh sâu sắc và khả năng tự động giải mã ra các câu tóm tắt mạch lạc, linh hoạt mà các thể hệ mô hình học sâu trước đó không thể đạt tới [9]. Việc ứng dụng Transformer là điều kiện tiên quyết giúp đề tài tiếp cận với những tiêu chuẩn công nghệ tiên tiến nhất.

2.6. Các mô hình Transformer sử dụng trong đề tài

Nhằm đạt được hiệu suất tóm tắt tốt nhất, đề tài sử dụng và so sánh các mô hình ngôn ngữ học sâu quy mô lớn, được xây dựng dựa trên kiến trúc Transformer.

ViT5: ViT5 có nguồn gốc từ kiến trúc mạng T5 của Google, nhưng được đào tạo lại từ đầu như một mô hình dành riêng cho tiếng Việt [19]. Kiến trúc của ViT5 hoàn toàn tuân theo cấu trúc Encoder-Decoder chuẩn, trong đó mọi bài toán NLP đều được coi là một tác vụ dịch văn bản sang văn bản [19]. Đặc điểm nổi bật của ViT5 là nó được tiền huấn luyện trên bộ dữ liệu khổng lồ CC100 đơn ngữ tiếng Việt với quy mô lên tới 138GB văn bản thô, và sử dụng bộ từ vựng đã được tối ưu hóa cẩn thận dành riêng cho sub-word tiếng Việt với kích thước 36K [19]. Khả năng xử lý tiếng Việt của ViT5 vô cùng vượt trội, mô hình đã đạt kết quả SOTA trên các bộ dữ liệu tóm tắt đa miền như Wikilingua và Vietnews [19]. Ưu điểm của mô hình là hiểu rất rõ ngữ pháp tiếng Việt, cho ra các đoạn tóm tắt Abstractive cực kỳ trôi chảy, có khả năng xử lý độ dài ngữ cảnh lớn lên tới 1024 token [19]. Hạn chế của nó là kích thước mô hình lớn và đòi hỏi tài nguyên tính toán cao

để tinh chỉnh. ViT5 được chọn làm một trong những mô hình lõi của đề tài nhờ năng lực sinh văn bản tiếng Việt xuất sắc và linh hoạt trên nhiều miền dữ liệu khác nhau.

mT5: mT5 là phiên bản đa ngôn ngữ của mô hình T5, do Google phát triển [13]. Kiến trúc của mT5 tương tự như ViT5 nhưng sở hữu một bộ từ vựng không lồ lên đến 250.000 wordpieces để hỗ trợ bao phủ hơn 100 ngôn ngữ khác nhau trên thế giới, bao gồm cả tiếng Việt [13]. Đặc điểm nổi bật của mT5 là khả năng học hỏi chuyển giao ngôn ngữ cross-lingual transfer, có thể áp dụng kiến thức từ các ngôn ngữ tài nguyên phong phú như tiếng Anh sang ngôn ngữ có tài nguyên thấp [13]. Về khả năng xử lý tiếng Việt, mT5 có thể đọc và sinh tóm tắt tiếng Việt. Tuy nhiên, ưu điểm về sự đa năng của nó lại đi kèm với hạn chế lớn về hiệu suất nội tại: không gian tham số bị pha loãng cho 100 ngôn ngữ dẫn đến khả năng nắm bắt ngữ nghĩa sâu sắc đối với riêng tiếng Việt thường yếu hơn so với các mô hình đơn ngữ chuyên biệt [4]. Đồng thời, quá trình BPE của nó được áp dụng trực tiếp lên dữ liệu đa ngữ chưa qua tách từ tiếng Việt. mT5 được lựa chọn trong đề tài nhằm đóng vai trò làm mô hình cơ sở đa ngữ để thực nghiệm so sánh và chứng minh sự cần thiết của các mô hình đơn ngữ tối ưu hóa cho tiếng Việt.

BARTPho: BARTPho là mô hình ngôn ngữ đơn ngữ cỡ lớn đầu tiên được tiền huấn luyện dưới dạng Seq2Seq dành riêng cho tiếng Việt [4, 15]. Mô hình có nguồn gốc từ kiến trúc Autoencoder khử nhiễu BART, áp dụng khung kiến trúc large kết hợp giữa một bộ mã hóa hai chiều tương tự BERT và một bộ giải mã tự hồi quy từ trái sang phải như GPT [4]. Đặc điểm nổi bật của BARTPho là nó được chia thành hai phiên bản: cấp độ âm tiết BARTpho-syllable và cấp độ từ BARTpho-word, được đào tạo trên 20GB dữ liệu tiếng Việt chất lượng cao[4]. Khả năng xử lý tiếng Việt của phiên bản BARTpho-word là cực kỳ xuất sắc nhờ nhận thức được cấu trúc từ ghép của tiếng Việt sau quá trình tách từ tự động [4]. Ưu điểm của BARTPho là vô cùng thích hợp cho các tác vụ sinh tự nhiên như tóm tắt văn bản, đạt kết quả SOTA vượt trội hoàn toàn so với mô hình đa ngữ mBART [4]. Hạn chế của mô hình thường nằm ở kích thước cửa sổ ngữ cảnh cố định, gây cản trở cho các văn bản quá dài. Đề tài lựa chọn BARTPho vì đây là kiến trúc sinh văn bản Seq2Seq tiên tiến, cung cấp hiệu năng vượt trội và giải quyết triệt để vấn đề ranh giới từ trong tiếng Việt.

2.7. Các phương pháp đánh giá chất lượng tóm tắt

Mục đích của việc đánh giá là cung cấp các thước đo định lượng và định tính nhằm xác định mức độ chính xác, tính đầy đủ của thông tin, độ trôi chảy và khả năng khái quát hóa của bản tóm tắt do hệ thống máy tính sinh ra so với bản tóm tắt mẫu do con người viết [14, 18]. Do ngôn ngữ tự nhiên vô cùng đa dạng, một câu tóm tắt có thể được diễn đạt bằng nhiều cách khác nhau, khiến việc đánh giá tự động trở thành một thách thức lớn trong ngành NLP.

Để giải quyết thách thức này, chỉ số ROUGE thường được sử dụng như một tiêu chuẩn đánh giá truyền thống và phổ biến nhất [18]. ROUGE đo lường tỷ lệ các đơn vị văn bản chồng chéo giữa bản tóm tắt sinh ra và bản mẫu. Các biến thể chính của ROUGE bao gồm: ROUGE-1 đo lường độ bao phủ dựa trên tần suất trùng khớp của các từ đơn - unigrams, ROUGE-2 đo lường sự trùng khớp của các cụm 2 từ liên tiếp - bigrams nhằm kiểm tra thứ tự từ, và ROUGE-L đo lường dựa trên chuỗi con chung dài nhất - Longest Common Subsequence - phản ánh cấu trúc câu và sự liên mạch của luồng thông tin [18]. Ưu điểm của ROUGE là dễ triển khai và đánh giá tốt mức độ đầy đủ của nội dung dựa trên sự bảo toàn từ vựng gốc [11]. Tuy nhiên, hạn chế chí mạng của ROUGE là nó phạt rất nặng các mô hình tóm tắt diễn giải khi mô hình thực hiện viết lại câu bằng các từ đồng nghĩa dù ngữ nghĩa không hề thay đổi, do ROUGE chỉ xét khớp từ vựng chính xác [14,11].

Để bù đắp khiếm khuyết của ROUGE, chỉ số BERTScore được đề xuất sử dụng. BERTScore đánh giá độ tương đồng giữa hai chuỗi văn bản bằng cách tính toán khoảng cách Cosine giữa các vector nhúng embeddings ngữ cảnh của các token, được sinh ra từ các mô hình ngôn ngữ lớn như BERT hoặc DistilBERT [11]. Ý nghĩa của BERTScore là nó tập trung vào cấp độ ngữ nghĩa thay vì cú pháp bề mặt. Thay vì tìm kiếm sự trùng lặp từ vựng cứng nhắc, thuật toán sẽ liên kết mỗi từ trong câu dự đoán với một từ có ngữ nghĩa gần nhất trong câu tham chiếu. Bằng cách này, BERTScore chấm điểm công bằng hơn cho các bản tóm tắt Abstractive chứa các từ ngữ đồng nghĩa hoặc được diễn giải theo cấu trúc ngữ pháp khác biệt [11].

Trong quá trình thực nghiệm của đề tài, các phương pháp đánh giá này đóng vai trò song hành không thể thiếu. Việc áp dụng kết hợp cả ROUGE và BERTScore cung cấp một khung đánh giá toàn diện, sâu sắc và đa chiều: ROUGE xác nhận sự đảm bảo thông tin nguyên bản quan trọng đối với phần trích rút, trong khi BERTScore chứng minh sự tinh vi, uyển chuyển của các mô hình sinh như ViT5 và BARTPho thông qua chất lượng ngữ nghĩa tự nhiên của bản tóm tắt đầu ra [11, 1].

Chương 2 đã xây dựng một hệ thống cơ sở lý thuyết vững chắc và toàn diện phục vụ cho bài toán tóm tắt văn bản tự động. Thông qua việc phân tích chi tiết, chương đã làm rõ bản chất, nguyên lý hoạt động cũng như ưu nhược điểm của hai phương pháp tiếp cận cốt lõi: tóm tắt trích rút và tóm tắt diễn giải. Từ những phân tích này, định hướng sử dụng phương pháp lai được củng cố, đóng vai trò như một giải pháp tối ưu nhằm kế thừa tính chính xác của trích xuất và khả năng diễn đạt tự nhiên của mô hình sinh, đồng thời khắc phục giới hạn về tài nguyên tính toán đối với các tài liệu dài.

Kiến trúc Transformer với cơ chế Self-Attention cũng đã được giới thiệu như một nền tảng công nghệ mang tính cách mạng, giải quyết triệt để các hạn chế của mạng nơ-ron hồi quy truyền thống. Các mô hình học sâu quy mô lớn được khảo sát, bao gồm ViT5, BARTPho đơn ngữ tiếng Việt và mT5 đa ngữ, đã minh chứng cho năng lực vượt trội trong việc hiểu ngữ cảnh và sinh văn bản tự nhiên. Sự lựa chọn các mô hình đơn ngữ như ViT5 và BARTPho được khẳng định là hướng đi phù hợp nhất để xử lý các thách thức đặc thù của tiếng Việt. Toàn bộ những nền tảng lý thuyết, công nghệ và phương pháp đo lường được đúc kết trong chương này chính là kim chỉ nam quan trọng, làm cơ sở khoa học trực tiếp cho quá trình phân tích, thiết kế và triển khai mô hình hệ thống sẽ được trình bày chi tiết trong Chương 3.

CHƯƠNG 3: PHÂN TÍCH THIẾT KẾ HỆ THỐNG

Chương này tập trung trình bày quy trình phân tích và thiết kế chi tiết hệ thống tóm tắt văn bản tiếng Việt kết hợp phân hệ hỏi đáp tài liệu đa tầng ChatRAG. Nội dung chương bao gồm mô tả bài toán nghiên cứu, phân tích các yêu cầu chức năng và phi chức năng, đặc tả thiết kế giao diện, phân tích mô hình nghiên cứu khoa học dữ liệu, và thiết kế cấu trúc kiến trúc hệ thống tổng thể. Cuối cùng, chương giới thiệu hệ thống các sơ đồ thiết kế kỹ thuật như sơ đồ kiến trúc nghiên cứu, pipeline xử lý dữ liệu và các workflow huấn luyện, suy luận làm cơ sở triển khai cài đặt thực nghiệm.

3.1. Mô tả bài toán nghiên cứu

Trong kỷ nguyên chuyển đổi số như hiện nay khối lượng thông tin và tài liệu văn bản tiếng Việt dưới dạng báo chí trực tuyến đang gia tăng một cách bùng nổ. Người đọc, các nhà nghiên cứu thường xuyên phải đối mặt với thực trạng quá tải thông tin khi phải đọc hiểu và tổng hợp thủ công các tài liệu dài hàng chục trang. Việc đọc thủ công này tiêu tốn rất nhiều thời gian, làm giảm hiệu năng khai thác tri thức và dễ dẫn đến bỏ sót các thông tin cốt lõi phân bố rải rác trong văn bản.

Các phương pháp tóm tắt văn bản hiện nay được chia làm hai hướng tiếp cận chính, mỗi phương pháp đều tồn tại những hạn chế kỹ thuật lớn khi áp dụng vào thực tế:

Các giải thuật trích rút cổ điển: TextRank, LexRank hay phân tích trị riêng SVD (LSA), hoạt động bằng cách lựa chọn trực tiếp các câu quan trọng trong văn bản gốc. Phương pháp này có ưu điểm là xử lý nhanh và độ trung thực thông tin cao, nhưng nhược điểm lớn là bản tóm tắt thu được thường rời rạc, thiếu tính liên kết mạch lạc và không thể tự diễn giải lại nội dung theo văn phong tự nhiên của con người.

Các mô hình diễn giải: Sử dụng các mạng nơ-ron sequence-to-sequence Transformer để tự sinh ra bản tóm tắt diễn giải. Tuy nhiên, các mô hình này bị giới hạn nghiêm ngặt về độ dài ngữ cảnh đầu vào thường chỉ từ 512 đến 1024 tokens. Khi gặp tài liệu dài hàng ngàn từ, hệ thống buộc phải cắt bỏ văn bản gây mất mát thông tin quan trọng ở phần sau. Hơn nữa, việc suy luận bằng các mạng nơ-ron lớn tiêu tốn rất nhiều tài

nguyên phần cứng như GPU VRAM và có thời gian trễ phản hồi lớn, dễ gặp lỗi lặp từ hoặc sinh ra các thông tin bịa đặt không có trong văn bản gốc.

Đề tài nghiên cứu khoa học này hướng tới các mục tiêu cụ thể sau nhằm khắc phục các hạn chế trên bằng cách so sánh đối sánh hiệu năng toàn diện của 15 cấu hình mô hình khác nhau bao gồm 3 giải thuật trích xuất, 3 mô hình sinh Transformer và 9 cấu hình lai ghép Hybrid Pipeline trên cùng một tập dữ liệu chuẩn để tìm ra phương án tối ưu nhất.

Xây dựng một kịch bản tóm tắt lai kết hợp lọc trích xuất trên CPU trước và sinh diễn giải trên GPU sau nhằm tăng tốc độ xử lý, tiết kiệm bộ nhớ đồ họa và bao phủ thông tin toàn cục tài liệu dài.

Thiết kế phân hệ hỏi đáp ngữ cảnh nâng cao ChatRAG tích hợp cơ chế phân mảnh ngữ nghĩa Semantic chunking, tìm kiếm lai Hybrid Search, tái xếp hạng Cross-Encoder Reranking và chỉ mục phân cấp cây tóm tắt RAPTOR để hỗ trợ trả lời các câu hỏi từ chi tiết đến tổng quát.

Phát triển bộ công cụ đánh giá tự động đa tiêu chí, kết hợp giữa các độ đo truyền thống ROUGE, BLEU và các độ đo ngữ nghĩa học sâu BERTScore, Semantic Similarity, Faithfulness, Fluency để cung cấp báo cáo hiệu năng chính xác cho nhà nghiên cứu. Hệ thống được thiết kế với các luồng dữ liệu đầu vào và đầu ra rõ ràng nhằm đảm bảo quá trình xử lý, đánh giá và khai thác thông tin diễn ra hiệu quả. Về dữ liệu đầu vào, hệ thống hỗ trợ tiếp nhận các tệp tài liệu từ người dùng dưới nhiều định dạng phổ biến như PDF, DOCX và TXT. Bên cạnh đó, người dùng cũng có thể nhập trực tiếp văn bản tiếng Việt thông qua giao diện để thực hiện tóm tắt mà không cần tải tệp lên hệ thống. Đối với phân hệ hỏi đáp ChatRAG, đầu vào là các câu hỏi truy vấn được gửi từ người dùng trong quá trình hội thoại nhằm khai thác thông tin từ tài liệu đã được lưu trữ và xử lý trước đó. Ngoài ra, hệ thống còn sử dụng các bản tóm tắt tham chuẩn làm dữ liệu tham chiếu phục vụ cho quá trình đánh giá chất lượng của các mô hình tóm tắt.

Sau khi hoàn thành quá trình xử lý, hệ thống tạo ra nhiều dạng dữ liệu đầu ra khác nhau. Kết quả quan trọng nhất là bản tóm tắt văn bản được sinh ra với nội dung cô đọng, mạch lạc và giữ lại các thông tin trọng tâm của tài liệu gốc. Hệ thống còn cung cấp bảng thống kê chi tiết các chỉ số đánh giá chất lượng như ROUGE, BLEU, BERTScore và thời

gian phản hồi nhằm hỗ trợ việc so sánh và phân tích hiệu năng giữa các mô hình. Đối với các thử nghiệm nghiên cứu, kết quả còn được trực quan hóa dưới dạng biểu đồ radar giúp người dùng dễ dàng quan sát ưu điểm và hạn chế của từng phương pháp. Trong phân hệ ChatRAG, hệ thống trả về câu trả lời cho các truy vấn của người dùng kèm theo thông tin trích dẫn nguồn, bao gồm tên tài liệu, số trang và đoạn văn liên quan, góp phần nâng cao tính minh bạch và độ tin cậy của kết quả.

3.2. Phân tích yêu cầu hệ thống

3.2.1. Yêu cầu chức năng

Hệ thống được thiết kế để đáp ứng đầy đủ các yêu cầu chức năng thực tế của một hệ quản trị tài liệu đơn giản kết hợp thử nghiệm mô hình học máy:

Tải và Trích xuất tài liệu: Hỗ trợ tải lên tài liệu đa định dạng, tự động phân tích cú pháp trích xuất văn bản thô theo trang, chuẩn hóa ký tự Unicode NFC và loại bỏ nhiễu định dạng.

Tóm tắt đơn thuật toán: Cung cấp giao diện cho phép người dùng chạy thử nghiệm tóm tắt trên một tài liệu với một thuật toán được chỉ định và nhận kết quả tức thì.

So sánh Playground đa mô hình: Hỗ trợ chạy song song và hiển thị side-by-side kết quả tóm tắt cùng các chỉ số hiệu năng độ trễ, số từ sinh ra của nhiều mô hình khác nhau trên cùng một văn bản nguồn.

Đánh giá tự động chất lượng: Khởi chạy module tính toán các chỉ số chất lượng học thuật khi có nhân tham chiếu, kết xuất kết quả chấm điểm ROUGE-L, BERTScore F1, độ trung thực thông tin Faithfulness và độ mạch lạc Fluency.

Hội thoại hỏi đáp ChatRAG: Cho phép người dùng trò chuyện, đặt câu hỏi dựa trên ngữ cảnh của tài liệu đã chọn. Chatbot trả lời thông tin chính xác và tự động gắn thẻ trích dẫn liên kết nguồn.

Dashboard Trực quan hóa kết quả: Tổng hợp và trực quan hóa dữ liệu hiệu năng hệ thống, vẽ biểu đồ radar so sánh thế mạnh giữa các nhóm mô hình, hiển thị phân bố độ dài tài liệu và nhật ký hoạt động.

3.2.2. Yêu cầu phi chức năng

Để phục vụ tốt cả môi trường nghiên cứu khoa học lẫn triển khai ứng dụng thực tế, hệ thống đáp ứng cơ bản các tiêu chuẩn chất lượng phi chức năng như:

Thời gian phản hồi: Giải thuật trích xuất trên CPU phải hoàn thành tóm tắt dưới 50ms. Mô hình sinh học sâu trên GPU phải hoàn thành sinh văn bản tóm tắt dưới 3 giây cho một phân đoạn văn bản thông thường.

Kiểm soát tài nguyên GPU: Hệ thống phải triển khai cơ chế khóa semaphore toàn cục để kiểm soát hàng đợi suy luận, đảm bảo tại một thời điểm chỉ có một tác vụ chiếm dụng CUDA Core của GPU để sinh văn bản, ngăn ngừa hoàn toàn lỗi CUDA Out Of Memory.

Tính ổn định và chịu lỗi: Khi các mô hình sinh học sâu gặp lỗi sinh chuỗi lặp vô hạn, hệ thống phải tự động phát hiện thông qua bộ lọc chất lượng và kích hoạt cơ chế giải mã fallback an toàn thay vì trả về lỗi API.

Khả năng mở rộng: Mã nguồn được thiết kế theo các mô-đun độc lập. Hệ thống cho phép đăng ký thêm mô hình học máy mới bằng cách cấu hình file JSON mà không cần viết lại mã nguồn xử lý.

Tính bảo mật: Toàn bộ dữ liệu tài liệu cá nhân, lịch sử trò chuyện và thông tin người dùng được lưu trữ cục bộ hoặc trên máy chủ SQLite/Qdrant riêng tư của hệ thống, không chia sẻ cho bên thứ ba.

3.3. Thiết kế giao diện hệ thống

Giao diện hệ thống được thiết kế theo phong cách giao diện người dùng tối giản hiện đại, sử dụng hệ màu sắc hài hòa và hỗ trợ hiển thị responsive trên nhiều thiết bị.


3.3.1. Giao diện trang chủ

Thanh điều hướng bên trái: Chứa các nút chuyển đổi nhanh giữa Dashboard, Playground, ChatRAG, Analytics và Settings.

Khu vực hiển thị chỉ số chính: Hiển thị tổng số tài liệu đã tải lên, số lượng phiên tóm tắt đã thực hiện, tổng số tin nhắn hỏi đáp và dung lượng lưu trữ hiện tại.

Bảng danh sách tài liệu: Hiển thị danh mục tài liệu kèm theo các cột thông tin tên tệp, số trang, kích thước, ngày tải lên và hành động (Xóa/Xem chi tiết).

Biểu đồ thống kê: Biểu đồ cột thể hiện sự phân bố độ dài từ vựng của các tài liệu trong hệ thống giúp người dùng có cái nhìn tổng quan về kho dữ liệu.



Hình 3.1. Giao diện trang chủ

3.3.2. Giao diện tóm tắt văn bản


Màn hình Playground phục vụ thử nghiệm tóm tắt đơn mô hình, bao gồm:

Panel nhập liệu bên trên: Chứa khung văn bản để người dùng nhập trực tiếp hoặc chọn một tài liệu có sẵn trong hệ thống. Bên trên tích hợp thanh chọn mô hình..

Panel kết quả bên dưới: Hiện thị bản tóm tắt được tạo ra. Dưới chân trang hiện thị các thông số thời gian xử lý và số lượng từ sinh ra.

The screenshot displays the AI Document Hub Playground interface, which is used for testing document summarization models. The interface is divided into several sections:


- Left Sidebar:** Contains navigation options such as "KHÔNG GIAN LÀM VIỆC" (Workspace), "Bảng điều khiển" (Dashboard), "Tóm tắt tài liệu" (Document Summarization), "Trò chuyện AI" (AI Chat), "PHÂN TÍCH & SO SÁNH" (Analysis & Comparison), "So sánh Mô hình" (Model Comparison), "Phân tích hiệu năng" (Performance Analysis), "QUẢN TRỊ HỆ THỐNG" (System Management), "Tập dữ liệu" (Dataset), "Mô hình AI" (AI Model), and "Cấu hình hệ thống" (System Configuration).
- Top Bar:** Includes the "AI Document Hub" logo, a search bar for models, and language selection options (VI, EN).
- Main Workspace:**
 - TÀI LIỆU ĐẦU VÀO (Input Document):** A section where users can upload a document or select from a list of pre-defined documents.
 - LỰA CHỌN THUẬT TOÁN (Model Selection):** A section where users can choose from various summarization models. The interface shows two categories: "EXTRACTIVE" (TextRank, LexRank, LSA) and "ABSTRACTIVE" (VITS, mT5, BARTPho). A "Chọn tất cả" (Select all) button is also present.
 - Tóm tắt cấu hình (Summarization Configuration):** A section where users can configure the summarization process, including the number of words to generate (e.g., 6 words) and the source (e.g., 907 words).
 - Sẵn sàng chạy so sánh (Ready to compare):** A button to initiate the comparison process.
- Results Section:** Displays the output of the summarization process, including the original text and the generated summary. The interface shows two examples: "VĂN BẢN GỐC" (Original Text) and "TÓM TẮT THAM CHIẾU (TỰY CHỌN)" (Referenced Summary (Self-Selected)).



Hình 3.2. Giao diện tóm tắt văn bản

3.3.3. Giao diện so sánh bản tóm tắt của các mô hình

Truy vấn dữ liệu: Khi người dùng đổi trang hoặc tìm kiếm mẫu thử, Frontend gửi một yêu cầu truy vấn đến API Backend kèm theo thông tin trang hoặc ID mẫu thử.




Hình 3.3. Giao diện chọn các mẫu thử để xem văn bản tóm tắt

Lấy kết quả pre-computed từ cơ sở dữ liệu: Thay vì phải chạy suy luận lại (tốn thời gian và tài nguyên GPU), Backend sẽ truy cập trực tiếp vào cơ sở dữ liệu SQLite/tệp lưu trữ kết quả benchmark để lấy thông tin của mẫu thử được yêu cầu. Dữ liệu này bao gồm:

Văn bản gốc, bản tóm tắt tham chiếu, và toàn bộ văn bản tóm tắt cùng điểm số (ROUGE-L, BERTScore, thời gian trễ) của các mô hình đã được chạy và lưu trữ sẵn từ trước.

Trả kết quả và hiển thị: Backend phản hồi dữ liệu về Client dưới dạng JSON. Frontend nhận và hiển thị ngay lập tức văn bản gốc cùng lưới kết quả tóm tắt của các mô hình lên màn hình, giúp người dùng duyệt và đối chiếu kết quả cực kỳ nhanh chóng mà không gặp độ trễ tính toán.




Hình 3.4. Giao diện hiển thị kết quả tóm tắt

3.3.4. Giao diện đánh giá kết quả

Màn hình Analytics phục vụ phân tích khoa học chuyên sâu:

Bảng xếp hạng Leaderboard: Hiển thị danh sách tất cả thuật toán kèm theo điểm số ROUGE-1, ROUGE-2, ROUGE-L, BLEU, BERTScore F1, Semantic Similarity và điểm Composite Score tổng hợp.

Biểu đồ Radar (Radar Chart): Trực quan hóa so sánh đa chiều giữa các cấu hình được chọn. Mỗi góc của biểu đồ radar đại diện cho một tiêu chí chất lượng (ví dụ: góc ROUGE-L biểu thị độ bao phủ cấu trúc, góc Latency biểu thị tốc độ, góc Faithfulness biểu thị độ chính xác thông tin). Biểu đồ này giúp dễ dàng nhận biết mô hình nào có thể mạnh toàn diện nhất.



Hình 3.5. Giao diện đánh giá kết quả

3.4. Phân tích và thiết kế mô hình nghiên cứu

3.4.1. Dữ liệu sử dụng trong nghiên cứu

Nghiên cứu sử dụng bộ dữ liệu báo chí tiếng Việt VietNews (nam194/vietnews) <https://github.com/ThanhChinhBK/vietnews> (V.-H. Nguyen, T.-C. Nguyen, M.-T. Nguyen, and N. X. Hoai, “VNDS: A Vietnamese Dataset for Summarization,” in Proc. 6th NAFOSTED Conf. Information and Computer Science NICS, 2019, pp. 375-380) được tải trực tiếp từ Hugging Face Hub. Đây là bộ dữ liệu tóm tắt văn bản tiếng Việt quy mô lớn, bao gồm hơn 143.000 mẫu bài báo thu thập từ các trang tin tức lớn như VnExpress, Tuổi Trẻ, Người Đưa Tin. Cấu trúc mỗi mẫu dữ liệu gồm các trường:

+ *article*: Văn bản bài viết thô (độ dài trung bình khoảng 400 từ).

+ *abstract*: Bản tóm tắt mẫu chuẩn do biên tập viên viết (độ dài trung bình khoảng 32 từ).

+ *title*: Tiêu đề bài viết.

Nghiên cứu thực hiện phân chia bộ dữ liệu theo tỷ lệ chuẩn: 99.134 mẫu cho tập huấn luyện, 22.184 mẫu cho tập kiểm chuẩn và 22.498 mẫu cho tập kiểm thử. Để thực hiện benchmark hiệu năng khoa học trong đề tài, một tập mẫu test ngẫu nhiên gồm 1000 bài báo được chọn lọc cố định bằng cách thiết lập *Random Seed* = 42 để đảm bảo tính tái lập kết quả đánh giá.

3.4.2. Quy trình tiền xử lý dữ liệu

Làm sạch nhiễu: Loại bỏ các ký tự lỗi và chuẩn hóa các khoảng trắng thừa.

Chuẩn hóa Unicode: Chuyển đổi toàn bộ văn bản về dạng chuẩn Unicode NFC để giải quyết triệt để lỗi gõ dấu tiếng Việt ví dụ lỗi ký tự dựng sẵn và ký tự tổ hợp.

Tách câu: Sử dụng các biểu thức chính quy tối ưu cho tiếng Việt để tách văn bản thành danh sách các câu độc lập dựa trên các dấu chấm câu và ngữ cảnh viết tắt.

Tách từ ghép tiếng Việt: Sử dụng công cụ tách từ của thư viện *pyvi* để liên kết các âm tiết cấu thành từ ghép bằng dấu gạch dưới (ví dụ: *trí tuệ nhân tạo* thành *trí_tuệ_nhân_tạo*), giúp mô hình nhúng và mô hình sinh học sâu nhận diện đúng ranh giới ngữ nghĩa của từ ghép tiếng Việt đơn lập.

3.4.3. Quy trình huấn luyện mô hình

Quá trình tinh chỉnh 3 mô hình học sâu Seq2Seq Transformers: ViT5, mT5, BARTPho được thực hiện trên môi trường máy chủ GPU bằng framework PyTorch và thư viện Transformers:

Chuẩn bị dữ liệu đầu vào: Văn bản bài báo sau tiền xử lý được chuyển đổi thành chuỗi Token IDs bằng Tokenizer tương ứng của từng mô hình. Đối với ViT5 và mT5, một tiền tố tác vụ dạng “summarize” được nối vào trước văn bản.

Cấu hình siêu tham số: Thiết lập kích thước lô hiệu dụng bằng 16, vật lý batch size = 2 hoặc 4, tích lũy gradient accumulation steps = 4 hoặc 8 để tiết kiệm VRAM. Tốc độ học đặt bằng 5×10^{-5} với thuật toán tối ưu AdamW và linear warmup schedule.

Tối ưu hóa phần cứng: Chạy huấn luyện ở chế độ dấu phẩy động độ chính xác hỗn hợp FP16 giúp giảm khoảng 50% dung lượng bộ nhớ GPU tiêu thụ và tăng tốc huấn luyện.

Kiểm chuẩn và Early Stopping: Sau mỗi epoch huấn luyện, mô hình được đánh giá trên tập Validation. Cơ chế Early Stopping sẽ theo dõi điểm validation loss, nếu loss không giảm liên tiếp trong 3 epoch, hệ thống sẽ tự động dừng huấn luyện để tránh overfitting và xuất bản checkpoint có điểm số tốt nhất.

3.4.4. Quy trình suy luận và sinh tóm tắt

Quản lý VRAM GPU: Khi có request suy luận, module “ModelLoader” thực hiện kiểm tra trạng thái GPU. Nếu GPU đang bận xử lý một request khác, request mới sẽ được xếp vào hàng đợi thông qua cơ chế khóa semaphore toàn cục.

Sinh chuỗi tự hồi quy: Mô hình sinh thực hiện giải mã bằng giải thuật Beam Search với cấu hình *num_beams*=4 và hình phạt lặp từ *repetition_penalty*=1.2 để tạo ra chuỗi Token IDs tóm tắt tối ưu.

Bộ lọc sửa lỗi sinh hỏng: Sau khi giải mã Token IDs thành văn bản, hệ thống quét văn bản đầu ra. Nếu phát hiện mô hình sinh ra các chuỗi ký tự lặp lại vô nghĩa do lỗi giải mã, hệ thống sẽ tự động kích hoạt cơ chế giải mã dự phòng an toàn để sinh lại bản tóm tắt hợp lệ.

3.4.5. Đánh giá kết quả

Độ trùng khớp từ vựng: Tính toán điểm số ROUGE-1, ROUGE-2, ROUGE-L và BLEU dựa trên tỷ lệ trùng lặp unigram, bigram và chuỗi con chung dài nhất giữa bản tóm tắt sinh ra và bản tóm tắt mẫu chuẩn.

Tương đồng ngữ nghĩa sâu: Vector hóa bản tóm tắt sinh ra và bản tóm tắt mẫu bằng mô hình nhúng SentenceTransformer, sau đó tính độ tương đồng Cosine giữa hai vector này để đo chất lượng truyền tải ý nghĩa tổng thể.

Độ tương đồng mức Token: Tính điểm BERTScore F1 bằng cách so sánh độ tương đồng ngữ nghĩa mềm giữa các vector nhúng token ngữ cảnh, khắc phục hạn chế của ROUGE khi người viết dùng từ đồng nghĩa.

Chất lượng thông tin: Tính toán độ trung thực Faithfulness mức độ bám sát thông tin văn bản gốc, không bịa đặt và độ mạch lạc Fluency đo bằng độ hỗn loạn perplexity của mô hình GPT-2 tiếng Việt.

3.5. Thiết kế kiến trúc hệ thống

3.5.1. Kiến trúc tổng thể hệ thống

Mô hình hoạt động tổng thể của hệ thống dựa trên luồng giao tiếp bất đồng bộ qua mạng nội bộ hoặc Internet. Client gửi các yêu cầu xử lý dữ liệu và nhận phản hồi dưới dạng JSON. Hệ thống tổ chức mã nguồn theo kiến trúc phân lớp sạch bao gồm: Lớp định tuyến API, Lớp dịch vụ nghiệp vụ và Lớp điều phối suy luận học máy.

3.5.2. Kiến trúc Frontend - Backend

Frontend: Được xây dựng bằng React, Vite và TypeScript. Trạng thái ứng dụng được quản lý tập trung bằng Zustand store. Frontend chịu trách nhiệm gửi các file tài liệu hoặc tham số cấu hình tóm tắt thông qua các HTTP POST requests dạng multipart/form-data đến Backend, nhận lại JSON kết quả và render các biểu đồ so sánh chất lượng bằng công cụ đồ họa Recharts.

Backend: Chạy trên nền Python, đóng vai trò như một API gateway điều phối. Backend tiếp nhận các yêu cầu, phân tích các tệp tin tải lên, thực hiện lưu trữ metadata vào SQLite DB và chuyển văn bản thô đến lớp AI Engine để tính toán. FastAPI được cấu hình chạy đa luồng bất đồng bộ để nâng cao thông lượng xử lý.

3.5.3. Kiến trúc AI Engine

Model Registry: File cấu hình khai báo danh sách tất cả các checkpoint mô hình trích xuất, mô hình sinh Seq2Seq và mô hình nhúng kèm đường dẫn thư mục cục bộ của chúng.


Model Loader: Module quản lý vòng đời nạp mô hình vào GPU VRAM. Khi mô hình được yêu cầu, ModelLoader sẽ nạp nó vào bộ nhớ đệm để tái sử dụng cho các request sau. Khi bộ nhớ GPU đầy, nó sẽ tự động hủy nạp các mô hình ít sử dụng.

Vector Store Integrator: Thành phần giao tiếp với Vector DB để thực hiện lưu trữ vector phân đoạn tài liệu và truy vấn tìm kiếm ngữ nghĩa thời gian thực phục vụ ChatRAG.

3.6. Các sơ đồ thiết kế hệ thống

3.6.1. Sơ đồ kiến trúc nghiên cứu


Sơ đồ kiến trúc nghiên cứu dưới đây mô tả cấu trúc phối hợp đa tầng của hệ thống từ lớp giao diện người dùng, lớp định tuyến API đến các bộ suy luận giải thuật và cơ sở dữ liệu lưu trữ



Hình 3.6. Sơ đồ kiến trúc nghiên cứu

3.6.2. Sơ đồ Pipeline xử lý dữ liệu


Sơ đồ dưới đây minh họa luồng xử lý và phân mảnh dữ liệu tài liệu từ dạng tệp tin thô tải lên cho đến khi lưu trữ thành các vector ngữ nghĩa trong Qdrant và các nút tóm tắt phân cấp cây RAPTOR trong SQLite



Hình 3.7. Sơ đồ pipeline xử lý dữ liệu


3.6.3. Workflow suy luận mô hình

Sơ đồ tuần tự dưới đây thể hiện tương tác thời gian thực giữa các thành phần hệ thống khi người dùng gửi yêu cầu tóm tắt văn bản, từ khâu tiền xử lý, kiểm soát GPU lock, suy luận Beam Search cho đến check lỗi hỏng đầu ra và hiển thị kết quả




Hình 3.8. Sơ đồ tuần tự suy luận của mô hình


3.6.4. Biểu đồ Use Case




Hình 3.9. Sơ đồ Use case tổng quát



Hình 3.10. Sơ đồ Use case tóm tắt văn bản



Hình 3.11. Sơ đồ Use case chatbot RAG



Hình 3.12. Sơ đồ Use case thống kê giám sát

Chương 3 đã hoàn thành việc phân tích và thiết kế chi tiết hệ thống tóm tắt văn bản tiếng Việt đa thuật toán. Quá trình thiết kế đã giải quyết thành công các thách thức đặc thù của tiếng Việt và giới hạn context window của các mô hình học sâu thông qua việc xây dựng các kịch bản lai Hybrid Pipeline và cấu trúc chỉ mục cây phân cấp RAPTOR. Các thiết kế kiến trúc hệ thống, giao diện người dùng và đặc biệt là hệ thống các sơ đồ thiết kế kỹ thuật được mô tả chi tiết trong chương này sẽ làm cơ sở nền tảng, tiền đề kỹ thuật trực tiếp để hình thành các nội dung xây dựng ứng dụng thực tế và tiến hành thực nghiệm đánh giá mô hình ở chương tiếp theo.

CHƯƠNG 4: CÀI ĐẶT THỰC NGHIỆM VÀ ĐÁNH GIÁ

Chương này tập trung trình bày toàn bộ quá trình cài đặt thực tế, thiết kế thực nghiệm và kết quả đánh giá hệ thống tóm tắt văn bản tiếng Việt tự động kết hợp hỏi đáp tài liệu thông minh ChatRAG. Đối với phần nghiên cứu mô hình, thông tin bộ dữ liệu VietNews, quy trình tiền xử lý, các tham số huấn luyện chi tiết và kịch bản thực nghiệm so sánh 15 cấu hình giải thuật được thiết kế chặt chẽ. Chương tiến hành phân tích chi tiết kết quả thực nghiệm tóm tắt trên 1.000 tài liệu kiểm thử. Qua đó, chương chỉ ra các ưu điểm, hạn chế và các bài học kinh nghiệm trong quá trình huấn luyện và tối ưu hóa hệ thống. Nội dung chương sẽ là cơ sở thực tế vững chắc để rút ra các kết luận chung và định hướng các công việc nghiên cứu tiếp theo ở chương cuối.

4.1. Môi trường và công nghệ cài đặt

4.1.1. Cấu hình phần cứng hệ thống

Để đảm bảo tính nhất quán và khả năng tái lập của các kết quả thực nghiệm, toàn bộ quá trình chạy suy luận và đánh giá chất lượng được thực thi trên một cấu hình phần cứng cục bộ chuẩn xác như sau:

- + Bộ vi xử lý (CPU): Intel(R) Core (TM) i5-12450H 12th Gen (2.00 GHz).
- + Bộ nhớ trong (RAM): 16 GB RAM vật lý.
- + Card đồ họa (GPU): NVIDIA GeForce RTX 3050 Ti Laptop GPU.
- + Bộ nhớ đồ họa (VRAM): 4.0 GB GDDR6.


4.1.2. Môi trường công nghệ phần mềm và thư viện hỗ trợ

Hệ thống sử dụng các nền tảng công nghệ mã nguồn mở hiện đại, đảm bảo tính mở rộng và hiệu năng xử lý cao:

- + Ngôn ngữ lập trình chính: Python version 3.13.2.
- + Thư viện học sâu và xử lý ngôn ngữ tự nhiên: PyTorch CUDA 12.4.
- + Hệ quản trị cơ sở dữ liệu và tìm kiếm: Qdrant Vector DB, SQLite.
- + Phát triển API và Giao diện: FastAPI, React.

4.2. Cơ chế hoạt động của Pipeline Tóm tắt Lại

Trong môi trường tài nguyên phần cứng hạn chế VRAM GPU 4GB, việc đưa trực tiếp một văn bản dài ví dụ bài báo 2.000 từ vào mô hình sinh Transformer Seq2Seq như ViT5 hay BARTPho sẽ ngay lập tức gây ra lỗi tràn bộ nhớ hoặc văn bản bị cắt cụt do vượt quá giới hạn ngữ cảnh 512 tokens. Để giải quyết triệt để vấn đề này, hệ thống phát triển cơ chế tóm tắt Lại hai giai đoạn Two-Stage Hybrid Summarization.



Hình 4.1. Sơ đồ pipeline tóm tắt Lại hai giai đoạn

4.3. Cài đặt mô hình và thiết kế thực nghiệm

4.3.1. Phân tích thống kê tập dữ liệu VietNews

Bộ dữ liệu được sử dụng để tinh chỉnh và đánh giá các mô hình là “nam194/vietnews”. Đây là bộ dữ liệu tóm tắt văn bản tiếng Việt quy mô lớn, chứa các bài báo thu thập từ 3 trang tin điện tử phổ biến tại Việt Nam: Tuổi Trẻ, VnExpress và Người Đưa Tin. Cấu trúc dữ liệu của mỗi mẫu bao gồm các trường thông tin: định danh, tiêu đề, tóm tắt tóm lược và nội dung chi tiết bài viết. Phân bố chi tiết của bộ dữ liệu thực tế được sử dụng trong thực nghiệm được mô tả trong bảng thống kê ASCII dưới đây:

Bảng 4.1: Thống kê chi tiết tập dữ liệu VietNews

Chỉ số phân tích	Tập Train	Tập Validation	Tập Test
Số lượng mẫu (bài báo)	99.134	22.184	22.498
Độ dài bài viết trung bình (từ)	406,5	435,7	429,5
Độ dài bản tóm tắt tham chiếu TB (từ)	32,4	31,8	31,8
Tỷ lệ nén trung bình (%)	9,31%	8,76%	8,92%
Độ dài bài viết tại phân vị 95% (từ)	785	804	812

Quy trình tiền xử lý dữ liệu thực tế: Loại bỏ các bài báo có phần nội dung bài viết hoặc phần tóm tắt bị trống hoặc ngắn dưới 10 từ. Chuẩn hóa văn bản tiếng Việt bằng cách đưa toàn bộ ký tự Unicode về dạng chuẩn NFC nhằm loại bỏ sự không đồng nhất trong gõ dấu tiếng Việt ví dụ chữ “hòa” gõ theo kiểu cũ và mới. Sử dụng thư viện regex để loại bỏ các thẻ HTML rác, các dòng thông tin thừa ở cuối bài viết.

4.3.2. Thiết kế kịch bản thực nghiệm và Các độ đo đánh giá

Quá trình huấn luyện các mô hình diễn giải được thực thi bằng cách sử dụng thư viện “Seq2SeqTrainer” của Hugging Face. Nhóm nghiên cứu thực hiện tinh chỉnh 3 mô hình nền tảng khác nhau để làm cơ sở so sánh thực nghiệm. Các thông số cài đặt huấn luyện thực tế được ghi nhận chi tiết như sau:

Mô hình ViT5-base là mô hình Seq2Seq được phát triển chuyên biệt cho tiếng Việt bởi VietAI. Mô hình được tiền huấn luyện trên khoảng 50GB dữ liệu văn bản tiếng Việt và sở hữu khoảng 220 triệu tham số. Trong nghiên cứu này, ViT5-base được lựa chọn làm mô hình sinh tóm tắt chính và được tinh chỉnh trên bộ dữ liệu VietNews trong 3 epochs.

Mô hình BARTPho-syllable là mô hình Transformer do VinAI phát triển, được thiết kế chuyên biệt cho tiếng Việt ở cấp độ âm tiết. Cách tiếp cận này giúp giảm ảnh hưởng của các từ ngoài từ điển và cải thiện khả năng xử lý ngôn ngữ tự nhiên tiếng Việt. Với khoảng 340 triệu tham số. Mô hình được tinh chỉnh trong 3 epochs kết hợp với bộ lập lịch học cosine decay nhằm nâng cao chất lượng sinh văn bản và duy trì tính ổn định trong quá trình huấn luyện.

Mô hình mT5-small là mô hình Seq2Seq đa ngôn ngữ được phát triển bởi Google với khoảng 300 triệu tham số. Trong nghiên cứu, mT5-small được sử dụng như mô hình đối chuẩn để so sánh với các mô hình được huấn luyện chuyên biệt cho tiếng Việt. Mô hình được tinh chỉnh trên bộ dữ liệu VietNews trong 3 epochs nhằm bảo đảm tính thống nhất về điều kiện thực nghiệm.

Thực nghiệm benchmark được chạy trên 1.000 mẫu ngẫu nhiên được trích xuất có định $seed = 42$ từ tập kiểm thử độc lập của bộ dữ liệu VietNews. 15 kịch bản thực nghiệm được thiết kế bao gồm: Nhóm Extractive: Lọc câu bằng các giải thuật TextRank, LexRank, và LSA. Nhóm Abstractive: Sinh câu tóm tắt trực tiếp từ mô hình gốc tinh chỉnh ViT5, BARTPho, mT5.

Nhóm Hybrid: Kết hợp chéo 2 giai đoạn. Giai đoạn 1 lọc bớt 65% câu rác bằng Extractive *tỷ lệ nén 0.35* rồi mới chuyển sang Giai đoạn 2 cho các mô hình Transformer sinh bản tóm tắt cuối cùng. Các độ đo tự động được cài đặt để đánh giá hiệu năng tóm tắt bao gồm:

- + ROUGE-1: Đo lường mức độ trùng lặp của các từ đơn giữa bản tóm tắt sinh ra và bản tham chiếu do con người viết.
- + ROUGE-2: Đo lường mức độ trùng lặp của các cụm 2 từ liên tiếp.

- + ROUGE-L: Đo lường chuỗi con chung dài nhất, đại diện cho tính mạch lạc và cấu trúc câu.
- + BLEU: Đánh giá độ chính xác của các n-grams (1 đến 4-grams).
- + BERTScore: Sử dụng mô hình PhoBERT nhúng để đo lường độ tương đồng ngữ nghĩa ở cấp độ token, xử lý tốt trường hợp sử dụng từ đồng nghĩa.
- + Semantic Similarity: Cosine similarity của vector biểu diễn toàn câu sử dụng SBERT.
- + Latency: Đo bằng giây thời gian trung bình cần thiết để xử lý xong một tài liệu đầu vào.
- + Composite Score: Điểm trung bình có trọng số của các metric chất lượng để chọn ra thuật toán cân bằng tốt nhất.

4.4. Đánh giá hệ thống và phân tích kết quả đạt được

4.4.1. Số liệu benchmark tóm tắt văn bản

So sánh chi tiết

Mô hình	Nhóm	ROUGE-1	ROUGE-L	BLEU	BERTScore	Semantic	Faithfulness	Hallucination	Độ trễ (s)	Composite
TEXTRANK	Extractive	41.49%	28.04%	7.58%	71.99%	81.7%	100.0%	0.0%	0.010s	61.4%
LEXRANK	Extractive	42.25%	28.15%	7.77%	72.07%	81.8%	100.0%	0.0%	0.006s	61.4%
LSA	Extractive	45.84%	29.13%	7.82%	70.99%	80.3%	100.0%	0.0%	0.006s	60.5%
VIT5	Abstractive	59.68%	38.27%	15.88%	70.74%	74.7%	82.6%	2.1%	2.493s	58.0%
TEXTRANK → VIT5	Hybrid	58.39%	36.78%	14.31%	70.25%	73.9%	83.4%	2.3%	1.644s	57.3%
LEXRANK → VIT5	Hybrid	58.11%	36.65%	14.08%	70.14%	73.8%	83.3%	1.7%	1.614s	57.2%
LSA → VIT5	Hybrid	56.38%	34.56%	12.17%	69.32%	72.5%	83.1%	2.1%	1.566s	56.1%
BARTPHO	Abstractive	53.92%	33.41%	8.08%	67.83%	77.5%	86.2%	0.5%	3.380s	55.8%
TEXTRANK → MT5	Hybrid	54.64%	33.41%	11.41%	68.94%	72.3%	83.4%	2.1%	1.994s	55.6%
TEXTRANK → BARTPHO	Hybrid	53.02%	32.78%	7.79%	67.71%	76.5%	86.9%	0.5%	1.864s	55.5%
LEXRANK → BARTPHO	Hybrid	52.87%	32.60%	7.71%	67.71%	76.5%	86.6%	0.7%	1.685s	55.4%
LEXRANK → MT5	Hybrid	54.36%	33.24%	11.18%	68.83%	72.0%	83.1%	2.6%	1.894s	55.4%
MT5	Abstractive	54.84%	32.95%	10.69%	68.62%	71.4%	81.9%	3.2%	2.728s	55.1%
LSA → MT5	Hybrid	52.42%	31.77%	9.48%	68.05%	70.9%	83.7%	2.7%	1.703s	54.6%
LSA → BARTPHO	Hybrid	51.02%	30.74%	6.77%	66.92%	75.0%	85.7%	1.1%	1.496s	54.2%

Hình 4.2. Kết quả thực nghiệm tóm tắt văn bản trên 1.000 mẫu VietNews

4.4.2. Nhận xét và phân tích chuyên sâu hiệu năng tóm tắt

- Phân tích chất lượng của các mô hình diễn giải

+ Mô hình tinh chỉnh ViT5 đạt điểm ROUGE-L cao nhất hệ thống với giá trị 0,3827, vượt qua mô hình BARTPho là 0,3341 và mT5 là 0,3295. Kết quả này cho thấy bộ tokenizer SentencePiece được tối ưu cho tiếng Việt của ViT5 có khả năng nắm bắt ranh giới từ ghép và ngữ nghĩa ngữ cảnh hiệu quả hơn.

+ Mô hình mT5 chỉ đạt mức hiệu năng trung bình và xuất hiện hiện tượng lặp từ ở một số trường hợp. Nguyên nhân là do bộ từ vựng đa ngôn ngữ của mT5 phải chia sẻ tài nguyên biểu diễn cho nhiều ngôn ngữ khác nhau, làm giảm khả năng sinh văn bản tiếng Việt tự nhiên so với các mô hình được huấn luyện chuyên biệt.

- Đánh giá hiệu quả của Pipeline Lai

+ Giảm độ trễ suy luận

- Đây là kết quả nổi bật nhất của kiến trúc lai. Thay vì đưa toàn bộ văn bản vào mô hình Transformer, hệ thống sử dụng các thuật toán trích xuất để giữ lại khoảng 35% nội dung quan trọng trước khi chuyển sang giai đoạn sinh tóm tắt.
- Mô hình BARTPho giảm thời gian xử lý từ 3,38 giây xuống còn 1,68 giây cho mỗi mẫu khi kết hợp với LexRank, tương đương mức cải thiện khoảng 50,3%. Đối với ViT5, thời gian xử lý giảm từ 2,49 giây xuống còn 1,61 giây khi kết hợp với LexRank.

+ Bảo toàn chất lượng tóm tắt

- Mặc dù lượng token đầu vào giảm đáng kể, chất lượng đầu ra chỉ suy giảm rất nhỏ. Cụ thể, cấu hình TextRank kết hợp ViT5 đạt ROUGE-L bằng 0,3678, chỉ thấp hơn khoảng 3,8% so với ViT5 thuần.

- Điều này chứng minh giai đoạn trích xuất đã loại bỏ được phần lớn thông tin dư thừa nhưng vẫn giữ lại các nội dung quan trọng phục vụ cho quá trình sinh tóm tắt.

+ Tính ổn định phần cứng

Kiến trúc Hybrid giúp giảm đáng kể áp lực bộ nhớ GPU. Trong quá trình thử nghiệm với các văn bản dài trên 1.500 từ, một số mô hình sinh thuần gặp khó khăn về bộ nhớ, trong khi các cấu hình Hybrid vẫn duy trì khả năng xử lý ổn định với thời gian phản hồi dưới 2 giây.

- Điểm mạnh và hạn chế của nhóm Extractive

+ Các thuật toán TextRank, LexRank và LSA đạt điểm Composite Score cao nhờ tốc độ xử lý rất nhanh, dưới 10 mili giây cho mỗi tài liệu, đồng thời duy trì mức Faithfulness đạt 100%.

+ Ưu điểm lớn nhất của nhóm này là không sinh ra nội dung ngoài văn bản gốc nên hoàn toàn tránh được hiện tượng Hallucination.

+ Nhược điểm của các phương pháp trích xuất là bản tóm tắt chỉ đơn thuần là tập hợp các câu được lựa chọn từ tài liệu nguồn. Điều này làm giảm tính liên kết ngữ nghĩa và khiến văn bản thiếu sự mượt mà trong diễn đạt so với các mô hình sinh.

4.5. Khó khăn và hạn chế trong quá trình triển khai thực nghiệm

Giới hạn bộ nhớ GPU: Khi vận hành đồng thời mô hình nhúng, mô hình tái xếp hạng và mô hình sinh tóm tắt trên GPU RTX 3050 Ti 4GB VRAM, hệ thống thường xuyên gặp tình trạng thiếu bộ nhớ.

Để khắc phục hạn chế về tài nguyên phần cứng, nhóm nghiên cứu đã xây dựng cơ chế quản lý vòng đời mô hình nhằm tối ưu việc sử dụng bộ nhớ đồ họa. Hệ thống liên tục giám sát mức sử dụng VRAM và tự động giải phóng các mô hình không được sử dụng trong một khoảng thời gian nhất định. Nhờ đó, hệ thống có thể vận hành ổn định trên các thiết bị có cấu hình phổ thông mà không cần nâng cấp phần cứng GPU.

Một khó khăn khác phát sinh trong quá trình xây dựng hệ thống hỏi đáp là hiện tượng nhiễu dữ liệu trong cơ sở dữ liệu vector. Nhiều tài liệu PDF và DOCX chứa các thành phần lặp lại như tiêu đề, chân trang hoặc các ghi chú kỹ thuật, khiến những nội dung không cần thiết này bị lưu vào cơ sở dữ liệu vector và làm giảm chất lượng truy xuất thông tin. Để giải quyết vấn đề này, nhóm nghiên cứu đã phát triển công cụ làm sạch dữ liệu tự động có khả năng phát hiện và loại bỏ các đoạn văn bản xuất hiện với tần suất bất thường. Sau khi thực hiện quá trình làm sạch và tái tạo vector nhúng, chất lượng hệ thống được cải thiện thể hiện qua chỉ số Faithfulness tăng.

Chương 4 đã trình bày toàn bộ quá trình triển khai thực nghiệm, huấn luyện mô hình và đánh giá hệ thống trên bộ dữ liệu VietNews. Kết quả thực nghiệm cho thấy ViT5 là mô hình diễn giải có chất lượng tốt nhất với ROUGE-L đạt 0,3827, trong khi kiến trúc Hybrid Pipeline giúp giảm đáng kể thời gian xử lý nhưng vẫn duy trì chất lượng tóm tắt ở mức cao. Kết quả này là cơ sở quan trọng để đánh giá mức độ hoàn thành mục tiêu nghiên cứu và đề xuất các hướng phát triển tiếp theo cho hệ thống.

KẾT QUẢ VÀ KIẾN NGHỊ

1. Kết quả đạt được

1.1. Về mặt lý thuyết

Trong quá trình nghiên cứu và thực hiện đề tài “Nghiên cứu và xây dựng hệ thống tóm tắt văn bản tự động tiếng Việt sử dụng các mô hình Transformer và kỹ thuật xử lý ngôn ngữ tự nhiên”, em đã tiếp cận, học hỏi và làm chủ các kiến thức nền tảng cũng như nâng cao.

Đã làm chủ kiến trúc Seq2Seq Transformer với cơ chế Multi-Head Self-Attention, đóng vai trò cốt lõi trong việc hiểu ngữ cảnh văn bản tiếng Việt. Đồng thời, nghiên cứu sâu các mô hình Transformer được huấn luyện riêng cho tiếng Việt như ViT5 và BARTPho, từ đó nắm được sự khác biệt về kiến trúc và phương pháp mã hóa từ vựng.

Đề tài cũng tìm hiểu và hiện thực hóa thành công các phương pháp tóm tắt trích xuất truyền thống gồm TextRank, LexRank và LSA. Các thuật toán này giúp đánh giá khả năng lựa chọn câu quan trọng trong văn bản và làm cơ sở để xây dựng các mô hình lai.

Nghiên cứu còn tiếp cận kiến trúc RAG cho bài toán hỏi đáp tài liệu dài. Các kỹ thuật được nghiên cứu bao gồm phân mảnh ngữ nghĩa động, tìm kiếm lai kết hợp BM25 và Dense Vector, tái xếp hạng bằng Cross-Encoder cùng cơ chế chỉ mục phân cấp RAPTOR nhằm hỗ trợ truy xuất tri thức hiệu quả trên các tài liệu có kích thước lớn.

1.2. Về mặt thực nghiệm

Các mô hình học sâu ViT5 và BARTPho đã được huấn luyện và tinh chỉnh thành công trên 30 nghìn mẫu thử của bộ dữ liệu VietNews gồm khoảng 143 nghìn mẫu. Quá trình huấn luyện áp dụng kỹ thuật LoRA với các tham số phù hợp, giúp giảm yêu cầu phần cứng nhưng vẫn duy trì khả năng hội tụ tốt của mô hình.

Đề tài cũng giải quyết cơ bản bài toán giới hạn bộ nhớ đồ họa và độ dài ngữ cảnh đầu vào của Transformer thông qua việc xây dựng Pipeline tóm tắt lai hai giai đoạn. Giai đoạn đầu sử dụng phương pháp trích rút để loại bỏ phần lớn nội dung dư thừa, trong khi giai đoạn sau sử dụng mô hình sinh để diễn giải lại nội dung theo ngôn ngữ tự nhiên.

Kết quả thực nghiệm cho thấy phương pháp Hybrid giúp giảm từ 35% đến 50% thời gian suy luận của các mô hình sinh mà vẫn duy trì chất lượng tóm tắt ở mức cao. Chẳng hạn, thời gian xử lý của BARTPho giảm từ 3,38 giây xuống còn khoảng 1,68 giây trong khi điểm ROUGE-L chỉ suy giảm nhẹ.

Đề tài đã hoàn thiện một hệ thống phần mềm full-stack với Backend FastAPI và Frontend React, cung cấp giao diện trực quan cho việc thử nghiệm, so sánh mô hình, đánh giá chất lượng và theo dõi hiệu năng hệ thống.

2. Hạn chế còn tồn đọng

Giới hạn về phần cứng là rào cản đáng kể. Với GPU dung lượng 4GB VRAM, việc vận hành đồng thời nhiều mô hình như Embedding Model, Reranker và Generator tạo áp lực lớn lên bộ nhớ đồ họa. Mặc dù cơ chế offload động đã giúp khắc phục vấn đề, thời gian khởi tạo mô hình ở lần chạy đầu vẫn còn tương đối cao.

Chất lượng của Pipeline Hybrid phụ thuộc trực tiếp vào hiệu quả của giai đoạn trích xuất. Nếu các câu chứa thông tin quan trọng bị loại bỏ ở bước đầu tiên, mô hình sinh ở giai đoạn sau không thể khôi phục lại các thông tin đó trong bản tóm tắt cuối cùng.

Hiện tượng ảo giác thông tin vẫn xuất hiện ở mức độ nhỏ đối với các mô hình sinh. Trong một số trường hợp, mô hình có thể bổ sung hoặc diễn giải chưa chính xác các thực thể và số liệu xuất hiện trong văn bản nguồn.

Hệ thống hiện chưa xử lý tối ưu các tài liệu PDF có cấu trúc phức tạp như bảng biểu lồng nhau hoặc sơ đồ hình ảnh, dẫn đến việc trích xuất văn bản đôi khi bị mất định dạng hoặc thiếu thông tin.

3. Hướng phát triển trong tương lai

Một trong những hướng phát triển quan trọng là áp dụng kỹ thuật QLoRA 4-bit nhằm giảm thêm mức tiêu thụ bộ nhớ GPU, từ đó tạo điều kiện thử nghiệm các mô hình lớn hơn như ViT5-large hoặc BARTPho-word trên phần cứng phổ thông.

Đề tài cũng có thể tích hợp các mô hình ngôn ngữ lớn chuyên biệt cho tiếng Việt nhằm nâng cao chất lượng hội thoại và khả năng lập luận của hệ thống ChatRAG.

Phạm vi nghiên cứu có thể được mở rộng sang bài toán tóm tắt đa văn bản, cho phép tổng hợp thông tin từ nhiều nguồn tài liệu khác nhau về cùng một chủ đề hoặc sự kiện.

Để đánh giá toàn diện hơn chất lượng tóm tắt, cần xây dựng quy trình đánh giá có sự tham gia của con người nhằm bổ sung cho các thước đo tự động như ROUGE, BLEU và BERTScore.

Bộ xử lý tài liệu có thể được nâng cấp bằng cách tích hợp các mô hình xử lý bố cục tài liệu hoặc OCR hiện đại, giúp trích xuất chính xác nội dung từ các bảng biểu, biểu đồ và hình ảnh phức tạp phục vụ cho hệ thống RAG.

TÀI LIỆU THAM KHẢO

- [1] N. Giarelis, C. Mastrokostas, and N. Karacapilidis, “Abstractive vs. Extractive Summarization: An Experimental Review,” *Applied Sciences*, vol. 13, no. 13, p. 7620, Jun. 2023, doi: [10.3390/app13137620](https://doi.org/10.3390/app13137620).
- [2] A. Vaswani *et al.*, “Attention Is All You Need,” Aug. 02, 2023, *arXiv*: arXiv:1706.03762. doi: [10.48550/arXiv.1706.03762](https://doi.org/10.48550/arXiv.1706.03762).
- [3] M. Lewis *et al.*, “BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension,” Oct. 29, 2019, *arXiv*: arXiv:1910.13461. doi: [10.48550/arXiv.1910.13461](https://doi.org/10.48550/arXiv.1910.13461).
- [4] N. L. Tran, D. M. Le, and D. Q. Nguyen, “BARTpho: Pre-trained Sequence-to-Sequence Models for Vietnamese,” Jun. 27, 2022, *arXiv*: arXiv:2109.09701. doi: [10.48550/arXiv.2109.09701](https://doi.org/10.48550/arXiv.2109.09701).
- [5] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” May 24, 2019, *arXiv*: arXiv:1810.04805. doi: [10.48550/arXiv.1810.04805](https://doi.org/10.48550/arXiv.1810.04805).
- [6] Y. Yang, P. Carlson, S. He, Y. Qiao, and T. Yang, “Cluster-based Partial Dense Retrieval Fused with Sparse Text Retrieval,” in *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, Washington DC USA: ACM, Jul. 2024, pp. 2327–2331. doi: [10.1145/3626772.3657972](https://doi.org/10.1145/3626772.3657972).
- [7] V. Tretyak and D. Stepanov, “Combination of abstractive and extractive approaches for summarization of long scientific texts,” Jun. 12, 2020, *arXiv*: arXiv:2006.05354. doi: [10.48550/arXiv.2006.05354](https://doi.org/10.48550/arXiv.2006.05354).
- [8] Z. Alami Merrouni, B. Frikh, and B. Ouhbi, “EXABSUM: a new text summarization approach for generating extractive and abstractive summaries,” *J Big Data*, vol. 10, no. 1, p. 163, Oct. 2023, doi: [10.1186/s40537-023-00836-y](https://doi.org/10.1186/s40537-023-00836-y).
- [9] C. Raffel *et al.*, “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer,” Sep. 19, 2023, *arXiv*: arXiv:1910.10683. doi: [10.48550/arXiv.1910.10683](https://doi.org/10.48550/arXiv.1910.10683).
- [10] A. See, P. J. Liu, and C. D. Manning, “Get To The Point: Summarization with Pointer-Generator Networks,” Apr. 25, 2017, *arXiv*: arXiv:1704.04368. doi: [10.48550/arXiv.1704.04368](https://doi.org/10.48550/arXiv.1704.04368).
- [11] D. F. Coimbra, “Hybrid Extractive/Abstractive Summarization Using Pre-Trained Sequence-to-Sequence Models”.

- [12] O. Yenen, “MonaVec: A Training-Free Embedded Vector Search Kernel for Edge and Offline AI Systems,” Jun. 17, 2026, *arXiv*: arXiv:2606.19458. doi: [10.48550/arXiv.2606.19458](https://doi.org/10.48550/arXiv.2606.19458).
- [13] L. Xue *et al.*, “mT5: A massively multilingual pre-trained text-to-text transformer,” Mar. 11, 2021, *arXiv*: arXiv:2010.11934. doi: [10.48550/arXiv.2010.11934](https://doi.org/10.48550/arXiv.2010.11934).
- [14] J. Zhang, Y. Zhao, M. Saleh, and P. J. Liu, “PEGASUS: Pre-training with Extracted Gap-sentences for Abstractive Summarization,” Jul. 10, 2020, *arXiv*: arXiv:1912.08777. doi: [10.48550/arXiv.1912.08777](https://doi.org/10.48550/arXiv.1912.08777).
- [15] D. Q. Nguyen and A. T. Nguyen, “PhoBERT: Pre-trained language models for Vietnamese,” Oct. 05, 2020, *arXiv*: arXiv:2003.00744. doi: [10.48550/arXiv.2003.00744](https://doi.org/10.48550/arXiv.2003.00744).
- [16] T.-H. Nguyen and T.-N. Do, “Pre-Training Clustering Models to Summarize Vietnamese Texts,” *Vietnam J. Comp. Sci.*, vol. 12, no. 01, pp. 83–100, Feb. 2025, doi: [10.1142/S2196888824500118](https://doi.org/10.1142/S2196888824500118).
- [17] P. Lewis *et al.*, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks,” Apr. 12, 2021, *arXiv*: arXiv:2005.11401. doi: [10.48550/arXiv.2005.11401](https://doi.org/10.48550/arXiv.2005.11401).
- [18] D. S., S. N., J. Andrew, and M. Mazzara, “Unified extractive-abstractive summarization: a hybrid approach utilizing BERT and transformer models for enhanced document summarization,” *PeerJ Computer Science*, vol. 10, p. e2424, Nov. 2024, doi: [10.7717/peerj-cs.2424](https://doi.org/10.7717/peerj-cs.2424).
- [19] L. Phan, H. Tran, H. Nguyen, and T. H. Trinh, “ViT5: Pretrained Text-to-Text Transformer for Vietnamese Language Generation,” May 26, 2022, *arXiv*: arXiv:2205.06457. doi: [10.48550/arXiv.2205.06457](https://doi.org/10.48550/arXiv.2205.06457).